

A data analytics method based on data science and machine learning for bank risk prediction in credit applications for financial institutions

Remigio Hurtado Ortiz

Universidad Politécnica Salesiana
Cuenca, Ecuador
rhurtadoo@ups.edu.ec

Edisson Salinas Jara

Universidad Politécnica Salesiana
Cuenca, Ecuador
esalinasj@est.ups.edu.ec

Juan Hurtado Ortiz

Instituto Superior Tecnológico Sudamericano
Cuenca, Ecuador
jphurtado2@sudamericano.edu.ec

Johnny Maisincho Panjón

Universidad Politécnica Salesiana
Cuenca, Ecuador
jmaisinchop@est.ups.edu.ec

Abstract—Nowadays, banks grant credits so that customers can acquire a good or service, start or improve a business, among other benefits. The problems that may arise are over-indebtedness and low saving possibilities on the part of customers, so the tendency is the risk of default. Financial institutions require tools for default risk analysis and problem prediction. Therefore, in this research, a data analysis method based on data science and machine learning is proposed for bank risk prediction in credit applications for financial institutions. For the analysis process and for the prediction of a credit, predictive analysis methods are used: Genetic Algorithms (GA), Random Forest (RF), K-Nearest-Neighbor (KNN), Support Vector Machines (SVM) and Neural Network (NN). Quality metrics such as Accuracy, Precision, Recall and F1 Score are used to evaluate the results. A public dataset called Statlog [1] is used. This work opens the door for data analysis in different banking services. The main objective of this research is to help financial companies to optimize their processes.

I. INTRODUCCIÓN

Esta sección está dividida en cuatro subsecciones: 1) Créditos en entidades bancarias, 2) Fundamentos de machine Learning, 3) Análisis de datos, y 4) Metodología CRISP-DM.

1) Créditos en entidades bancarias: es un contrato por el cual la entidad financiera en la cual pone a disposición de socio una cierta cantidad de dinero por el cual tendrá que devolver con intereses y comisiones según el plazo pactado para hacer el pago. Una entidad bancaria es una agrupación o una entidad que tiene como objetivo ofrecer servicios financieros para realizar depósitos, retiros, solicitudes de créditos, entre otros. Por lo tanto, las entidades bancarias requieren conocer el riesgo que correrá al momento de aprobar un crédito, realizar predicciones para analizar el riesgo que correrá con el socio al momento de aprobar un crédito y prevenir problemas futuros. La era de Big Data dificulta el análisis de datos tradicional y requiere una transformación digital en los procesos de las instituciones financieras. Para explotar los datos masivos, descubrir conocimiento y realizar

predicciones se requiere técnicas eficientes para procesar grandes cantidades de datos. Por lo tanto, surge la necesidad de técnicas como Machine Learning y Deep Learning.

2) Fundamentos de machine learning: el machine learning se incluye dentro de un campo mucho más amplio como es el de la inteligencia artificial. El aprendizaje automático busca construir sistemas o máquinas inteligentes que puedan aprender a través de la experiencia, sin ser programados explícitamente ni requerir ninguna intervención humana.

3) El análisis de datos: es un proceso de recolección, limpieza, transformación y modelado de datos con el objetivo de descubrir información útil, informar conclusiones y respaldar la toma de decisiones. El análisis de datos tiene múltiples facetas y enfoques, que abarcan diversas técnicas bajo una variedad de nombres como minería de datos, inteligencia de negocios, aprendizaje automático, análisis del Big Data, etc. El análisis de datos es la piedra angular en diferentes dominios de negocios y de las ciencias.

4) CRISP-DM: Se trata de un modelo estándar abierto del proceso que describe los enfoques comunes que utilizan los expertos en análisis de datos. Es el modelo analítico más usado. El método propuesto se basa en esta metodología [1].

El resto del documento está estructurado de la siguiente manera:

II. Trabajo relacionado: se menciona los trabajos más relevantes relacionados con el problema y las técnicas utilizadas en este trabajo. III. Método propuesto: se explica a detalle el proceso del método propuesto. IV. Diseño de experimentos: se expone las características del dataset, parámetros de optimización en el método propuesto y medidas de calidad. V. Resultados y discusión: se presenta los resultados siguiendo los pasos del método propuesto. VI. Conclusiones: se presenta las conclusiones más relevantes y el trabajo futuro.

II. TRABAJO RELEVANTE RELACIONADO

A continuación, se presenta el trabajo relacionado más relevante con respecto a: 1) riesgo para el otorgante de crédito y 2) comportamiento de receptores de créditos. Cabe destacar, que estos trabajos han incorporado machine learning, y deep learning.

1) Riesgo para el otorgante de crédito

- En [2] se propone el uso de una red neuronal (Perceptrón multicapa) para predecir el comportamiento de una PYME (pequeña y mediana empresa) respecto a la morosidad en el pago de sus créditos, permitiendo así anticipar y minimizar los efectos desfavorables en la economía y gestión de la Caja Metropolitana de Lima. Algunos métodos relacionados con machine learning aplicado a PYMES se presentan en [3] y [4].
- En [5] se propone una red neuronal que presenta un porcentaje de precisión aceptable para clasificar una institución financiera sin fines de lucro dentro de una escala de riesgo con base al valor de sus índices financieros; ayudando a la detección temprana de problemas futuros. La red neuronal artificial presenta una precisión de clasificación del 79.59%, porcentaje que está dentro del rango de precisión obtenido por estudios revisados para actividades de clasificación en entidades financieras.
- En [6] se da a conocer el desarrollo de la libertad financiera y la integración. Se indica que los bancos comerciales chinos se enfrentarán a circunstancias graves en el curso de la revolución financiera, lo que provocará un mayor riesgo crediticio de los bancos comerciales. La aplicación de redes neuronales artificiales en la alerta temprana del riesgo crediticio de los bancos comerciales es un gran apoyo. El propósito de esta investigación es el estudio de la alerta temprana después del préstamo.

2) Comportamiento de receptores de créditos

- En [7] se predice si un solicitante de crédito hipotecario incumplirá el pago de una o más cuotas del potencial crédito usando técnicas de Machine Learning. El problema de Machine Learning en este caso es uno de clasificación de dos clases, donde se busca identificar si un solicitante incumplirá o no el pago de una o más de las cuotas del potencial crédito. El ejercicio iterativo usa las métricas de validación derivadas de la matriz de confusión para tomar las diferentes decisiones de elección y hacer seguimiento a las mejoras del modelo. El mejor modelo desarrollado obtiene un accuracy de 75% con asertividad asimétrica entre las clases, logrando un F1-Score de 85% para la clase mayoritaria y de 28% para la minoritaria.
- En [8], [9], [10], [11], [12] se evalúa modelos de redes neuronales artificiales para la clasificación de clientes en el proceso de evaluación de créditos de consumo. Las arquitecturas de redes neuronales utilizadas son la red

Perceptrón Multicapa y la Red Modular. Los mejores resultados obtenidos con la implementación de la red Perceptrón Multicapa, en la etapa de prueba y producción, corresponden a un 87% y 64,5% de casos correctamente clasificados, respectivamente.

- En [13], [14], [15], [16], [17] se desarrolla modelos de red neuronal para hacer análisis efectivo para la calificación crediticia de las corporaciones. Se utilizan los algoritmos de retro propagación y Levenberg-Marquardt. Los resultados muestran redes eficientes y estas constituyen herramientas útiles para la predicción de la calificación crediticia de las empresas.

III. MÉTODO PROPUESTO

En esta sección se presenta el método de análisis, los parámetros del método y los algoritmos que detallan el proceso de análisis. Cabe destacar, que el método de análisis propuesto se basa en la metodología CRISP-DM. En la Figura 1 se presenta el método propuesto compuesto de tres fases. **Primera fase:** en esta fase tenemos el método de análisis, el primer paso es la limpieza de datos, la transformación de variables (categóricas a numéricas) y análisis descriptivo. El análisis descriptivo es un método de análisis estadístico que antecede a los estudios cuantitativos en el cual podemos ver lo que es la media de las variables, el mínimo, el máximo, correlaciones entre otras. **Segunda Fase:** los métodos de análisis predictivo ayudan a predecir en qué casos la entidad bancaria corre riesgo con un socio al momento de solicitar un crédito. **Tercera Fase:** se evalúa los métodos para realizar las predicciones con mayor efectividad.

En la siguiente sección se explica el diseño de experimentos del método de análisis.

TABLE I
DESCRIPCIÓN DE PARÁMETROS DE MÉTODOS DE ANÁLISIS PREDICTIVO

Parámetros para Red Neuronal (RN)	
Epochs	Número de iteraciones
Optimizer	Tipo de algoritmo de descenso del gradiente
Batch_size	Cantidad de muestras por batch
Parámetros para Máquinas de vectores de soporte (SVM)	
C	Parámetro de penalización
Gama	Coficiente para cada kernel
kernel	Función de aprendizaje
Parámetros para Algoritmo Genético (AG)	
genes	Cantidad de genes
generaciones	Cantidad de iteraciones
pressure	Cuántos individuos se seleccionan para reproducción
Mutation_chance	Probabilidad de que un individuo mute
K	Número de individuos con mayor fitness
Parámetros para Random Forest(RF)	
n_estimators	Número de árboles incluidos en el modelo
max_depth	Profundidad máxima que pueden alcanzar los árboles
Parámetros K-Nearest-Neighbor(KNN)	
n_neighbors	Número de vecinos




Fig. 1. Método propuesto de análisis de datos

IV. DISEÑO DE EXPERIMENTOS

Esta sección presenta las características del dataset, los parámetros para optimización de los métodos predictivos, y posteriormente las medidas de calidad.

A. Características del dataset

En la Tabla II se presenta las características del dataset.

TABLE II
CARACTERÍSTICAS DEL DATASET

Dataset	Número de instancias	Número de variables
Statlog [18]	1000	21

B. Parámetros para optimización

En la Tabla III se presenta los valores para optimización de los métodos de análisis predictivo.

C. Medidas de calidad

En esta sección se presenta las medidas de calidad, las cuales se utilizan para evaluar y determinar el mejor método de análisis predictivo. Para la evaluación se utiliza la técnica

de Validación Cruzada K-Folds (K=20). A continuación, se presenta las medidas de calidad.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

Where TP , TN , FP and FN are the number of True Positives, True Negatives, False Positives and False Negatives, respectively.

V. RESULTADOS Y DISCUSIÓN

En esta sección se da a conocer los resultados más relevantes siguiendo el método de análisis propuesto; estos se presentan en tres partes: 1) Resultados de preparación de datos, 2) Resultados de métodos predictivos, y 3) Resultados de la red neuronal.

1) Resultados de preparación de datos

En este paso se realiza el análisis del conjunto de datos. En la Figura 2 se presenta las correlaciones entre variables con respecto a la variable de salida (TIPOCLIENTE). Se puede notar que las variables más influyentes para determinar el riesgo o tipo de cliente son: activos, plazo de meses de crédito y monto de crédito. La variable propósito de crédito indica que hay propósitos (bienes a adquirir) que están más o menos correlacionados con la decisión de aprobación de un crédito.

2) Resultados de métodos predictivos

En esta sección se presenta los resultados de la fase 2 del método de análisis. Se ha entrenado y optimizado varios métodos predictivos ajustando los parámetros de cada uno, a fin de obtener los mejores resultados. En la tabla 4 se presentan los parámetros finales de la optimización. En la Tabla V se presenta los resultados de los métodos de predicción. El mejor método es la red neuronal, los resultados indican que es la técnica más apropiada para realizar la predicción de créditos con un Accuracy de 0.775.

3) Resultados de la red neuronal

En la Figura 3 se presenta la evolución en train y test del método de la red neuronal. En la Figura 4 se presenta el mapa del proceso de optimización Grid Search para la optimización de la densidad de capas de la red neuronal. Se puede notar que la mejor combinación es 11 con 64 neuronas y 12 con 2 neuronas.

TABLE III
VALORES PARA OPTIMIZACIÓN DE MÉTODOS

Método	Valores de parámetros
RN	De compilación: epochs=20,25,30,40,50,60,80,90,100 batch_size=1,5,10,15,20,25,30,40,50,60,70,80,90,100 optimizador= Adaptive Gradient Algorithm (AdaGrad), Adadelata (variante de AdaGrad), Root Mean Square Propagation (RMSprop), Adaptive moment estimation (Adam).
	De activación de cada capa: Capas 1, 2 y 3: tangente hiperbólica, lineal, rectificadora Capa 4: sigmoide
	De densidad de capas (cantidad de neuronas): capas 1, 2 y 3: 2,4,8,16,32,64,96,128,160,192,224,256,512 capa 4 (de salida): 1 neurona
	De dropout en capas: capas 1, 2 y 3: 0, 0.05, 0.1, 0.15, 0.2, 0.3, 0.4, 0.5
SVM	gamma=0.1, 0.5, 1 kernel=lineal, polinomial, radial (rbf), sigmoide C=0.001, 0.1, 1, 5, 10, 50
KNN	n_neighbors= entre 1 a 30
RF	n_estimators = 100, 150, 200,250,300 max_depth = 10, 15, 20, 25,30, 35, 40, 50, 60
GA	generaciones=100,500,1000 pressure=20 mutation_chance=0.2 K=5,10,50,100,200

TABLE IV
PARÁMETROS FINALES

Método	Valores de parámetros
RN	epochs=50 batch size=40 optimizador=RMSprop 4 capas (64,2,64,1) dropout de capas (0,0.3, 0.1) funciones de activación: (rectificadora, rectificadora, sigmoide)
SVM	kernel=sigmoid C=5 gama=0.1
RF	n_estimators=200 max_depth=30
KNN	n_neighbors=28
GA	generaciones=1000 pressure=20 mutation_chance=0.2 K=5

TABLE V
COMPARACIÓN DE MÉTODOS PREDICTIVOS

MÉTODO	ACCURACY	PRECISION	RECALL	F1
RN	0.775	0.8333	0.8511	0.8421
SVM	0.65	0.7647	0.7324	0.7482
KNN	0.755	0.7925	0.8873	0.8372
RF	0.755	0.7962	0.8803	0.8361
AG	0.3733	0.76	0.0945	0.1681

En la Figura 5 se presenta la matriz de confusión con el detalle de la cantidad de Verdaderos Positivos, Verdaderos Negativos, Falsos Positivos y Falsos Negativos. Siendo Positivo “Otorgado” y Negativo “No Otorgado”.

VI. CONCLUSIONES

En esta investigación se proporcionó un método de análisis que incluye machine learning cumpliendo con el objetivo de

predecir el riesgo bancario en solicitudes de créditos para instituciones financieras. En la primera fase se realizó la transformación de variables y análisis de correlaciones entre variables. El análisis de correlación indicó que las variables más influyentes para determinar el riesgo o tipo de cliente son: activos, plazo de meses de crédito y monto de crédito. En la segunda fase 2 se realizó el análisis predictivo con varias técnicas de machine learning, la técnica que presentó mejores resultados fue la red Neuronal, con un accuracy equivalente a 0.775. Por lo tanto, la red neuronal es la técnica que mejor se adaptó al método de análisis y consiguió las mejores predicciones. Cabe destacar, que le siguió de cerca la técnica Random Forest, que es una técnica de tipo ensamble, que actualmente es de gran relevancia en problemas de clasificación. Como trabajo futuro, esta investigación plantea experimentar con nuevos procesos de ciencia de datos y técnicas predictivas de machine learning y deep learning, además, se plantea el desarrollo de nuevos métodos de análisis aplicados en áreas del ámbito bancario.

REFERENCES

- [1] Wirth, Rüdiger, and Jochen Hipp. "CRISP-DM: Towards a standard process model for data mining." Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining. Vol. 1. 2000.
- [2] Alva Ranilla, Mayra Yessica, and Keiko Cecilia Tamashiro Wong. "Machine Learning para predecir la morosidad en créditos MYPEs de la Caja Metropolitana de Lima." (2012).
- [3] Condori Quispe, Martha. "Modelo de red neuronal para la simulacion del riesgo crediticio de pymes de la ciudad de La Paz." Diss. 2011.
- [4] López García, José Ramón. "Modelización de la probabilidad de accidente laboral en función de las condiciones de trabajo mediante técnicas "Machine Learning"." (2017).
- [5] Cinca, Carlos Serrano, and José Luis Gallizo Larraz. "Las redes neuronales artificiales en el tratamiento de la información financiera." Departamento de Contabilidad y Finanzas, Universidad de Zaragoza (1996).




Fig. 2. Correlaciones del dataset




Fig. 3. Evolución de la red neuronal




Fig. 4. Mapa de Grid Search de la optimización




Fig. 5. Matriz de confusión

- [6] Jiang, Hong, and Chenqi Wang. "A study on credit risk early warning model of commercial banks based on BP neural network." 2011 International Conference on Computer Science and Service System (CSSS). IEEE, 2011.
- [7] Tafur Hernández, Cristhian David. "Riesgo por incumplimiento de pagos en créditos de vivienda." (2022).
- [8] Rozas Urra, Juan, Oscar Soto Lorca, and Luis Eduardo Canales Carrasco. Redes neuronales para el apoyo al proceso de evaluación de otorgamiento de créditos de consumo. Diss. Universidad de Talca (Chile). Departamento de Informática de Gestión, 2003.
- [9] Fernández, Ana Ofelia Negrete. "Redes Neuronales." (2021).
- [10] Tornero Lucas, Juan. "Machine Learning: modelos ocultos de Markov (HMM) y redes neuronales artificiales (ANN)." (2017).
- [11] Aguilar, Gilberto Sotolongo, and María Victoria Guzmán Sánchez. "Aplicaciones de las redes neuronales. El caso de la Bibliometría." Ciencias de la Información 32.1 (2001).
- [12] Liu, Yijun, et al. "Artificial Neural Networks for Corporation Credit Rating Analysis [C]." 2009 International Conference on Networking and Digital Society, Vol. 1, 2009.
- [13] Ghobadi, Fahimeh, and Mohsen Rohani. "Cost sensitive modeling of credit card fraud using neural network strategy." 2016 2nd international conference of signal processing and intelligent systems (ICSPIS). IEEE, 2016.
- [14] Shen, Jiatong. "Credit card fraud detection using autoencoder-based deep neural networks." 2021 IEEE 2nd International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE). IEEE, 2021.
- [15] Mora Cuartas, Andrés Mauricio, Maribel Serna Rodríguez, and Natalia Serna Rodríguez. "Las Entidades bancarias en Colombia, consecuencia de un movimiento constante del sector bancario." (2011).
- [16] Quiliche Villanueva, Marina Haydee. "Propuesta de un diseño de mejora del proceso de atención de clientes para mejorar la calidad del servicio de una entidad Bancaria Cajamarca 2016." (2016).
- [17] Bustos, Laura Valdunciel, Marcela Leonor Flórez Romero, and José Ángel Miguel Dávila. "Análisis de la calidad del servicio que prestan las entidades bancarias y su repercusión en la satisfacción del cliente y la lealtad hacia la entidad." RAE: Revista Asturiana de Economía 38 (2007): 79-107.
- [18] Hofmann, H. "UCI Machine Learning Repository: Statlog (German Credit Data) Data Set." (2013).