

CAPÍTULO

2

REPASO DE CONCEPTOS ESTADÍSTICOS BÁSICOS

La mayoría de las técnicas para la elaboración de pronósticos se basan en conceptos estadísticos fundamentales que se estudian en libros de texto de estadística en los negocios y en cursos introductorios de estadística. Este capítulo examina algunos de los conceptos básicos que servirán como base para la mayoría del material en el resto del libro.

La mayoría de los procedimientos estadísticos hacen deducciones sobre datos de interés, llamados *población*, después de la selección y la medición de un subgrupo de tales datos, llamado *muestra*. La selección cuidadosa de una muestra representativa y el uso de una muestra lo suficientemente grande son componentes importantes de un proceso estadístico deductivo, que tenga un grado de riesgo aceptablemente bajo.

En la elaboración de pronósticos, generalmente trabajamos con datos históricos en un intento por predecir el futuro incierto. Por tal motivo, nos concentraremos en examinar los datos de la muestra, en manipular estos datos de alguna forma y en usar los resultados para efectuar pronósticos.

DESCRIPCIÓN DE DATOS CON RESÚMENES NUMÉRICOS

El objetivo de los procedimientos estadísticos descriptivos es detallar brevemente un conjunto grande de mediciones, con unos cuantos valores clave resumidos. El resumen más común se obtiene promediando los valores. En estadística, el proceso de promediar generalmente se realiza calculando la *media*, la cual implica la suma de todos los valores y la división entre el número de éstos. Aunque en cierto sentido la media indica la “parte de en medio”, este cálculo es sensible a unas cuantas mediciones que sean mucho más grandes o mucho más pequeñas que el resto. Estas mediciones inusuales se denominan *valores atípicos*. El ejemplo 2.1 presenta una ilustración de este fenómeno.

La media de la muestra ($\bar{X}$ o X -testada) se calcula usando la ecuación 2.1.

$$\bar{X} = \frac{\sum X}{n} \quad (2.1)$$

donde

$\bar{X}$ = la media de la muestra

$\sum X$ = la suma de todos los valores de la muestra

n = el tamaño de la muestra

Para simplificar los cálculos en este texto, se usa un tipo de notación abreviada. En la notación simplificada para la suma de todos los valores de X (véase la ecuación 2.1), se entiende que la sumatoria va desde 1 hasta n . Un sistema de notación más formal para este procedimiento es

$$\sum_{i=1}^n X_i$$

donde el subíndice i varía de su valor inicial de 1 a n , en incrementos de 1. Puesto que casi todas las sumas van de 1 a n , omitiremos los índices inicial y final, y usaremos la notación más sencilla, excepto donde sea necesaria una notación más completa para fines de claridad.

Además de la tendencia central de un conjunto de valores, obtenidos al calcular la media, también es interesante conocer el rango (intervalo) a través del cual se dispersan los valores alrededor de la media. La *desviación estándar* es una unidad para medir la distancia desde la media. La fórmula para la desviación estándar está dada por

$$S = \sqrt{\frac{\Sigma(X - \bar{X})^2}{n - 1}} = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{n}}{n - 1}} \quad (2.2)$$

donde el numerador es la suma de las diferencias al cuadrado, entre los valores medidos y su media.

Muchos procedimientos estadísticos utilizan la *varianza* de la muestra. La varianza de un conjunto de medidas es la desviación estándar al cuadrado. Entonces, la varianza de la muestra (S^2) se calcula como

$$S^2 = \frac{\Sigma(X - \bar{X})^2}{n - 1} = \frac{\Sigma X^2 - \frac{(\Sigma X)^2}{n}}{n - 1} \quad (2.3)$$

Ejemplo 2.1 Cálculo de media, varianza y desviación estándar

Considere el siguiente conjunto de edades de personas:

23, 38, 42, 25, 60, 55, 50, 42, 32, 35

Para esta muestra, $n = 10$ y

$$\sum_{i=1}^n X_i = X_1 + X_2 + \cdots + X_{10} = 23 + 38 + \cdots + 35 = 402$$

$$\bar{X} = \frac{\Sigma X}{n} = \frac{402}{10} = 40.2$$

$$S^2 = \frac{\Sigma(X - \bar{X})^2}{n - 1} = \frac{(23 - 40.2)^2 + \cdots + (35 - 40.2)^2}{10 - 1} = \frac{1,339.6}{9} = 148.84$$

$$S = \sqrt{S^2} = \sqrt{148.84} = 12.2$$

Los cálculos se muestran en la tabla 2.1. La media de la muestra es 40.2 años, la varianza de la muestra es 148.84 y la desviación estándar de la muestra es 12.2 años.

TABLA 2-1 Cálculo de S^2 ($\bar{X} = 40.2$)		
X	$X - \bar{X}$	$(X - \bar{X})^2$
23	-17.2	295.84
38	-2.2	4.84
42	1.8	3.24
25	-15.2	231.04
60	19.8	392.04
55	14.8	219.04
50	9.8	96.04
42	1.8	3.24
32	-8.2	67.24
35	-5.2	27.04
		$\Sigma(X - \bar{X})^2 = 1,339.60$
		$S^2 = \frac{1,339.60}{10 - 1} = 148.84$

Para indicar la sensibilidad de la media a una medición atípica, suponga que sustituimos la edad 60 con una edad mucho mayor, digamos 90. Sustituyendo esta edad, la media sería

$$\bar{X} = \frac{\Sigma X}{n} = \frac{23 + \cdots + 25 + 90 + 55 + \cdots + 35}{10} = \frac{432}{10} = 43.2$$

Incrementar el tamaño de una sola de las diez edades originales da como resultado un incremento de 3 años en la media de la edad.

El término *grados de libertad* se usa para indicar el número de datos que son libres entre sí, en el sentido de que no pueden calcularse uno a partir del otro y, por lo tanto, llevan piezas de información únicas. Por ejemplo, suponga que se hacen los tres enunciados siguientes:

Estoy pensando en el número 5. Estoy pensando en el número 7. La suma de los dos números en que estoy pensando es 12.

A primera vista, se presentan tres piezas de información. Sin embargo, si se conocen cualesquiera dos de estos enunciados, el otro se podría inferir. Diríamos entonces que sólo hay dos piezas únicas de información en los tres enunciados o, usando el término estadístico, sólo hay dos grados de libertad porque únicamente dos de los valores tienen libertad para variar; no así el tercero.

Los *grados de libertad* se refieren al número de datos que son independientes uno de otro y que tienen piezas de información únicas

En el ejemplo que se presenta en la tabla 2-1, las edades de 10 personas constituyen una muestra con 10 grados de libertad. Cualquier edad pudo haberse incluido en la muestra y, por lo tanto, cada una de las edades tiene libertad para variar. Cuando se calcula la media, se usan las 10 edades para contar con una edad media igual a 40.2 años.

El cálculo de la desviación estándar de la muestra difiere. Cuando se calcula la desviación estándar de la muestra, se usa un estimado de la media de la población (la media de la muestra $\bar{X}$). Si en los cálculos se emplea la media de la muestra como un estimado de la media de la población, por lo general se obtendrá una desviación estándar más pequeña que la desviación estándar de la población. Sin embargo, este problema se corrige dividiendo el valor $\sum(X - \bar{X})^2$ entre los grados de libertad adecuados. Una vez que se calcula la media de la muestra, sólo se requieren nueve de las desviaciones $X - \bar{X}$, en este ejemplo, para calcular la desviación estándar de la muestra. Dadas nueve de las desviaciones, se determina la última desviación, puesto que $\sum(X - \bar{X})$ debe ser igual a cero. Por lo tanto, decimos que la desviación estándar de la muestra (o varianza de la muestra) tiene nueve grados de libertad. En general, siempre que se utilice un estadístico muestral para estimar un parámetro de la población, se pierde un grado de libertad.

Se pueden definir estadísticos de resumen para poblaciones. Para distinguir entre parámetros poblacionales de estadísticos muestrales, usamos notaciones diferentes. La tabla 2-2 presenta los símbolos usados tanto para parámetros de la población como para estadísticos muestrales.

La media y la desviación estándar son las medidas más comúnmente usadas para describir datos muestrales de forma breve y significativa. Sin embargo, están disponibles otras medidas de resumen descriptivas. Por ejemplo, la *mediana* se usa a menudo para indicar el valor de la parte media o central en un conjunto de datos. La mediana es el valor que divide por la mitad un conjunto de mediciones ordenadas. Es decir, la mitad de las mediciones son menores que la mediana y la mitad son mayores. Puesto que la mediana simplemente divide un conjunto de mediciones por la mitad, es invariable si, por ejemplo, se incrementa la medición más grande. Decimos que la mediana es *resistente* a los efectos de valores atípicos.

Algunas veces, el *rango* de datos se presenta como una medida de dispersión burda. El rango es la diferencia entre los valores mayor y menor. Por ejemplo, el rango de edades en la tabla 2-1 es 37 (60-23).

Después de que los valores numéricos se ordenan de menor a mayor, los *cuartiles* dividen el conjunto de datos en cuatro partes iguales. Como hemos visto, la mediana divide el conjunto ordenado en dos partes iguales y, algunas veces, se llama el *segundo cuartil* y se denota con Q_2 . El *primer cuartil* (Q_1) divide la mitad inferior del conjunto en dos partes iguales, en tanto que el *tercer cuartil* (Q_3) divide la mitad superior en dos partes iguales. El conjunto de edades en la tabla 2-1, por ejemplo, tiene un primer cuartil de $Q_1 = 30.25$, una mediana (o segundo cuartil) de $Q_2 = 40$ y un tercer cuartil de $Q_3 = 51.25$.

Finalmente, el *rango intercuartil* es otro indicador de la variabilidad de un conjunto de datos. Es simplemente la diferencia entre el tercer cuartil y el primer cuartil ($Q_3 - Q_1$), es decir, el rango para el 50% central de los valores de los datos. Para los datos de edades, el rango intercuartil es 21 ($51.25 - 30.25$).

Minitab y Excel sirven para calcular la mayoría de los estadísticos descriptivos presentados hasta aquí. La figura 2-1 muestra el resultado de Minitab para los datos de edades de la tabla 2-1. Las instrucciones para el cálculo de estadísticos descriptivos usando Minitab y Excel se presentan en las secciones de aplicaciones de Minitab y Excel, al final de este capítulo.

TABLA 2-2 Notación para parámetros de la población y de la muestra

<i>Estadístico</i>	<i>Símbolo de población</i>	<i>Símbolo de muestra</i>
Media	μ	$\bar{X}$
Varianza	σ^2	S^2
Desviación estándar	σ	S




FIGURA 2-1 Resultado de Minitab para estadísticos descriptivos

PRESENTACIÓN DE INFORMACIÓN NUMÉRICA

En la elaboración de pronósticos, trabajamos con dos tipos de datos: *datos transversales*, los cuales consisten en observaciones desde el mismo marco de referencia temporal; y *datos de series de tiempo*, que consisten en una secuencia de observaciones en el tiempo. La tabla 2-3 muestra un ejemplo de datos transversales: el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta específica de Fortune 500. Otro ejemplo son los ingresos anuales de ejecutivos corporativos en 2006 y los precios de venta de casas en cierta ciudad en un día determinado. Algunos ejemplos de datos de series de tiempo son el número de visitantes mensuales al Grand Coulee Dam Visitor Center durante varios años, las ventas mensuales de Sears Corporation durante los últimos diez años, el precio diario de la acción de IBM para 2006 y la producción anual de trigo en Estados Unidos para el periodo 2000-2005.

Una de las cuestiones más importantes que se deben hacer primero cuando se explora una variable es visualizar los datos en tablas y gráficas. Las características básicas de los datos, incluyendo observaciones inusuales y patrones únicos, se perciben más fácil visualmente. A veces, incluso, las gráficas sugieren explicaciones posibles para alguna variación en los datos.

Un *diagrama de puntos* es una de las formas más simples de visualizar gráficamente los datos. En la figura 2-2 el eje horizontal presenta el rango de valores para el ingreso neto como un porcentaje del capital invertido de la tabla 2-3. Cada observación se representa usando un punto colocado encima del eje. Los diagramas de puntos muestran los detalles de los datos y también le permiten a un pronosticador comparar dos o más conjuntos de datos.

Un *diagrama de caja* es útil para mostrar las características de distribución de los datos. La figura 2-3 ilustra un diagrama de caja del ingreso neto como un porcentaje de los datos del capital invertido de la tabla 2-3. En la mediana se traza una línea a lo largo de la caja. Esta línea

TABLA 2-3 Ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

17	23	22	18	8	7	12	2	49	14
14	36	16	7	3	8	10	11	20	17
15	25	18	12	20	7	5	11	0	22
14	10	14	19	8	12	13	21	3	22
11	18	2	18	14	11	36	16	7	14
12	14	10	8	20	13	8	23	6	21
9	23	7	14	25	12	12	8	11	5
18	13	14	9	16	2	19	21	18	9
14	2	20	17	11	16	13	12	22	16
7	6	14	10	1	21	35	20	18	28
17	15	9	12	5	10	14	1	17	14
14	14	6	22	16	13	14	8	12	6
15	10	22	19	16	4	20	18	2	3
20	7	15	39	4	3	10	7	15	16
12	13	12	11	18	10	13	7	13	12
14	8	11	17	11	22	16	11	12	11
9	11	13	0	12	3	9	9	13	27
1	16	18	12	11	0	10	9	12	22
18	44	4	3	17	12	8	16	7	16
27	11	19	12	22	3	14	14	7	8
11	1	3	17	8	7	5	19	22	




FIGURA 2-2 Diagrama de puntos para el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

divide los datos en dos secciones iguales. El borde inferior del cuadro es el primer cuartil (Q_1), y el borde superior es el tercer cuartil (Q_3). Se construyen límites adicionales usando el rango intercuartil ($Q_3 - Q_1$). El límite inferior se localiza en $Q_1 - 1.5(Q_3 - Q_1)$, y el límite superior se localiza en $Q_3 + 1.5(Q_3 - Q_1)$. Los valores atípicos están identificados como aquellos puntos fuera de los límites inferior y superior, y están representados por asteriscos. En la figura 2-3, el primer cuartil es 8, la mediana es 13, el tercer cuartil es 17, y el rango intercuartil es




FIGURA 2-3 Diagrama de caja para el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

9 ($17 - 8$). El límite inferior es -5.5 ($8 - 1.5 \times 9$) y el límite superior es 30.5 ($17 + 1.5 \times 9$). Note que el valor más bajo dentro del límite inferior, -5.5 , es 0; en tanto el valor más alto dentro del límite superior, 30.5 , es 28. Seis valores (35, 36, 36, 39, 44 y 49) exceden el límite superior de 30.5 y son los valores atípicos.

El *histograma* condensa los datos, agrupando valores similares en clases. Se puede construir un histograma colocando la variable de interés en el eje horizontal, y la frecuencia, frecuencia relativa o frecuencia porcentual, en el eje vertical. Al observar un histograma como el de la figura 2-4, usted puede indicar la proporción del área total, arriba de un intervalo del eje




FIGURA 2-4 Histograma del ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500




FIGURA 2-5 Ventas mensuales de las tiendas de alimentos Alomega (de la tabla 3-11)

horizontal. Un total de 23 de las 209 compañías, o el 11.0%, tienen ingreso neto como porcentaje del capital invertido en el rango entre 6.25% y 8.75%. Por lo tanto, el cuarto rectángulo de la figura 2-4 contiene .110 del área total representada por las barras verticales sombreadas.

Aunque los histogramas ofrecen buenas descripciones visuales de conjuntos de datos, especialmente de conjuntos de datos muy grandes, no nos permiten identificar observaciones individuales. En contraste, en un diagrama de puntos, está visible cada uno de los valores originales.

Se utilizan *diagramas de dispersión* para visualizar la relación entre dos variables. Tales diagramas se analizarán más adelante, en el capítulo de la sección sobre análisis de correlación.

Para datos cronológicos, la forma gráfica más frecuentemente empleada es un *diagrama de series de tiempo*, en el cual los datos se grafican a través del tiempo. La figura 2-5 ilustra el diagrama de una serie de tiempo con las ventas anuales en las tiendas de alimentos Alomega, que analizamos en el ejemplo 1.1. Un diagrama de series de tiempo revela la variabilidad de los datos y el momento en que ocurren picos y valles. También muestra el tamaño relativo de los picos y los valles, en comparación con el resto de la serie.

Un paso importante en la selección de una técnica de pronósticos adecuada consiste en identificar los patrones de datos que existen dentro de una serie de tiempo. Una vez que se identifican los patrones de datos, se pueden utilizar los métodos de pronóstico más adecuados para tales patrones. Se identifican cuatro tipos de patrones de datos para series de tiempo: horizontal, de tendencia, cíclico y estacional. Cada tipo se estudiará con profundidad en el capítulo 3.

Una herramienta utilizada con frecuencia para identificar patrones de datos en las series de tiempo es el *correlograma* o la *función de autocorrelación*, que es una herramienta gráfica para presentar las correlaciones entre diversos retrasos de una serie de tiempo. Los correlogramas también se examinarán en el capítulo 3.

DISTRIBUCIONES DE PROBABILIDAD

Variable aleatoria es el nombre que se le da a una cantidad que puede tomar valores diferentes de una prueba a otra en un experimento, donde el resultado exacto es un suceso fortuito. Si sólo son posibles ciertos valores específicos, la variable aleatoria se llama *variable discreta*. Ejemplos son el número de habitaciones en una casa, el número de gente que llega a pagar a las cajas de un supermercado en cierta hora, y el número de unidades defectuosas en un lote de partes elec-

trónicas. Si es posible cualquier valor de la variable aleatoria dentro de cierto rango, se llama *variable continua*. Ejemplos de este tipo de variable son el peso de un individuo, la longitud de una parte manufacturada, y el tiempo entre llegadas de automóviles a una caseta de peaje.

Una *variable aleatoria discreta* puede tener valores tan sólo de un conjunto predeterminado. A menudo tales resultados se presentan como números enteros. Una *variable aleatoria continua* puede tomar cualquier valor dentro de un rango específico. Tales resultados se representan numéricamente con intervalos de valores.

La *distribución de probabilidad* de una variable aleatoria discreta enlista todos los valores posibles que puede tomar la variable, junto con la probabilidad de que ocurra cada uno. El *valor esperado* de una variable aleatoria es el valor medio (promedio) que adquiere la variable en muchos intentos realizados. El valor esperado, $E(X)$, para una distribución de probabilidad discreta se obtiene al multiplicar cada valor posible de X por su probabilidad, $P(X)$, y después se suman los productos. La ecuación 2.4 presenta este cálculo:

$$E(X) = \sum [X \times P(X)] \quad (2.4)$$

El *valor esperado* de una variable aleatoria es el valor medio de la variable a lo largo de varios ensayos u observaciones.

Ejemplo 2.2 Una distribución de probabilidad discreta

El número de días sin ventas de un vendedor, durante un mes, se describe mediante la distribución de probabilidad mostrada en la tabla 2-4. Estos valores se basan en experiencias del vendedor y se usarán para pronosticar la actividad futura de ventas. La columna X lista todos los valores (días sin ventas) que son posibles, mientras que la columna $P(X)$ lista las probabilidades correspondientes. Observe que puesto que se listan todos los valores posibles de X , las probabilidades suman 1.00, o 100%. Esto es válido para todas las distribuciones de probabilidad, ignorando los errores por redondeo.

Para la distribución de probabilidad dada en la tabla 2-4, el valor esperado es

$$E(X) = 1(.1) + 2(.2) + 3(.25) + 4(.15) + 5(.30) = 3.35$$

De modo que si se observara a este vendedor durante un número de meses muy grande y se registrara el número de días sin venta, la media sería 3.35 días sin venta, si la actividad futura está pronosticada correctamente por los datos históricos, en los cuales se basa la distribución de probabilidad.

TABLA 2-4 Distribución de probabilidad discreta para el ejemplo 2.2

X	$P(X)$
1	.10
2	.20
3	.25
4	.15
5	.30

Advierta que la media cae cerca de la parte central de los valores X . Es atraída hacia el extremo superior de la distribución de probabilidad debido a la probabilidad relativamente alta asociada con $X = 5$.

Para una distribución continua, la probabilidad de obtener un valor específico se aproxima a cero. Por ejemplo, la probabilidad de que alguien pese 150 libras podría considerarse igual a cero, ya que esto significaría que tal peso sea exactamente 150.0000 —sin importar la precisión de la escala que se use. En el caso de la distribución continua, las probabilidades se asignan a intervalos o rangos de valores. Por ejemplo, podría calcularse la probabilidad de que el peso de un individuo caiga en el intervalo de 149 a 151 libras.

Algunas distribuciones teóricas ocurren una y otra vez en aplicaciones estadísticas prácticas, y por este motivo es importante examinar sus propiedades. Una de éstas es la *distribución binomial*, que a menudo se utiliza para representar una variable aleatoria discreta. Los requisitos para un experimento binomial son los siguientes:

1. Hay n ensayos idénticos, cada uno de los cuales da como resultado uno de dos resultados posibles —digamos, éxito y fracaso.
2. La probabilidad de éxito para cada resultado se mantiene igual de un ensayo a otro.
3. Los ensayos son independientes (no están relacionados).

Nos interesa encontrar la probabilidad X de éxitos que ocurren en n ensayos, donde arbitrariamente el éxito se define como uno de los dos resultados posibles. Los diversos valores de X , junto con sus probabilidades, forman la distribución binomial. Estas probabilidades se calculan con la siguiente fórmula binomial:

$$P(X) = \binom{n}{X} p^X (1 - p)^{n-X} \quad \text{para } X = 0, 1, \dots, n \quad (2.5)$$

donde

$\binom{n}{X}$ = el número de combinaciones de n elementos tomados X a la vez

p = la probabilidad de éxito en cada ensayo

X = el número específico de éxitos que nos interesa

n = el número de ensayos

La *distribución binomial* es una distribución de probabilidad discreta, que describe la probabilidad de X éxitos en n ensayos independientes de un experimento binomial.

Una forma más sencilla de encontrar probabilidades binomiales que usar la ecuación 2.5 es remitirse a una tabla de distribución binomial como la tabla B-1, que se encuentra en el Apéndice B. Los bloques que representan n agrupan las probabilidades. Cada bloque tiene una columna titulada con p y filas indicadas con X .¹

¹Minitab y Excel también calculan probabilidades binomiales.




FIGURA 2-6 Una distribución normal

Ejemplo 2.3 Una probabilidad binomial

Suponga que ocho artículos se extraen aleatoriamente de una línea de producción que, se sabe, produce partes defectuosas el 5% de las veces. ¿Cuál es la probabilidad de obtener exactamente cero defectuosos? La respuesta de la tabla B-1 es 0.6634. (Aquí, $n = 8$, $p = .05$ y $X = 0$).

La distribución continua importante, ya que muchas poblaciones de números se pueden aproximar mediante ella, es la *distribución normal*. Para identificar una población normal específica, es necesario conocer la media y la desviación estándar. Una curva normal es simétrica y tiene forma de campana, como se ilustra en la figura 2-6. Esta distribución representa muchas variables de la vida real que se miden en una escala continua.

Las probabilidades de valores extraídos de una distribución normal, que caen en varios intervalos, se obtienen convirtiendo primero todos los intervalos en unidades de desviación estándar, llamadas Z como número de varianzas.² El resultado Z , como el número de varianzas de cualquier valor de X , es el número de desviaciones estándar desde el valor central de la curva (μ) hasta ese valor. Entonces, la fórmula es

$$Z = \frac{X - \mu}{\sigma} \quad (2.6)$$

donde

X = el valor de interés

μ = la media

σ = desviación estándar

Después de que se haya calculado Z como número de varianzas, se puede consultar la tabla de la curva normal, para encontrar el área bajo la curva entre el centro de la curva original (μ) y el valor de interés (X).³

La *distribución normal* tiene forma de campana y está completamente determinada por su media y su desviación estándar.

²Se puede demostrar que, si la variable aleatoria X tiene una distribución normal con media μ y desviación estándar σ , entonces la variable aleatoria $Z = (X - \mu)/\sigma$ tiene una distribución normal, con media 0 y desviación estándar 1. Esta distribución normal específica se conoce como la *distribución normal estándar*.

³Se pueden calcular las probabilidades normales usando Minitab o Excel.




FIGURA 2-7 Áreas de la curva normal para el ejemplo 2.4

Ejemplo 2.4 Cálculo de una probabilidad normal

Los pesos de una población de partes fabricadas con cierta máquina, están distribuidos normalmente con una media de 10 libras y una desviación estándar de 2 libras. ¿Cuál es la probabilidad de que una pieza seleccionada al azar de la máquina pese entre 9 y 12 libras? La curva normal con el área sombreada adecuada se ilustra en la figura 2-7.

Puesto que a menudo las tablas de la curva normal se diseñan para dar áreas desde el centro de la curva hasta algún punto, deben obtenerse dos áreas separadas: una a cada lado de la media. Luego se suman estas áreas. Dicho proceso indicará la probabilidad de que un valor caiga en este intervalo. Los dos valores de Z son

$$Z_1 = \frac{X_1 - \mu}{\sigma} = \frac{9 - 10}{2} = -.50$$

$$Z_2 = \frac{X_2 - \mu}{\sigma} = \frac{12 - 10}{2} = 1.00$$


Por lo tanto, el área bajo la curva normal entre 9 y 12 de la figura 2-7 es la misma que el área bajo la curva normal de Z (véase la nota al pie de página 2) entre $-.5$ y 1 . Para la tabla normal de este libro, se ignora el signo negativo en el primer valor de Z , ya que el área de la curva normal para Z entre $-.5$ y 0 es la misma que el área bajo la curva entre 0 y $.5$. Estos dos valores de Z se localizan en la tabla B-2, una tabla de curva normal, darán como resultado las siguientes dos áreas, las cuales se suman después:

$Z_1 = -.50$	:	.1915
$Z_2 = 1.00$	:	.3413
		.5328

Se concluye que hay aproximadamente un 53% de probabilidad de que una parte de esta población, extraída al azar, pesará entre 9 y 12 libras.

DISTRIBUCIONES MUESTRALES

En la mayoría de aplicaciones estadísticas, se extrae una muestra al azar de la población en estudio, se calcula un estadístico a partir de los datos de la muestra y se infieren conclusiones acerca de la población sobre la base de dicha muestra. Una *distribución muestral* es la distribución de todos los valores posibles del estadístico muestral que se pueden obtener de la

FIGURA 2-8 Distribución muestral de $\bar{X}$

población, para un tamaño de muestra dado. Por ejemplo, de una población se toma una muestra aleatoria de 100 personas, se pesan y luego se calcula su media (promedio) de peso. Esta media de la muestra ($\bar{X}$) puede considerarse como si fuera extraída de la distribución de todas las medias muestrales posibles, con un tamaño de 100, que podrían tomarse de la población. Más generalmente, cada estadístico muestral que se calcule a partir de los datos de la muestra puede considerarse como si se hubiera tomado de una distribución muestral.

Una *distribución muestral* es el arreglo de todos los valores posibles de un estadístico muestral, que puede extraerse de una población, para un tamaño de muestra dado.

El *teorema central del límite* indica que, conforme aumenta el tamaño de la muestra, la distribución muestral de las medias de la muestra tiende hacia la distribución normal, y que la media de esta distribución normal es μ , la media de la población; y la desviación estándar es $\sigma/\sqrt{n}$, la desviación estándar de la población, dividida entre la raíz cuadrada del tamaño de la muestra. La cantidad $\sigma/\sqrt{n}$ se conoce como el *error estándar* de la media de la muestra. Así, la distribución muestral de la media de la muestra tenderá hacia la normalidad, sin importar la forma de la distribución de la población de la cual se extrajeron las muestras. La figura 2-8 demuestra cómo se observaría tal distribución muestral.

El teorema central del límite es de importancia fundamental en estadística, ya que permite a los analistas calcular la probabilidad de varios resultados de muestras, usando el conocimiento de las probabilidades de la curva normal.

Ejemplo 2.5 Cálculo de una probabilidad usando la distribución muestral de $\bar{X}$

¿Cuál es la probabilidad de que la media de una muestra aleatoria de 100 pesos —extraída de una población— estará dentro de 2 libras del peso medio de la población verdadera, si se estima que la desviación estándar de la población es de 15 libras? La figura 2-9 ilustra la distribución muestral adecuada.

El error estándar es $\sigma/\sqrt{n} = 15/\sqrt{100} = 1.5$, que da como resultado un valor Z de $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n}) = 2/1.5 = 1.33$ y una área de la tabla de la curva normal de .4082. Al duplicar esta área para contabilizar ambos lados de la media, da como resultado una área total de .8164. Las probabilidades son del 82% de que la media de la muestra estará dentro de 2 libras de la media verdadera, dado el tamaño de la muestra de 100 y la variabilidad estimada de la población, $\sigma = 15$. Como se verá, esta destreza al calcular las probabilidades de los resultados de una muestra facilitará a un analista hacer inferencias acerca de la población de la muestra, con aplicabilidad directa a la realización de pronósticos.




FIGURA 2-9 Áreas de distribución muestral para el ejemplo 2.5

Para tamaños de muestra pequeños, quizá las medias muestrales no estén normalmente distribuidas. Sin embargo, si la población de la cual se selecciona la muestra es esencialmente normal y la desviación estándar de la población se estima con la desviación estándar de la muestra S , se conoce la distribución muestral de la relación

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (2.7)$$

También llamada *distribución t de Student* (o simplemente *distribución t*) con $n - 1$ grados de libertad (que se abrevian gl). La distribución t está centrada en 0 y tiene una forma de campana, pero con colas más gruesas que en una distribución normal. Sin embargo, conforme se incrementa el número de grados de libertad (y de forma equivalente, el tamaño de la muestra n), la distribución t parece cada vez más una distribución normal con una media de 0 y una desviación estándar de 1.

La tabla B-3 (en el Apéndice B) presenta valores tomados de la distribución t . Observe que sólo se requiere especificar un valor antes de remitirse a la tabla; a saber, los grados de libertad. Una vez que se conocen los grados de libertad, se pueden obtener los valores t que excluyen porcentajes deseados del área bajo la curva. Por ejemplo, si la distribución t de interés tiene 12 grados de libertad, entonces un valor t de 2.179 en cada lado del 0 incluirá el 95% del área bajo la curva y excluirá el 5% de ella, es decir, 2.5% en cada cola.

Ejemplo 2.6 Uso de la distribución t

El gerente de una compañía de tarjetas de crédito afirma que el tiempo medio para resolver una queja de los clientes es de 30 días. Para probar tal aseveración, se recopilieron datos de una muestra de 15 quejas, las cuales tuvieron un tiempo medio para resolverse de 35.9 días y una desviación estándar de 10.2 días.

Si los datos se consideran como una muestra aleatoria de una población normal, ¿arrojan sospechas sobre la afirmación del gerente?

Si la afirmación del gerente es correcta, la media de la población es $\mu = 30$ y la variable aleatoria

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

tiene una distribución t de Student con $n - 1 = 15 - 1 = 14$ grados de libertad. La afirmación del gerente será sospechosa, si el valor de esta variable es demasiado grande o demasiado pequeño, porque esto ocurre cuando el valor de $\bar{X}$ está lejos de μ . Consultando la tabla B-3 para 14 grados de libertad, vemos que $t_{.025} = 2.145$. Antes de obtener la muestra, la probabilidad de que t excederá 2.145 es .025. Asimismo, la probabilidad de que t será menor que -2.145 es de .025. Sumando estas dos probabilidades iguales, la probabilidad es $.025 + .025 = .5$ de que t será más grande

que 2.145 o menor que -2.145 . Ahora estamos listos para determinar si el valor de $\bar{X}$, 35.9, está lejos de μ , 30. El valor observado de t es

$$t = \frac{35.9 - 30}{10.2/\sqrt{15}} = 2.240$$

el cual excede $t_{.025} = 2.145$. En vez de aceptar la explicación de que ocurrió un evento con escasa probabilidad, cuestionamos la afirmación de que la media sea de 30 días. Un valor más grande para la media sería más consistente con los datos.

INFERENCIA DE UNA MUESTRA

Estimación

Cuando no es viable o incluso es imposible medir la población total de interés, se selecciona una muestra de la población y se utiliza para aprender acerca de la población. Este aprendizaje (llamado *inferencia*) por lo común toma dos formas. La primera de estas se denomina *estimación*, donde los resultados de la muestra se usan para estimar una característica desconocida de la población. Si bien la estimación es el término estadístico común para dicha tarea, también podría llamarse pronóstico en muchas situaciones de negocios, porque la muestra consiste en observaciones históricas recopiladas y se requiere un valor (estimado o pronosticado) para una observación futura. La segunda forma de aprendizaje acerca de la población a partir de una muestra se llama *prueba de hipótesis* y se estudiará en la siguiente sección.

Una *estimación puntual* (un pronóstico) de una cantidad de la población, como la media poblacional, es un solo valor calculado a partir de los datos de la muestra, y estima el valor de la cantidad desconocida de una población. En estadística, una cantidad de la población se conoce como *parámetro* de ésta. Una estimación puntual es la “mejor suposición” de un parámetro de la población calculada a partir de la muestra. Con frecuencia, la mejor suposición de un parámetro de la población lo proporciona la cantidad correspondiente de la muestra. Por ejemplo, la mejor suposición del valor de la media de la población está dada por el valor de la media de la muestra. La tabla 2-2 contiene tres parámetros de la población y los estadísticos muestrales que dieron estimaciones puntuales de aquéllos.

Un *intervalo de estimación* es un intervalo dentro del cual es probable que esté el parámetro de la población de interés. Se obtiene construyendo un intervalo alrededor de la estimación puntual:

$$\text{Estimación puntual} = \pm \text{múltiplo} \times (\text{desviación estándar estimada de la estimación puntual}) \quad (2.8)$$

donde el “múltiplo” es a menudo un punto porcentual de la distribución normal o un punto porcentual de la distribución t . Se prefiere un intervalo de estimación por encima de la estimación puntual, ya que aquélla toma en cuenta la incertidumbre asociada con una estimación.

Idealmente, nos gustaría obtener una muestra y luego determinar un intervalo que, por ejemplo, contuviera en definitiva la media de la población, μ . Sin embargo, debido a la variabilidad de una muestra a otra, tal objetivo es inalcanzable. En vez de eso, especificamos una alta probabilidad —digamos, .95 o .99— de que un intervalo propuesto cubrirá el valor verdadero del parámetro de la población de interés. Como esta probabilidad pertenece al intervalo antes de que se observe la muestra, se denomina el *nivel de confianza*. Un intervalo obtenido mediante un procedimiento que satisfaga el requisito de probabilidad se llama *intervalo de confianza*. La cantidad a la derecha del signo $\pm$ en la ecuación 2.8 se conoce a menudo como el *error permitido*, y su magnitud dependerá directamente del nivel de confianza (a través de un múltiplo) y la información en la muestra (a través de la desviación estándar estimada de la estimación puntual).

Una *estimación puntual* es un solo valor estimado de un parámetro de la población. Un *intervalo de estimación* es un intervalo dentro del cual es probable que esté el parámetro de la población.

Ejemplo 2.7 Cálculo de estimaciones puntual y de intervalos de estimación

Se elige una muestra aleatoria de 500 compradores en el Centro Comercial Northgate, para determinar la distancia promedio que recorrieron para llegar al centro comercial. Un análisis de los resultados de la muestra revela que $\bar{X} = 23.5$ millas y $S = 10.4$ millas.

La estimación puntual para la distancia media desconocida de la población, para todos los compradores del centro comercial, es de 23.5 millas, la media de la muestra.

La desviación estándar estimada de $\bar{X}$ es $S/\sqrt{n}$ y para muestras aleatorias grandes (digamos, $n > 30$), el múltiplo en la construcción de un intervalo de confianza (véase la ecuación 2.8) para la media de la población, μ , es Z , un punto porcentual normal estándar. Por lo tanto, un intervalo de estimación para μ es

$$\bar{X} \pm Z \frac{S}{\sqrt{n}} \quad (2.9)$$

Si establecemos el nivel de confianza en 95%, entonces $Z = 1.96$, el punto más alto .025 (2.5%) de una distribución normal estándar (véase nota al pie 2). Usando la ecuación 2.9 con nuestros resultados de la muestra, se produce el intervalo

$$\begin{aligned} 23.5 \pm 1.96 \frac{10.4}{\sqrt{500}} \\ 23.5 \pm 1.96(.465) \\ 23.5 \pm .91 : (22.6, 24.4) \end{aligned}$$

Así, se dice, con 95% de confianza, que el número medio de millas recorridas para llegar al centro comercial, por la población de compradores, está en algún punto entre 22.6 millas y 24.4 millas. El 95% de confianza se refiere al hecho de que si, digamos, se seleccionaran 100 muestras de tamaño de 500, se calculara la media y la desviación estándar de cada muestra y se construyeran intervalos de estimación, 95 de 100 de los intervalos contendrían, en efecto, la media real de la población. Por lo tanto, es altamente probable que el intervalo específico construido arriba contenga la media de la población en millas viajadas al centro comercial.

Si el tamaño de la muestra hubiera sido pequeño, quizá $n = 20$, entonces, un intervalo de confianza de 95% para μ podría construirse con la ecuación 2.9, usando un punto porcentual t con 19 gl en vez de Z . Puesto que el punto más alto .025 (2.5%) de una distribución t con 19 gl es $t_{.025} = 2.093$ y $S/\sqrt{n} = 10.4/\sqrt{20} = 2.326$, el intervalo de confianza de 95% de la muestra pequeña será considerablemente más amplio, que el intervalo con la muestra grande calculado arriba. Esto es razonable porque hay más incertidumbre asociada con una muestra pequeña. Note que para muestras pequeñas, también hacemos la suposición adicional de que las millas viajadas están distribuidas aproximadamente normal.

Prueba de hipótesis

En muchas situaciones de inferencia, incluyendo la elaboración de pronósticos, el interés está en probar alguna clase de afirmación acerca de la población, en vez de la estimación o el pronóstico de uno de sus parámetros. Este procedimiento se llama *prueba de hipótesis* y es la segunda forma principal de examinar evidencia de la muestra. La prueba de hipótesis implica los siguientes pasos:

- Paso 1.** Formule la hipótesis que se va a probar (llamada hipótesis nula, representada con H_0) y la definición de la hipótesis alternativa (la que se acepta si H_0 se rechaza, representada con H_1).
- Paso 2.** Obtenga una muestra aleatoria de elementos de la población, mídalos y calcule el estadístico de prueba adecuado de la muestra.

TABLA 2-5 Resultados de una prueba de hipótesis

		Acción	
		No rechace H_0	Rechace H_0
Condición natural	H_0 verdadera	Decisión correcta	Error tipo I: probabilidad α
	H_0 Falsa	Error tipo II: probabilidad β	Decisión correcta

Paso 3. Suponga que la hipótesis nula es verdadera, y determine la distribución de muestral, del estadístico de prueba.

Paso 4. Calcule la probabilidad de que un valor del estadístico de prueba, por lo menos tan grande como el observado, se hubiera extraído de esta distribución muestral.

Paso 5. Si esta probabilidad es alta, no rechace la hipótesis nula; si esta probabilidad es baja, se desacredita la hipótesis nula y puede rechazarse con poco margen de error.

Cuando se siguen estos pasos, es posible que haya dos tipos de error, como se indica en la tabla 2-5. Se espera que se tome la decisión correcta con respecto a la hipótesis nula, después de examinar la evidencia de la muestra; no obstante, siempre hay una posibilidad de rechazar una H_0 verdadera y fallar en rechazar una H_0 falsa. Las probabilidades de dichos eventos se conocen como alfa (β) y beta (σ), respectivamente. Alfa también se conoce como *nivel de significancia* de la prueba.

Ejemplo 2.8 Construcción de una prueba de hipótesis

El supervisor de un taller cree que disminuyó el peso medio de las piezas producidas por cierta máquina. Se desea probar la hipótesis de que el peso medio de las piezas producidas por la máquina es todavía de 50 libras, es decir, el peso medio de las piezas en años pasados. Se toma una muestra aleatoria de 100 piezas. Se supone que la desviación estándar de los pesos de las piezas es de 5 libras, sin importar el peso medio, ya que este valor ha permanecido constante en estudios anteriores de las piezas. Usaremos la media de la muestra, como nuestro estadístico de prueba y tomaremos como hipótesis nula el *statu quo*; es decir, el peso medio de la pieza, μ , es de 50 libras. Por lo tanto, si la hipótesis nula H_0 es verdadera, el teorema central del límite indica que la distribución muestral de $\bar{X}$ es, en este caso, normal con media $\mu = 50$ y desviación estándar $\sigma/\sqrt{n} = 5/\sqrt{100} = .5$. Un valor de la media de la muestra, $\bar{X}$, cercano o mayor que 50 apoya la H_0 ; un valor de $\bar{X}$ muy por debajo de 50 es evidencia contra la H_0 , puesto que tal evento es improbable si H_0 es verdadera. Entonces, una regla de decisión sensible es aquella que rechaza H_0 para un valor de $\bar{X}$ muy por debajo de 50. Sin embargo, con esta regla, es probable que cometamos un error tipo I, es decir, que rechacemos una H_0 verdadera. Podemos controlar la probabilidad de rechazar una H_0 verdadera cuando seleccionamos α , el nivel de significancia. Suponga que hacemos a α pequeña —digamos .05 (5%). Entonces, rechazaremos H_0 si el valor observado de nuestro estadístico de prueba, $\bar{X}$, cae más allá del punto más bajo 0.05 (5%) de su distribución muestral de la H_0 . La prueba se muestra en la figura 2-10.

La regla de decisión para esta prueba es como sigue:

$$\text{Si } \bar{X} < 49.18, \text{ rechace la hipótesis nula } H_0: \mu = 50$$

Suponga que la media de la muestra resulta ser de 49.6 libras. Entonces, podríamos no rechazar H_0 al nivel de 5%. Por otro lado, si el peso medio de la muestra resultara ser de 48.6 libras, rechazaríamos H_0 . Note que para $\bar{X} = 48.6$, la probabilidad de obtener un valor en este extremo (muy por debajo de 50), si H_0 es verdadera, es $P(\bar{X} < 48.6) = P(Z < \frac{48.6 - 50}{.5}) = P(Z < -2.8) = P(Z > 2.8) = (.5000 - .4974) = .0026$ lo cual es, desde luego, un evento improbable.

En la prueba de hipótesis, siempre existe alguna ambigüedad asociada con la selección de las hipótesis nula y alternativa. En general, la hipótesis nula es el *estatus quo* (condición actual) o hipótesis “sin cambio”. La hipótesis alternativa es la hipótesis de investigación o de cambio.




FIGURA 2-10 Prueba de hipótesis para el ejemplo 2.8

Para descubrir si lo que hemos hecho marcó una diferencia o resultó en un cambio del *status quo* o de los procedimientos actuales, formulamos la diferencia o el cambio como la hipótesis alternativa. El objetivo es ver si podemos rechazar la hipótesis nula, con una probabilidad pequeña de un error tipo I, a favor de la alternativa.

La prueba de hipótesis que se describe en el ejemplo 2-8 se conoce como prueba *unilateral*. Se sigue esta terminología porque, en este ejemplo, la hipótesis alternativa especifica valores de los parámetros de la población, a un lado del valor especificado en la hipótesis nula. Las pruebas para las cuales la hipótesis alternativa especifica valores tanto más grandes como más pequeños, que el valor con la hipótesis nula, se llaman pruebas *bilaterales*. En este caso, valores del estadístico de prueba mucho más grandes o mucho más pequeños que el valor del parámetro de la población, con H_0 , conducen al rechazo.

Valor p

En el ejemplo 2-8, calculamos la probabilidad de obtener un valor de la media de la muestra tan extremo como $\bar{X} = 48.6$ si la hipótesis nula $H_0: \mu = 50$ es verdadera. La probabilidad encontrada fue de .0026. Esta probabilidad se llama *valor de prueba* o simplemente *valor p* de la prueba. En vez de seleccionar un nivel de significancia, ahora es práctica común calcular e informar el valor p para la prueba; de hecho, los paquetes de software estadístico en general reportan los valores p asociados con estadísticos de prueba. En efecto, los valores p y su uso en pruebas de hipótesis se analizan en los pasos 4 y 5 de nuestro procedimiento de prueba de hipótesis, al inicio de esta sección. Un valor p pequeño significa un fuerte rechazo de la hipótesis nula. El valor p puede considerarse como evidencia a favor (un valor p grande) o en contra (un valor p pequeño) de la hipótesis nula. Los puntos límite comunes para valores p pequeños son .05 y .01.

Usando la información del ejemplo 2.8, si se realiza una prueba bilateral, $H_0: \mu = 50$ contra $H_1: \mu \neq 50$, y $\bar{X} = 48.6$, el valor p sería $P(\bar{X} < 48.6 \text{ o } \bar{X} > 51.4) = 2P(Z > \frac{51.4 - 50}{.5})$, o dos veces el área bajo la curva normal estándar a la derecha de $Z = 2.8$. En este ejemplo, el valor p es igual a $2(0.0026) = 0.0052$.

El valor p o *probabilidad de significancia* es la probabilidad de obtener, al menos, un resultado de la muestra tan extremo como el realmente observado, si H_0 fuera verdadera. De forma equivalente, el valor p puede considerarse como la α más pequeña, para la cual el estadístico de prueba observado conduce al rechazo de H_0 .

Ejemplo 2.9 Cálculo de un valor p

Suponga que se desea probar la hipótesis de que la puntuación media de estudiantes en un examen nacional es de 500, contra la hipótesis alternativa de que es menor de 500. Se toma una muestra aleatoria de 15 estudiantes de la población que produce una puntuación media de la muestra de $\bar{X} = 475$. La desviación estándar de la población se estima con la desviación estándar de la muestra,

$S = 35$. Suponga que la población de las puntuaciones de los exámenes se distribuye normalmente.

Queremos saber si los puntajes promedio de la prueba son menores que su valor histórico de 500. Tomaremos una decisión con base en la evidencia de la muestra y, en particular, del valor de la media de la muestra. Las hipótesis en competencia son

$$H_0: \mu = 500$$

$$H_1: \mu < 500$$

Si H_0 fuera verdadera, esperaríamos ver un valor del promedio de la muestra cercano a 500 o mayor. Si H_0 fuera falsa (H_1 es verdadera), esperaríamos ver un valor del promedio de la muestra bastante menor de 500. Puesto que el tamaño de la muestra es pequeño, la población es normal y la desviación estándar de la población se estima con la desviación estándar de la muestra, un estadístico de prueba adecuado es el estadístico t dado en la ecuación 2.7, con $n - 1 = 15 - 1 = 14$ gl. Un valor negativo grande del estadístico t es evidencia contra H_0 (que indica que el promedio de la muestra es mucho menor que el promedio hipotético de la población de 500). Primero, realicemos la prueba para un nivel de significancia de $\alpha = .05$. La prueba (regla de decisión) se ilustra en la figura 2-11.




FIGURA 2-11 Prueba de hipótesis para el ejemplo 2.9

Puesto que la regla de decisión es como sigue:

Si observó que $t < -1.76$, rechace $H_0: \mu = 500$

y el estadístico t observado es:

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{475 - 500}{35/\sqrt{15}} = -2.77$$

rechazaríamos la hipótesis nula y concluiríamos que la puntuación media de la prueba de estudiantes en el examen nacional es menor de 500. El *valor p* en este caso es $P(t < -2.77)$. Usando la tabla B-3 con 14 gl y la simetría de la distribución t , esto probablemente esté entre .010 y .005. Nuestro estadístico de prueba observado es muy improbable si H_0 es verdadera. El *valor p* nos indica que deberíamos rechazar la hipótesis nula.

ANÁLISIS DE CORRELACIÓN

En la construcción de modelos estadísticos para realizar pronósticos, a menudo es útil examinar la relación entre dos variables. Dos técnicas, el análisis de correlación y el análisis de regresión, se estudian aquí. Además, en capítulos posteriores se consideran casos especiales de correlación y de regresión. Este énfasis en la correlación y en la regresión se justifica en vista del uso generalizado de dichas técnicas, en todas las clases de aplicaciones para la elaboración de pronósticos.

Diagramas de dispersión

Un estudio de la relación entre variables inicia con el caso más sencillo: el de la relación existente entre dos variables. Suponga que se toman dos mediciones en cada uno de varios objetos. Un analista quiere determinar si una de estas variables medibles, llamada Y , tiende a aumentar o a disminuir cuando la otra variable, llamada X , cambia. Por ejemplo, suponga que se miden tanto la edad como el ingreso de varios individuos, como se indica en la tabla 2-6. ¿Qué se puede decir acerca de la relación entre X y Y ?

En la tabla 2-6, se observa que Y y X tienen una relación evidente. Conforme X aumenta, Y tiende a incrementarse. De esta muestra de cinco individuos, parece que cuanto más vieja se vuelve una persona, más dinero ganará esa persona. Por supuesto, es peligroso llegar a conclusiones sobre la base de una muestra pequeña, un tema que se estudiará más tarde. Incluso con estas observaciones, parece existir una relación evidente entre Y y X .

Estos cinco puntos de datos pueden graficarse sobre una escala bidimensional, con valores de X a lo largo del eje horizontal y valores de Y a lo largo del eje vertical. Una gráfica como ésta se llama *diagrama de dispersión* y se ilustra en la figura 2-12.

TABLA 2-6 Mediciones de ingreso y edad

<i>Persona</i>	<i>Ingreso (en miles) Y</i>	<i>Edad (años) X</i>
1	27.8	22
2	28.5	23
3	30.0	26
4	35.0	27
5	36.4	35




FIGURA 2-12 Diagrama de dispersión para edad e ingreso

Un *diagrama de dispersión* es una gráfica de puntos de datos X - Y en un sistema de coordenadas bidimensional.

El diagrama de dispersión ayuda a ilustrar lo que la intuición sugiere cuando se observan a primera vista los datos; a saber: la evidencia de una relación lineal entre Y y X . Esta relación se llama una relación lineal *positiva*, porque conforme X se incrementa, lo hace también Y .

En otras situaciones donde intervienen dos variables, quizá surjan diferentes patrones en el diagrama de dispersión. Considere los diagramas de la figura 2-13.

La figura 2-13(a) sugiere lo que se llama una *relación lineal positiva perfecta*. Conforme X se incrementa, Y aumenta también, y de una forma perfectamente predecible. Es decir, los puntos de datos X y Y parecen formar una línea recta. La figura 2-13(b) sugiere una *relación lineal negativa perfecta*. Conforme X se incrementa, Y disminuye de un modo perfectamente predecible.

Las figuras 2-13(c) y (d) ilustran una *relación lineal imperfecta, positiva y negativa*, respectivamente. Conforme X se incrementa en estos diagramas de dispersión, Y se incrementa (parte c) o disminuye (parte d), aunque no lo hace de un modo perfectamente predecible. Así, Y podría estar ligeramente más arriba o más abajo de “lo esperado”. Es decir, los puntos X - Y no forman una línea recta.

Los diagramas de dispersión en las figuras 2-13(a) a d) ilustran *relaciones lineales*. La relación X - Y , sea perfecta o imperfecta, puede resumirse con una línea recta. En cambio, en la figura 2-13(e) aparece una *relación curva*.

Finalmente, la figura 2-13(f) sugiere que no hay relación de ninguna clase entre las variables X y Y . Conforme X se incrementa, Y no parece aumentar ni disminuir de algún modo predecible. Sobre la base de la evidencia de la muestra que se indica en la figura 2-13(f), podría concluirse que en el mundo que contiene todos los puntos de datos X - Y , no existe relación alguna, ni lineales ni de otra clase, entre las variables X y Y .




FIGURA 2-13 Patrones para puntos de datos X-Y




FIGURA 2-14 Asociación lineal fuerte y débil para puntos de datos X-Y

Considere ahora los dos diagramas de dispersión en la figura 2-14. Ambos diagramas de dispersión sugieren relaciones lineales positivas imperfectas entre Y y X . La figura 2-14(a) ilustra una relación fuerte porque los puntos de datos están bastante cerca de la línea recta que pasa a través de ellos. En la figura 2-14(b), los puntos de datos están más lejos de la recta que pasa a través de ellos, sugiriendo así una relación lineal más débil. Más adelante en este capítulo, mostraremos cómo medir la fortaleza de la relación que existe entre dos variables.

Como sugieren los dos diagramas de dispersión de la figura 2-14, a menudo es deseable resumir la relación entre dos variables ajustando una recta a través de los puntos de datos. Usted aprenderá cómo se hace esto en breve; por el momento, piense que una línea recta puede ajustarse a los puntos de un diagrama de dispersión, de modo que resulte un “buen ajuste”. Una pregunta de interés para la elaboración del pronóstico es ¿qué tan rápido se sube o baja la línea recta?

La respuesta a esta cuestión requiere del cálculo de la pendiente de la línea. La pendiente de cualquier recta se define como el cambio de Y asociado con una unidad de incremento en X .

Para resumir, cuando se estudia una relación entre dos variables, uno debe saber primero si la relación es lineal (ilustrada con una línea recta) o no lineal. Si es lineal, uno necesita saber si la relación es positiva o negativa, y qué tan abruptamente sube o desciende la recta que ajusta los puntos de datos. Por último, uno necesita conocer la fortaleza de la relación, es decir, qué tan cerca están los puntos de datos de la línea que mejor se ajusta a ellos.

Coefficiente de correlación

La fortaleza de la relación lineal que existe entre dos variables se mide usando la *correlación* que existe entre ellas. El *coeficiente de correlación* mide la fortaleza de la siguiente manera. Dos variables con una relación negativa perfecta tienen un coeficiente de correlación igual a -1 . En el otro extremo, dos variables con una relación positiva perfecta tienen un coeficiente de correlación igual a 1 . De esta manera, el coeficiente de correlación varía de -1 a 1 inclusive, dependiendo de la cantidad de asociación entre las dos variables que se estén midiendo.

El *coeficiente de correlación* mide el grado en que dos variables están linealmente relacionadas entre sí.

El diagrama de dispersión en la figura 2-13(a) ilustra una situación que produce un coeficiente de correlación de 1 . El diagrama de dispersión en la figura 2-13(b) tiene un coeficiente de correlación de -1 . Las figuras 2-13(e) y (f) ilustran dos variables que no están linealmente relacionadas. Los coeficientes de correlación para estas relaciones son iguales a 0 ; es decir, se presenta una relación no lineal.

Los pronosticadores se interesan tanto en la población como en los datos muestreados. En la *población* que contiene todos los puntos de datos X - Y de interés, hay un coeficiente de correlación cuyo símbolo es ρ , la letra griega ρ . Si se extrae una muestra aleatoria de estos puntos de datos X - Y , el coeficiente de correlación para tales datos de muestra se denota con la letra r .

Frecuentemente, X - Y se miden en unidades diferentes, como libras y dólares, unidades vendidas y dólares en ventas, o tasa de desempleo y dólares del PIB. A pesar de tales unidades diferentes para X - Y , es todavía importante medir el grado en que X y Y están relacionadas. Estas mediciones se realizan convirtiendo primero las variables X y Y a unidades estándar o valores de Z .

Después de que las mediciones X - Y se han convertido en Z como número de varianza, se multiplican estos valores Z para cada medida X - Y , lo que da como resultado productos cruzados para cada caso. Estos productos cruzados son de interés porque la media de estos valores es el coeficiente de correlación. El cálculo del coeficiente de correlación (esencialmente) como el producto cruzado medio de Z producirá el valor correcto; pero en la mayoría de los casos, el coeficiente de correlación se calcula directamente a partir de los valores X - Y . La ecuación 2-10 muestra cómo se calcula el coeficiente de correlación de la muestra, r , a partir de Z como número de varianza y de las mediciones X - Y . Aquí $Z_x = (X - \bar{X})/S_x$ y $Z_y = (Y - \bar{Y})/S_y$.

$$\begin{aligned} r &= \frac{1}{n-1} \sum Z_x Z_y = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \sqrt{\sum (Y - \bar{Y})^2}} \\ &= \frac{n \sum XY - (\sum X)(\sum Y)}{\sqrt{n \sum X^2 - (\sum X)^2} \sqrt{n \sum Y^2 - (\sum Y)^2}} \end{aligned} \quad (2.10)$$

Una tabla como la 2-7 facilita el cálculo de r .

Ejemplo 2.10 Cálculo del coeficiente de correlación de una muestra

Si se estudia la relación entre la edad y el ingreso, sería de interés conocer el valor de r para estos datos. Los cálculos requeridos se presentan en la tabla 2-7. Los totales de la tabla 2-7 se sustituyen en la ecuación 2.10, con lo cual se obtiene:

$$\begin{aligned} r &= \frac{n \sum XY - \sum X \sum Y}{\sqrt{n \sum X^2 - (\sum X)^2} \sqrt{n \sum Y^2 - (\sum Y)^2}} \\ &= \frac{5(4,266.1) - (133)(157.7)}{\sqrt{5(3,643) - (133)^2} \sqrt{5(5,035.05) - (157.7)^2}} \\ &= \frac{21,330.5 - 20,974.1}{\sqrt{526} \sqrt{305.96}} = \frac{356.4}{(22.93)(17.49)} = .89 \end{aligned}$$

Se observa que el coeficiente de correlación de la muestra confirma lo que se ilustró en la figura 2-12. El valor de r es positivo, lo cual sugiere una relación lineal positiva entre la edad y el ingreso. También, en una escala de 0 a 1, el valor de r es bastante alto (0.89). Este resultado sugiere una relación lineal fuerte en vez de una débil. La pregunta restante es si la combinación del tamaño de la muestra y el coeficiente de correlación es lo suficientemente fuerte para hacer afirmaciones significativas acerca de la población, de la cual se extrajeron los valores de los datos.

Ahora deberían hacerse dos observaciones importantes acerca de la correlación. Primero, siempre debe tenerse en mente que se mide la *correlación*, no la *causalidad*. Puede ser perfectamente válido decir que dos variables están relacionadas sobre la base de un coeficiente de

TABLA 2-7 Cálculos para la correlación entre edad e ingreso del ejemplo 2.10

Persona	Y	X	Y ²	X ²	XY
1	27.8	22	772.84	484	611.6
2	28.5	23	812.25	529	655.5
3	30.0	26	900.00	676	780.0
4	35.0	27	1,225.00	729	945.0
5	36.4	35	1,324.96	1,225	1,274.0
Totales	157.7	133	5,035.05	3,643	4,266.1

correlación alto. Quizá sea válido o no decir que una variable es causante del cambio en la otra; esto es una cuestión para el juicio del analista. Por ejemplo, puede ser verdad que el volumen de ventas de una tienda local, en una área escasamente poblada, está altamente correlacionado con el precio de mercado promedio de las acciones en Nueva York. Después de examinar una muestra grande de estas dos variables, podría concluirse que existe esa correlación alta. Probablemente no sea verdad que una de tales variables esté causando el cambio en la otra. De hecho, los cambios de ambas variables quizá sean causados por un tercer factor, el estado general de la economía. Los políticos, los anunciantes y otros a menudo cometen el error de suponer una causa con base en la correlación.

Segundo, advierta que el coeficiente de correlación mide una relación *lineal* entre dos variables. En el caso en que el coeficiente de correlación es bajo, se concluiría que las dos variables no están estrechamente relacionadas de forma lineal. Tal vez estén estrechamente relacionadas de un modo no lineal o curvado. Así, un coeficiente de correlación bajo no significa que las dos variables no estén relacionadas, solo que parece que no existe una relación lineal o en línea recta.

AJUSTE DE UNA LÍNEA RECTA

Como se mencionó antes, con frecuencia es de interés ajustar una línea recta a través de un conjunto de puntos de datos X - Y , de manera tal que resulte un “buen ajuste”. Como se mostrará en los capítulos posteriores, esa línea bien ajustada puede usarse para pronosticar valores desconocidos de Y , la variable de interés.

En la práctica, se usa un procedimiento matemático bien definido para calcular tanto la intersección con el eje Y (ordenada al origen), como la pendiente de la línea recta mejor ajustada. El enfoque más común para determinar esa línea mejor ajustada se llama *método de los mínimos cuadrados*. Con este procedimiento, se construye una línea que minimiza la suma de los cuadrados de las distancias entre los puntos de datos y la recta, medidos en la dirección (Y) vertical.

El método de los mínimos cuadrados selecciona los valores de la pendiente y de la intersección con el eje Y que minimizan la suma de errores al cuadrado (distancias), SSE , entre los valores de Y y la recta.

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1 X)^2 \quad (2.11)$$

donde $\hat{Y} = b_0 + b_1 X$ es el valor estimado de Y , sobre la recta ajustada.

Usando el cálculo, se pueden derivar expresiones algebraicas específicas para los valores de los mínimos cuadrados. Particularmente:

$$b_1 = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} \quad (2.12)$$


$$b_0 = \bar{Y} - b_1 \bar{X} = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} \quad (2.13)$$

donde

b_1 = la pendiente de la recta

b_0 = la intersección con el eje Y

El *método de los mínimos cuadrados* se utiliza para calcular la ecuación de una recta, que minimiza la suma de las distancias al cuadrado entre los puntos de datos X - Y y la recta, medidos en la dirección vertical (Y).

**Ejemplo 2.11 Cálculo de una recta ajustada usando el método de los mínimos cuadrados**

El ejemplo 2-10 sugiere una relación lineal positiva fuerte entre edad e ingreso. Sustituyendo los totales de la tabla 2-7 en las ecuaciones 2.12 y 2.13, la ecuación de una recta que mejor se ajuste a los puntos se calcula como:

$$b_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{5(4,266.1) - (133)(157.7)}{5(3,643) - (133)^2} = \frac{356.4}{526} = .678$$

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \frac{157.7}{5} - \frac{(.678)(133)}{5} = 31.540 - 18.035 = 13.505$$

La recta que mejor se ajusta a los datos, $\hat{Y} = 13.505 + .678 X$, se ilustra en la figura 2-15.

La ecuación calculada en el ejemplo 2-11, junto con otros valores que pueden calcularse a partir de los datos de la muestra, es de enorme utilidad para los gerentes en el pronóstico de valores futuros de una variable importante, y en la evaluación anticipada de qué tan precisos serían tales pronósticos. En un capítulo posterior, usted aprenderá cómo extraer gran parte de información a partir de los datos de la muestra, y cómo usarla para hacer pronósticos con el análisis de regresión.

El coeficiente de la pendiente de cuadrados mínimos está relacionado con el coeficiente de correlación de la muestra. Específicamente:

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (2.14)$$

Como resultado, b_1 y r son proporcionales entre sí y tienen el mismo signo.

Ejemplo 2.12 Demostración de la relación entre el coeficiente de correlación y el coeficiente de la pendiente

Usando los resultados de la tabla 2-7 y los ejemplos 2-10 y 2-11, verificamos numéricamente la ecuación 2.14. Usando la ecuación 2.14, tenemos

$$b_1 = \frac{\sqrt{\Sigma(Y - \bar{Y})^2}}{\sqrt{\Sigma(X - \bar{X})^2}} r = \frac{\sqrt{61.192}}{\sqrt{105.2}} .89 = (.763)(.89) = .679$$

Este valor, considerando el error por redondeo, coincide con el valor del coeficiente de la pendiente calculado directamente en el ejemplo 2.11, usando la ecuación 2.12.

Ejemplo 2.13

Suponga que el director general de una empresa constructora grande sospecha que los gastos estimados de los proyectos de construcción de su compañía no están muy cercanos de los gastos reales al final del proyecto. Los datos que se presentan en la tabla 2-8 se recopilaron de unos cuantos proyectos anteriores, para analizar la relación entre los costos estimados y los costos reales. Puesto que tiene a su disposición Minitab, se analizan los datos usando este programa.

La figura 2-16 ilustra que la correlación entre los costos de construcción estimados y reales, con base en los datos de la muestra, es $r = .912$. El director general de la compañía está sorprendido por saber que éste sea alto.

La figura 2-17 presenta los datos graficados como un diagrama de dispersión y la recta que mejor se ajusta a estos datos: $\hat{Y} = .683 + .922X$. El director general puede ahora pronosticar el costo de construcción real (Y), después de que se preparó el estimado para el proyecto (X).

TABLA 2-8 Costos estimados y reales del proyecto de construcción del ejemplo 2.13

<i>Reglón</i>	<i>Actual</i>	<i>Estimado</i>
1	0.918	0.575
2	7.214	6.127
3	14.577	11.215
4	30.028	28.195
5	38.173	30.100
6	15.320	21.091
7	14.837	8.659
8	51.284	40.630
9	34.100	37.800
10	2.003	1.803
11	20.099	18.048
12	4.324	8.102
13	10.523	10.730
14	13.371	8.947
15	1.553	3.157
16	4.069	3.540
17	27.973	37.400
18	7.642	7.650
19	3.692	13.700
20	29.522	29.003
21	15.317	14.639
22	5.292	5.292
23	0.707	0.960
24	1.246	1.240
25	1.143	1.419
26	21.571	38.936

Correlations: ActualCost, EstimatedCost

Pearson correlation of ActualCost and EstimatedCost = 0.912

Regression Analysis: ActualCost versus EstimatedCost

The regression equation is

ActualCost = 0.683 + 0.9223 EstimatedCost

FIGURA 2-16 Resultado de Minitab para el ejemplo 2.13




FIGURA 2-17 Gráfica de la línea ajustada del ejemplo 2.13

EVALUACIÓN DE LA NORMALIDAD

Muchas técnicas estadísticas, incluyendo algunas de las que se usan en la elaboración de pronósticos, requieren la suposición de que un conjunto de datos sigue una distribución normal. Por tal motivo, se han desarrollado técnicas estadísticas que prueban la hipótesis de que un conjunto de datos muestrales fue extraído de una población normalmente distribuida.

Considere las tasas de rendimiento mensual del índice bursátil Standard & Poor's 500, mostradas en la tabla 2-9. ¿Se puede suponer que estos datos siguen una distribución normal? La respuesta, obtenida con Minitab, está contenida en la figura 2-18.

La recta trazada en la figura 2-18 muestra qué puntos de una curva normal perfecta se verían como si se hubieran graficado usando esta escala especial.⁴ Como se indica, los datos de la tabla 2-9 están muy cerca de esta línea, lo cual sugiere un buen ajuste entre los datos de S&P y una distribución normal.

⁴Están disponibles otras gráficas de probabilidad normal. Una de ellas, llamada *gráfica de puntuaciones normal*, se usa frecuentemente. En todas estas gráficas, normalmente se indica si los datos graficados están cerca de una recta.

TABLA 2-9 Tasas mensuales de rendimiento (%) del índice Standard & Poor's 500

	Año			
	1	2	3	4
Ene.	—	6.87	-7.13	4.07
Feb.	4.10	-2.94	0.85	6.51
Mar.	-3.39	2.06	2.40	2.20
Abr.	0.94	4.89	-2.73	0.03
Mayo	0.32	3.45	8.80	3.79
Jun.	4.23	-0.80	-0.89	-4.91
Jul.	-0.54	8.47	-0.52	4.39
Ago.	-3.94	1.54	-9.91	1.95
Sept.	3.90	-0.66	-5.25	-1.93
Oct.	2.56	-2.55	-0.67	1.18
Nov.	-1.91	1.64	5.82	-4.49
Dic.	1.46	2.12	2.45	10.58




FIGURA 2-18 Gráfica de probabilidad normal para tasas de rendimiento mensuales del índice Standard & Poor's 500

La prueba de normalidad preestablecida de Minitab es la prueba Anderson-Darling, cuyos resultados se ilustran en la figura 2-18. Los detalles de esta prueba no nos interesan por el momento; sin embargo, note el *valor p* (indicado como P-Value en la parte superior derecha de la figura) de .927. En este caso, el *valor p* grande sugiere que los datos de la muestra de S&P son consistentes con la hipótesis nula (en efecto, no es inusual si la hipótesis nula es verdadera). El rechazo de la hipótesis nula de la normalidad daría como resultado casi con seguridad un error. Por lo tanto, la hipótesis nula no debería rechazarse y la suposición de que los datos de S&P siguen una distribución normal puede hacerse con seguridad.

APLICACIÓN EN LA ADMINISTRACIÓN

Muchos de los conceptos en este capítulo de repaso pueden considerarse como los antecedentes necesarios para la comprensión de técnicas más avanzadas para elaborar pronósticos, que se encuentran a lo largo del resto del libro. Sin embargo, los conceptos en este capítulo también tienen valor por sí mismos en muchas aplicaciones estadísticas. Aunque algunas de dichas aplicaciones quizá no caigan lógicamente dentro del título de “pronósticos”, implican el uso de datos recopilados para contestar preguntas acerca de incertidumbres en la operación de negocios, en especial de los resultados futuros inciertos.

Los procedimientos estadísticos descriptivos mencionados al principio del capítulo son ampliamente usados siempre que grandes cantidades de datos deban describirse de forma convincente, de modo que puedan utilizarse en el proceso de toma de decisiones. Sería casi imposible pensar en una sola área que implique mediciones numéricas, en las cuales los conjuntos de datos no estén resumidos rutinariamente, usando estadísticos descriptivos. Este hecho se aplica específicamente a la media, que por lo general se conoce como el “promedio”, y —en menor medida— a la desviación estándar. Los promedios son cosa común y se han utilizado por muchos años para tener medidas centrales de conjuntos ordenados de datos. El énfasis reciente en la calidad requiere una comprensión de la variación y, por lo tanto, medidas de dispersión, tales como la desviación estándar, están apareciendo con cada vez mayor frecuencia en la práctica de negocios.

Las distribuciones binomial y normal son buenos ejemplos de distribuciones teóricas que sirven como modelos para muchas situaciones de la vida real. Como tales, se han utilizado abundantemente en aplicaciones, incluyendo la elaboración de pronósticos.

La estimación y la prueba de hipótesis son el principal fundamento de la inferencia estadística básica. La elaboración de pronósticos, o estimación, acerca de los valores de interés de población, a partir de una muestra aleatoria, se emplea comúnmente siempre que las restricciones de tiempo y de costos descartan un examen de todos los elementos en consideración. El muestreo está muy extendido en auditorías. La prueba de hipótesis está relacionada con dos enunciados en competencia, acerca de parámetros de la población, de modo que se emplea a menudo para contestar preguntas como éstas:

- ¿Cómo se compara la media de ventas de este periodo con la del periodo anterior?
- ¿Cómo se compara la razón activos/pasivos media de empresas exitosas con la de empresas malogradas?
- ¿La producción media por hora de este proceso de producción es menor de lo que había sido?

La correlación se utiliza ampliamente para examinar las relaciones entre pares de variables numéricas. Como veremos en capítulos posteriores, estas relaciones son de gran importancia en la elaboración de pronósticos, porque el pronóstico de una variable a menudo requiere los valores de las variables relevantes relacionadas. Tanto los análisis de regresión simple como múltiple son técnicas de pronósticos que caen dentro de esta categoría.

Glosario

Distribución binomial. La distribución binomial es una distribución de probabilidad discreta, que describe la probabilidad de X éxitos en n ensayos independientes de un experimento binomial.

Variable aleatoria continua. Una variable aleatoria continua puede tomar cualquier valor dentro de un rango específico. Estos resultados se representan numéricamente con intervalos de valores.

Coefficiente de correlación. Mide el grado en que dos variables están linealmente relacionadas entre sí.

Grados de libertad. Se refieren al número de datos que son independientes entre sí y llevan piezas únicas de información.

Variable aleatoria discreta. Tipo de variable que sólo puede tomar ciertos valores de un conjunto predeterminado. Estos resultados a menudo se representan numéricamente con enteros.

Valor esperado. El valor medio de la variable a lo largo de muchos ensayos u observaciones.

Intervalo de estimación. Intervalo numérico dentro del cual es probable que se encuentre el parámetro de la población.

Método de los mínimos cuadrados. Se usa para calcular la ecuación de una línea recta que minimiza la suma de los cuadrados de las distancias entre los puntos de datos X - Y y la línea, medidos en la dirección vertical (Y).

Distribución normal. Tiene forma de campana y está completamente determinada por su media y su desviación estándar.

Estimación puntual. Estimación de un parámetro poblacional mediante un valor único.

Valor p . También llamado probabilidad de significancia, es la probabilidad de obtener un resultado de muestra por lo menos tan extremo como el que se observa realmente si H_0 es verdadera.

Distribución muestral. Es el arreglo de todos los valores posibles de un estadístico muestral, que puede obtenerse a partir de una población para un tamaño de muestra determinado.

Diagrama de dispersión. Un diagrama de dispersión es una gráfica de puntos de datos X - Y sobre una gráfica bidimensional.

Fórmulas clave

Media de la muestra

$$\bar{X} = \frac{\sum X}{n} \quad (2.1)$$

Desviación estándar de la muestra

$$S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} = \sqrt{\frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1}} \quad (2.2)$$

Varianza de la muestra

$$S^2 = \frac{(X - \bar{X})^2}{n - 1} = \frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1} \quad (2.3)$$

Valor esperado

$$E(X) = \sum [X \times P(X)] \quad (2.4)$$

Distribución de probabilidad binomial

$$P(X) = \binom{n}{X} p^X (1 - p)^{n-X} \quad \text{para } X = 0, 1, \dots, n \quad (2.5)$$

Z como número de varianzas

$$Z = \frac{X - \mu}{\sigma} \quad (2.6)$$

Estadístico de prueba t (distribución t de Student)

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (2.7)$$

Intervalo de confianza para la media de la población (muestra grande)

$$\bar{X} \pm Z \frac{S}{\sqrt{n}} \quad (2.9)$$

Intervalo para la media de la población (muestra pequeña, población normal)

$$\bar{X} \pm t \frac{S}{\sqrt{n}}$$

Coefficiente de correlación

$$\begin{aligned} r &= \frac{1}{n-1} \sum Z_X Z_Y = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \sqrt{\sum (Y - \bar{Y})^2}} \\ &= \frac{n \sum XY - (\sum X)(\sum Y)}{\sqrt{n \sum X^2 - (\sum X)^2} \sqrt{n \sum Y^2 - (\sum Y)^2}} \end{aligned} \quad (2.10)$$

Método de mínimos cuadrados

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1 X)^2 \quad (2.11)$$

Ecuación de la pendiente de regresión ajustada

$$b_1 = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} \quad (2.12)$$

Ecuación de la intersección con el eje Y de la recta de regresión ajustada

$$b_0 = \bar{Y} - b_1 \bar{X} = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} \quad (2.13)$$

Ecuación alternativa de la pendiente de la ecuación de regresión ajustada

$$b_1 = \left(\frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} \right) r \quad (2.14)$$

Problemas

1. Dick Hoover, propietario de Modern Office Equipment, está preocupado por los costos de fletes (de envío) y por los costos de oficina en que incurren pedidos pequeños. En un esfuerzo por reducir gastos en esta área, decide aplicar una

política de descuentos en pedidos de más de \$40, con la esperanza de que esto motive a los clientes a consolidar varios pedidos pequeños en pedidos más grandes. Los siguientes datos presentan las cantidades por transacción para una muestra de 28 clientes.

10, 15, 20, 25, 15, 17, 41, 50, 5, 9,
12, 14, 35, 18, 19, 17, 28, 29, 11, 11,
43, 54, 7, 8, 16, 13, 37, 18

- Calcule la media de la muestra.
 - Calcule la desviación estándar de la muestra.
 - Calcule la varianza de la muestra
 - Si la política tiene éxito, ¿la media de la distribución aumentará, disminuirá o no se verá afectada?
 - Si la política tiene éxito, ¿la desviación estándar de la distribución aumentará, disminuirá o no se verá afectada?
 - Dados los datos anteriores, pronostique la cantidad del siguiente pedido de parte de los clientes.
2. Sandy James cree que los precios de las viviendas se han estabilizado en los recientes meses. Para convencer a su jefe, ella tiene pensado comparar los precios actuales con los precios del año pasado. Ella reúne 12 precios de viviendas de anuncios clasificados:

125,900 253,000 207,500 146,950 121,450 135,450
175,000 200,000 210,950 166,700 185,000 191,950

Luego, calcula la media y la desviación estándar de los precios que encontró. ¿Cuáles son estos dos valores?

3. Una compañía constructora grande planea idear una manera útil de visualizar las ganancias típicas de trabajos obtenidos por licitación. Debido a que los trabajos varían significativamente en tamaño y en la cantidad final de subasta exitosa, la compañía ha decidido expresar las utilidades como ganancias porcentuales:

$$\text{Ganancias porcentuales} = 100 \times \frac{\text{Ganancias}}{\text{Costos reales de construcción}}$$

Cuando se pierde dinero en un proyecto, las ganancias son negativas y también la utilidad neta resultante. Una muestra de 30 trabajos arrojó las ganancias porcentuales:

15.9 21.3 -1.8 6.6 .4 53.6 19.7 -.5 6.7 -2.3
11.9 -.3 19.0 12.8 -9.6 26.8 21.0 32.0 -.4 10.9
6.9 -8.5 3.5 3.5 -1.9 4.0 13.0 15.1 9.7 33.9

- Calcule un estimado de las ganancias porcentuales medias para la población de trabajos al incluir todos los trabajos potenciales.
- Construya un intervalo de confianza de 95% para las ganancias porcentuales medias de la población de trabajos, usando un argumento de muestra grande.
- Construya un intervalo de confianza de 95%, para las ganancias porcentuales medias para la población de trabajos, suponiendo que 30 es un tamaño de muestra pequeño. ¿Cuál es la suposición adicional que usted necesita hacer en este caso?
- Compare los dos intervalos en los incisos b) y c). Explique por qué un tamaño de muestra de 30 a menudo se toma como límite entre una muestra grande y una pequeña.

4. De los datos en una muestra grande de transacciones de ventas, el propietario de un negocio pequeño informa que un intervalo de confianza de 95% para la utilidad media por transacción, μ , es (23.41, 102.59). Use estos datos para determinar
 - a) Una estimación puntual (mejor conjetura) de la media, μ , y su margen de error de 95%.
 - b) Un intervalo de confianza de 90% para la media, μ .
5. Queremos predecir si el número medio de días de ausencia por año se ha incrementado para una muestra grande de trabajadores. Se sabía que hace un año la media era de 12.1. Una muestra reciente de 100 empleados revela una media muestral de 13.5, con una desviación estándar de la muestra de 1.7 días. Pruebe con nivel de significancia de .05, para determinar si la media de la población se ha incrementado, o si la diferencia entre 13.5 y 12.1 simplemente representa un error de muestreo.
6. New Horizons Airlines quiere predecir el número medio de asientos vacíos por vuelo a Alemania para el siguiente año. Para realizar tal pronóstico, se seleccionan al azar los registros de 49 vuelos de los archivos del año pasado, y se anota el número de asientos desocupados para cada vuelo. La media y la desviación estándar de la muestra son de 8.1 asientos y 5.7 asientos, respectivamente. Desarrolle una estimación puntual y por intervalo de 95% del número medio de asientos desocupados por vuelo, durante el año pasado. Pronostique la media de asientos vacíos por vuelo a Alemania para el siguiente año. Analice la exactitud de su pronóstico.
7. Por un periodo de varios años, un dentífrico ha recibido una puntuación media de 5.9, en una escala de 7 puntos, en cuanto a la satisfacción general del cliente con el producto. Debido a un cambio no anunciado en el producto, existe la preocupación de que quizás haya cambiado la satisfacción del cliente. Suponga que las puntuaciones de satisfacción para una muestra de 60 clientes tienen una media de 5.60 y una desviación estándar de .87. ¿Indican estos datos que la puntuación media de satisfacción es diferente de 5.9? Pruebe con $\alpha = .05$. ¿Cuál es el *valor p* de la prueba?
8. La gerente de una tienda de yogurt congelado afirma que una porción de tamaño mediano contiene un promedio de más de 4 onzas de producto. A partir de una muestra aleatoria de 14 raciones, se obtiene una media de 4.31 onzas y una desviación estándar de .52 onzas. Pruebe, con $\alpha = .05$, la afirmación de la gerente. Calcule el *valor p* para la prueba. Suponga que la distribución de peso por ración es normal.
9. Con base en experiencias pasadas, la California Power Company predice que la media del uso residencial de electricidad por hogar será de 700 kwh para el próximo enero. En enero, la compañía selecciona una muestra aleatoria simple de 50 hogares, y calcula una media y una desviación estándar de 715 y 50, respectivamente. Utilice un nivel de significancia de 0.05, para determinar si el pronóstico de California Power es razonable. Calcule e interprete el *valor p* de esta prueba.
10. Expertos demógrafos indican que el tamaño de la familia ha disminuido en los años recientes. Hace 10 años, el tamaño promedio de la familia era de 2.9. Considere la población de 200 tamaños de familia mostrados en la tabla P-10. Seleccione al azar una muestra de 30 tamaños de familia y pruebe la hipótesis de que el tamaño promedio de la familia no ha cambiado en los últimos 10 años.
11. A James Dobbins, supervisor de mantenimiento en Atlanta Transit Authority, le gustaría determinar si hay una relación positiva entre el costo de mantenimiento anual de un autobús y su antigüedad. Si existe tal relación, James cree que puede predecir mejor el presupuesto anual de mantenimiento de los autobuses. Él reúne los datos que se presentan en la tabla P-11.
 - a) Grafique un diagrama de dispersión.
 - b) ¿Qué tipo de relación hay entre estas dos variables?
 - c) Calcule el coeficiente de correlación.

TABLA P-10

(1) 3	(35) 1	(69) 2	(102) 1	(135) 5	(168) 6
(2) 2	(36) 2	(70) 4	(103) 2	(136) 2	(169) 3
(3) 7	(37) 4	(71) 3	(104) 5	(137) 1	(170) 2
(4) 3	(38) 1	(72) 7	(105) 3	(138) 4	(171) 3
(5) 4	(39) 4	(73) 2	(106) 2	(139) 2	(172) 4
(6) 2	(40) 2	(74) 6	(107) 1	(140) 4	(173) 2
(7) 3	(41) 1	(75) 2	(108) 2	(141) 1	(174) 2
(8) 1	(42) 3	(76) 7	(109) 2	(142) 2	(175) 1
(9) 5	(43) 5	(77) 3	(110) 1	(143) 4	(176) 5
(10) 3	(44) 2	(78) 6	(111) 4	(144) 1	(177) 3
(11) 2	(45) 1	(79) 4	(112) 1	(145) 2	(178) 2
(12) 3	(46) 4	(80) 2	(113) 1	(146) 2	(179) 4
(13) 4	(47) 3	(81) 3	(114) 2	(147) 5	(180) 3
(14) 1	(48) 5	(82) 5	(115) 2	(148) 3	(181) 5
(15) 2	(49) 2	(83) 2	(116) 1	(149) 1	(182) 3
(16) 2	(50) 4	(84) 1	(117) 4	(150) 2	(183) 1
(17) 4	(51) 1	(85) 3	(118) 2	(151) 6	(184) 2
(18) 4	(52) 6	(86) 3	(119) 1	(152) 2	(185) 4
(19) 3	(53) 2	(87) 2	(120) 3	(153) 5	(186) 3
(20) 2	(54) 5	(88) 4	(121) 5	(154) 1	(187) 2
(21) 1	(55) 4	(89) 1	(122) 1	(155) 2	(188) 5
(22) 5	(56) 1	(90) 2	(123) 2	(156) 1	(189) 3
(23) 2	(57) 2	(91) 3	(124) 3	(157) 4	(190) 4
(24) 1	(58) 1	(92) 3	(125) 4	(158) 2	(191) 3
(25) 4	(59) 5	(93) 2	(126) 3	(159) 2	(192) 2
(26) 3	(60) 2	(94) 4	(127) 2	(160) 7	(193) 3
(27) 2	(61) 7	(95) 1	(128) 1	(161) 4	(194) 2
(28) 3	(62) 1	(96) 2	(129) 6	(162) 2	(195) 5
(29) 6	(63) 2	(97) 4	(130) 1	(163) 1	(196) 3
(30) 1	(64) 6	(98) 3	(131) 2	(164) 7	(197) 3
(31) 2	(65) 4	(99) 2	(132) 5	(165) 2	(198) 2
(32) 4	(66) 1	(100) 6	(133) 2	(166) 7	(199) 5
(33) 3	(67) 2	(101) 4	(134) 1	(167) 4	(200) 1
(34) 2	(68) 1				

TABLA P-11

<i>Autobús</i>	<i>Costo de mantenimiento (\$) Antigüedad</i>	
	<i>Y</i>	<i>(años) X</i>
1	859	8
2	682	5
3	471	3
4	708	9
5	1,094	11
6	224	2
7	320	1
8	651	8
9	1,049	12

TABLA P-12

<i>Semana</i>	<i>Libros vendidos Y</i>	<i>Espacio en estantes X</i>
1	275	6.8
2	142	3.3
3	168	4.1
4	197	4.2
5	215	4.8
6	188	3.9
7	241	4.9
8	295	7.7
9	125	3.1
10	266	5.9
11	200	5.0

12. Ana Sheehan es la gerente de la cadena de supermercados Spendwise. A ella le gustaría predecir las ventas (ejemplares por semana) de libros de pasta blanda (rústica), con base en la cantidad de espacio de exhibición en los anaqueles (en pies). Anna reúne datos para una muestra de 11 semanas, como se presenta en la tabla P-12.
- Grafique un diagrama de dispersión.
 - ¿Qué tipo de relación hay entre estas dos variables?
 - Calcule el coeficiente de correlación. Utilice el método de mínimos cuadrados para determinar la pendiente y la intersección con el eje Y de la ecuación de la recta. Use esta ecuación para predecir el número de libros vendidos, si se usan 5.2 pies de espacio en estantes (es decir, $X = 5.2$).
13. Considere la población de 200 observaciones semanales presentadas en la tabla P-13. La variable independiente X es la temperatura semanal promedio en Spokane, Washington. La variable dependiente Y es el número de acciones de Sunshine Mining Stock, con las que se hicieron operaciones en la bolsa de valores de Spokane en una semana. Elija datos al azar para 16 semanas y calcule el coeficiente de correlación. (*Sugerencia:* Asegúrese de que su muestra se obtiene aleatoriamente de la población). Luego determine la recta de los mínimos cuadrados y pronostique Y para una temperatura promedio semanal de 63.
14. Un inversionista inmobiliario recolecta los siguientes datos de una muestra aleatoria de apartamentos en el lado oeste de College Station, Texas.
- Grafique los datos como un diagrama de dispersión donde Y = renta y X = tamaño.
 - Determine la ecuación de la recta ajustada que relacione la renta con el tamaño.
 - ¿Cuál es el incremento estimado en renta, para un pie adicional de espacio?
 - Pronostique la renta mensual para un departamento de 750 pies cuadrados.

Renta (\$ mensuales)	Tamaño (pies ²)	Renta (\$ mensuales)	Tamaño (pies ²)
720	1,000	650	800
595	900	748	960
915	1,200	685	650
760	810	755	970
1,000	1,210	815	1,000
790	860	745	1,000
880	1,135	715	1,000
845	960	885	1,180

TABLA P-13

<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>
(1)	50	37	(51)	54	86	(101)	22	43	(151)	79	85
(2)	90	77	(52)	76	48	(102)	32	5	(152)	79	27
(3)	46	55	(53)	55	48	(103)	24	13	(153)	48	61
(4)	47	27	(54)	12	15	(104)	63	3	(154)	5	7
(5)	12	49	(55)	5	70	(105)	16	58	(155)	24	79
(6)	23	23	(56)	2	9	(106)	4	13	(156)	47	49
(7)	65	18	(57)	77	52	(107)	79	18	(157)	65	71
(8)	37	1	(58)	6	71	(108)	5	5	(158)	56	27
(9)	87	41	(59)	67	38	(109)	59	26	(159)	52	15
(10)	83	73	(60)	30	69	(110)	99	9	(160)	17	88
(11)	87	61	(61)	3	13	(111)	76	96	(161)	45	38
(12)	39	85	(62)	6	63	(112)	15	94	(162)	45	31
(13)	28	16	(63)	70	65	(113)	10	30	(163)	90	35
(14)	97	46	(64)	33	87	(114)	20	41	(164)	69	78
(15)	69	88	(65)	13	18	(115)	37	1	(165)	62	93
(16)	87	87	(66)	10	4	(116)	56	27	(166)	0	51
(17)	52	82	(67)	21	29	(117)	6	73	(167)	8	68
(18)	52	56	(68)	56	21	(118)	86	19	(168)	47	30
(19)	15	22	(69)	74	9	(119)	27	94	(169)	7	81
(20)	85	49	(70)	47	8	(120)	67	5	(170)	48	30
(21)	41	44	(71)	34	18	(121)	22	31	(171)	59	46
(22)	82	33	(72)	38	84	(122)	32	13	(172)	76	99
(23)	98	77	(73)	75	64	(123)	90	11	(173)	54	98
(24)	99	87	(74)	0	81	(124)	88	50	(174)	95	11
(25)	23	54	(75)	51	98	(125)	35	40	(175)	7	6
(26)	77	8	(76)	47	55	(126)	57	80	(176)	24	83
(27)	42	64	(77)	63	40	(127)	73	44	(177)	55	49
(28)	60	24	(78)	7	14	(128)	13	63	(178)	41	39
(29)	22	29	(79)	6	11	(129)	18	74	(179)	14	16
(30)	91	40	(80)	68	42	(130)	70	40	(180)	24	13
(31)	68	35	(81)	72	43	(131)	9	53	(181)	36	31
(32)	36	37	(82)	95	73	(132)	93	79	(182)	62	44
(33)	22	28	(83)	82	45	(133)	41	9	(183)	77	11
(34)	92	56	(84)	91	16	(134)	17	52	(184)	32	60
(35)	34	33	(85)	83	21	(135)	10	82	(185)	12	82
(36)	34	82	(86)	27	85	(136)	69	37	(186)	85	7
(37)	63	89	(87)	13	37	(137)	5	57	(187)	90	68
(38)	30	78	(88)	6	89	(138)	18	62	(188)	78	10
(39)	31	24	(89)	76	76	(139)	88	21	(189)	60	27
(40)	84	53	(90)	55	71	(140)	99	94	(190)	96	90
(41)	56	61	(91)	13	53	(141)	86	99	(191)	51	6
(42)	48	18	(92)	50	13	(142)	95	45	(192)	9	62
(43)	0	45	(93)	60	12	(143)	78	19	(193)	93	78
(44)	58	4	(94)	61	30	(144)	3	76	(194)	61	22
(45)	27	23	(95)	73	57	(145)	38	81	(195)	5	99
(46)	78	68	(96)	20	66	(146)	57	95	(196)	88	51
(47)	78	79	(97)	36	27	(147)	77	30	(197)	45	44
(48)	72	66	(98)	85	41	(148)	25	59	(198)	34	86
(49)	21	80	(99)	49	20	(149)	99	93	(199)	28	47
(50)	73	99	(100)	83	66	(150)	9	28	(200)	44	49

15. Abbot & Sons necesita pronosticar la edad media μ de sus trabajadores contratados por hora. Se obtiene una muestra aleatoria de los archivos personales, con los resultados de abajo. Prepare una estimación puntual y un intervalo de confianza de 98%, para la edad media de los trabajadores. Pruebe la hipótesis $H_0: \mu = 44$ contra $H_1: \mu \neq 44$ al nivel de 2%. ¿Los resultados de la prueba de hipótesis son consistentes con el intervalo de confianza para μ ? ¿Usted esperaría que fueran?

$$\bar{X} = 45.2 \quad S = 10.3 \quad n = 175$$

16. En cada una de las siguientes situaciones, establezca una hipótesis nula adecuada, H_0 , y una hipótesis alternativa, H_1 . Identifique el parámetro que utilizará para establecer la hipótesis.
- Datos de Census Bureau indican que el ingreso familiar medio, en el área que atiende un centro comercial, es de \$63,700 anuales. Una empresa de investigación de mercados encuesta a los compradores del centro comercial, para averiguar si el ingreso familiar medio de los clientes es mayor que el de la población general.
 - El año pasado, al departamento de bomberos local le tomó un promedio de 4.3 minutos dar respuesta a las llamadas. ¿Los datos de este año indican un promedio diferente en el tiempo de respuesta?
 - Se anuncia que el área media de varios miles de apartamentos en un nuevo desarrollo es de 1,300 pies cuadrados. Un grupo de arrendatarios cree que los apartamentos son más pequeños que lo que dice la publicidad. Ellos contrataron a un ingeniero para medir una muestra de apartamentos para probar sus sospechas.
17. Un inversionista con un portafolio de inversiones sustancial demandó a su agente bursátil y a su empresa de corretaje, a causa de que la falta de diversificación en su portafolio le ocasionó un desempeño deficiente. Las tasas de rendimiento para los 39 meses que la cuenta fue administrada por tal agente produjeron estos estadísticos de resumen: $\bar{r} = -1.10\%$, $S = 5.99\%$. Considere los 39 rendimientos mensuales como una muestra aleatoria de la población de rendimientos que la correduría generaría, si administrara la cuenta para siempre. Usando los resultados de la muestra, construya un intervalo de confianza de 95%, para la media de rendimientos mensuales del mercado. Permita que S&P 500 represente al mercado y suponga que el rendimiento medio de S&P 500 para el mismo periodo es de 0.94%. ¿Éste un valor realista para la media de la población de cuentas del cliente? Explique.
18. La tabla P-18 proporciona sueldos mensuales en dólares (SUELDOS) y tiempo de servicio (TDS) en meses, en un momento específico, para 16 mujeres que tienen trabajos de servicio al cliente en bancos de Texas.

TABLA P-18

<i>Empleado</i>	<i>SUELDOS</i>	<i>TDS</i>
1	389	94
2	377	60
3	315	45
4	316	39
5	324	20
6	403	76
7	390	106
8	441	62
9	418	68
10	413	55
11	396	27
12	353	58
13	483	139
14	437	98
15	341	70
16	476	60

- Grafique los datos de la tabla P-18 como un diagrama de dispersión, con SUELDOS a lo largo del eje vertical (Y) y TDS en el eje horizontal (X).
- Calcule el coeficiente de correlación de la muestra, r . Usando el signo y la magnitud de r , describa la naturaleza de la asociación lineal entre SUELDOS y TDS. ¿Puede pensar en otras variables que afectarían los sueldos semanalmente, además del tiempo de servicio?
- Calcule la recta ajustada que pueda usarse para predecir SUELDOS a partir de TDS. Si el TDS es de 80 meses, ¿cuál será el SUELDO pronosticado?

CASOS

CASO 2-1 ALCAM ELECTRONICS

Jarrick Tilby se tituló recientemente en administración de negocios en una pequeña universidad y comenzó a trabajar a Alcam Electronics, un fabricante de varios componentes electrónicos para la industria. Después de unas semanas en el trabajo, la gerente y propietaria de Alcam, McKennah Labrum, lo llamó a su oficina y le pidió investigar una cuestión respecto a cierto transistor fabricado por Alcam, porque una compañía de TV grande estaba interesada en una compra significativa.

McKennah quería pronosticar el tiempo de vida promedio de este tipo de transistor, un asunto de gran preocupación para la compañía de TV. Las unidades que actualmente están en existencia podrían ser representativas de aquellas que se producirían durante la vigencia del nuevo contrato si es que éste fuera aceptado.

Jarrick decidió tomar una muestra aleatoria de los transistores en cuestión y formuló un plan para llevar a cabo esa tarea. Numeró los contenedores de almacenamiento de los transistores, les puso números aleatorios y muestreó todos los transistores en cada contenedor seleccionado para la muestra. Puesto que cada contenedor incluía aproximadamente de 20 transistores, seleccionó 10 números al azar, lo cual le dio un tamaño de muestra final de 205 transistores. Debido a que había seleccionado 10 de 55 contenedores, creía que tenía una buena muestra representativa y podría usar los resultados de esta muestra para generalizar a la población completa de transistores en el inventario, así como a las unidades aún habrían de ser fabricadas con el mismo proceso.

Entonces, Jerrick consideró la cuestión del tiempo de vida promedio de las unidades. Debido a que el tiempo de vida de la unidad puede extenderse varios años, se dio cuenta de que ninguna de las unidades muestreadas podría probarse, si se deseaba una res-

puesta oportuna. Por lo tanto, decidió contactar a varios usuarios de dichos componentes para determinar si había registros acerca de la vida de los componentes. Por fortuna, encontró tres compañías que han usado el transistor en el pasado y que tenían registros limitados acerca del tiempo de vida del componente. En total, recibió datos sobre 38 transistores cuyos tiempos de falla eran conocidos. Puesto que estos transistores se fabricaron usando el proceso actual, Jarrick pensó que los resultados de esta muestra podrían utilizarse para hacer inferencias acerca de las unidades en el inventario y aquellas que se fabricarían.

Los resultados de los cálculos que Jarrick ejecutó con su muestra de datos del tiempo de vida son:

$$n = 38$$

$$\text{Tiempo de vida promedio } \bar{X} = 4,805 \text{ horas}$$

$$\text{Desviación estándar de tiempos de vida } S = 675 \text{ horas}$$

Después de encontrar que el tiempo de vida promedio de la muestra era tan sólo de 4,805 horas, Jarrick estaba preocupado porque sabía que otro proveedor de componentes estaba garantizando un tiempo de vida promedio de 5,000 horas. Aunque su promedio de la muestra estaba un poco por debajo de 5,000 horas, se dio cuenta de que el tamaño de la muestra era únicamente de 38 y que esto no constituía una prueba contundente de que la calidad de Alcam fuera inferior a la del otro proveedor. Decidió probar la hipótesis de que el tiempo de vida promedio de todos los transistores era de 5,000 horas contra la alternativa de que fuera menor. En seguida se presentan los cálculos que realizó usando $\alpha = .01$:

$$H_0: \mu = 5,000$$

$$H_1: \mu < 5,000$$

Si $S = 675$, entonces el punto de la regla de decisión es

$$5,000 - 2.33 \frac{675}{\sqrt{38}} = 4,744.9$$

y la regla de decisión es como sigue:

$$\text{Si } \bar{X} < 4,744.9, \text{ rechace } H_0$$

Puesto que la media de la muestra (4,805) no estaba por debajo del punto de la regla de decisión para el rechazo (4,744.9), Jarrick no rechazó la hipótesis de que el tiempo de vida medio de todos los componentes era igual a 5,000 horas. Pensó que esto serían

buenas noticias para McKennah Labrum e incluyó un resumen de sus hallazgos en su informe final. Pocos días después, le entregó a McKennah su informe verbal y escrito. Ella lo llamó a su oficina para felicitarlo por su buen trabajo y compartir con él una inquietud que tenía en relación con sus hallazgos. Ella dijo: “Estoy preocupada por el nivel de significancia tan bajo de tu prueba de hipótesis. Tan sólo tomaste una probabilidad de 1% de rechazar la hipótesis nula si fuera verdadera. Esto me suena muy conservador. Estoy alarmada de firmar el contrato y luego entrarme de que nuestro nivel de calidad no satisface la especificación deseada de 5,000 horas”.

PREGUNTA

1. ¿Cómo respondería ante el comentario de McKennah Labrum?

CASO 2-2 MR. TUX

John Mosby, propietario de varias tiendas de alquiler Mr. Tux, está interesado en predecir su volumen de ventas mensual (véase caso 1-1). Como primer paso, John recolecta datos de ventas mensuales de los años 1998 a 2005, como se expone en la tabla 2-10.

Después, John calcula el valor promedio de ventas mensuales para cada año (es decir, suma los 12 valores


para 1998 y los divide entre 12). John también calcula la desviación estándar para los 12 valores mensuales de cada año. Los resultados se presentan en la tabla 2-11. John también decide construir una gráfica de series de tiempo, que se ilustra en la figura 2-19. Grafica los valores medios de ventas mensuales sobre el eje Y y el tiempo sobre el eje X.

TABLA 2-10 Datos de ventas mensuales de Mr. Tux

	1998	1999	2000	2001	2002	2003	2004	2005
Ene.	6,028	16,850	15,395	27,773	31,416	51,604	58,843	71,043
Feb.	5,927	12,753	30,826	36,653	48,341	80,366	82,386	152,930
Mar.	10,515	26,901	25,589	51,157	85,651	208,938	224,803	250,559
Abr.	32,276	61,494	103,184	217,509	242,673	263,830	354,301	409,567
Mayo	51,920	147,862	197,608	206,229	289,554	252,216	328,263	394,747
Jun.	31,294	57,990	68,600	110,081	164,373	219,566	313,647	272,874
Jul.	23,573	51,318	39,909	102,893	160,608	149,082	214,561	230,303
Ago.	36,465	53,599	91,368	128,857	176,096	213,888	337,192	375,402
Sept.	18,959	23,038	58,781	104,776	142,363	178,947	183,482	195,409
Oct.	13,918	41,396	59,679	111,036	114,907	133,650	144,618	173,518
Nov.	17,987	19,330	33,443	63,701	113,552	116,946	139,750	181,702
Dic.	15,294	22,707	53,719	82,657	127,042	164,154	184,546	258,713

TABLA 2-11 Valores mensuales promedio de ventas de Mr. Tux

<i>Año</i>	<i>Promedio (media) (\$)</i>	<i>Desviación estándar (\$)</i>
1998	22,013	13,165
1999	44,603	35,290
2000	64,841	47,217
2001	103,610	57,197
2002	141,381	70,625
2003	169,432	63,376
2004	213,866	96,387
2005	247,231	99,153

**FIGURA 2-19** Ventas mensuales medias de Mr. Tux

PREGUNTAS

1. ¿Qué ideas de pronósticos le vienen a la mente cuando estudia los valores medios de ventas mensuales para los años de esos datos?
2. Suponga que John traza una recta a mano a través de su diagrama de dispersión, de modo que “se ajuste bien” y, luego, extiende esta línea hacia el futuro, usando puntos a lo largo de la línea como sus pronósticos mensuales. ¿Qué tan exactos piensa usted que serían tales pronósticos? Use los valores de la desviación estándar que calculó John,

al contestar esta pregunta. Con base en su análisis, ¿animaría a John para continuar buscando un método de pronóstico más exacto? John tiene la última versión de Minitab en su computadora. ¿Cree usted que él debería utilizar la función de análisis de regresión de Minitab, para calcular una línea de mínimos cuadrados? Si lo hizo, ¿qué variable X debería utilizar para pronosticar las ventas mensuales (Y)?

CASO 2-3 ALOMEGA FOOD STORES

En el ejemplo 1.1, la presidenta de Alomega, Julie Ruth, recolectó datos de las operaciones de su compañía. Obtuvo datos de varios meses de ventas, junto con posibles variables explicativas (repase esta situación en el ejemplo 1.1). Mientras su equipo de análisis estaba trabajando con los datos, en un intento por pronosticar las ventas mensuales, se impacientó y se preguntó cuál de las variables de predicción era mejor para este propósito.

Debido a que ella tenía un programa estadístico en su computadora de escritorio, decidió echar una mirada a los datos por sí misma. Primero, encontró los coeficientes de correlación entre la variable de ventas mensuales y varias de las variables explicativas potenciales. Específicamente, estaba interesada en las correlaciones entre las ventas mensuales y el importe de la publicidad en periódicos, el importe mensual de la publicidad en TV, el de la publicidad de uno o dos meses antes, la publicidad en televisión uno o dos meses antes y las calificaciones de la publicidad de sus competidores. Los valores r (coeficientes de correlación) fueron los siguientes:

Coeficiente de correlación r entre la variable ventas y	
Importe mensual de publicidad en periódico	.45
Importe mensual de publicidad en TV	.60
Importe de publicidad en periódico un mes antes	-.32
Importe de publicidad en periódico dos meses antes	.21
Importe de publicidad en TV un mes antes	-.06
Importe de publicidad en TV dos meses antes	.03
Calificación de la publicidad de los competidores	-.18

Julie no estaba sorprendida de encontrar que la correlación más alta era entre las ventas mensuales y los importes de publicidad en TV ($r = .60$); pero esperaba una correlación más fuerte. Decidió usar una función de regresión para calcular la ecuación de la recta

de mínimos cuadrados, usando las ventas como la variable dependiente, y el importe de publicidad en TV como la variable explicativa. Los resultados de esta corrida fueron

$$\text{Ventas} = 341,663 + .336 (\text{publicidad mensual en TV})$$

$$r\text{-cuadrada} = .36(36\%) \quad \text{valor } p = .000$$

Julie buscó en su libro de texto de estadística universitaria, para interpretar los resultados para r -cuadrada y $\text{valor } p$ que imprimió. Después de la lectura, ella recordó que r -cuadrada (que es el cuadrado del coeficiente de correlación r) mide el porcentaje de la variabilidad en ventas, que puede explicarse con la variabilidad en los dólares mensuales de publicidad en TV (esto se estudiará en el capítulo 6). El $\text{valor } p$ también indica que el coeficiente de la pendiente (.336) es significativo; es decir, puede rechazarse la hipótesis de que es cero en la población de la cual se extrajo la muestra sin que exista posibilidad de error.

Julie concluyó que la ecuación de regresión que encontró era importante y podría utilizarse para el pronóstico de ventas mensuales, si se conoce el presupuesto asignado a publicidad en TV. Puesto que los gastos de publicidad en TV están bajo el control de la compañía, ella sintió que tenía una buena forma de pronosticar las ventas futuras. En una breve conversación con el gerente de su departamento de administración de datos, Roger Jackson, ella mencionó sus hallazgos. Él contestó: “Sí, nosotros encontramos eso también. Pero nos dimos cuenta de que la publicidad en TV explica sólo aproximadamente un tercio de la variabilidad en las ventas. Muy bien, 36%. Realmente no creemos que sea suficiente, y estamos tratando de usar otras variables juntas para intentar obtener ese valor r -cuadrado más elevado. Además, creemos que estamos en un método que consistentemente hará un mejor trabajo que el análisis de regresión”.

PREGUNTAS

1. ¿Qué piensa del análisis de Julie Ruth?
2. Defina los residuos (errores) como diferencias entre los valores de ventas reales y los valores

predichos por la línea recta. ¿Cómo podría examinar usted los residuos para decidir si la representación de la línea recta de Julie es adecuada?

Aplicaciones de Minitab

El problema. En el ejemplo 2.1, se analizó un conjunto de edades usando estadística descriptiva.

Soluciones de Minitab

1. Introduzca el nombre de la variable Ages (Edades) debajo de C1.
2. Introduzca los datos en la columna C1.
3. Haga clic en los menús mostrados abajo.

Stat>Basic Statistics>Graphical Summary

4. Aparece la ventana de diálogo Graphical Summary:
 - a) Haga clic en Variables y seleccione Ages (C1), como se ilustra en la figura 2-20.
 - b) Haga clic en OK en la ventana de diálogo Graphical Summary y aparecerá el resumen mostrado en la figura 2-21.
 - c) Para imprimir esta gráfica, haga clic en los siguientes menús.


File>Print Graph


5. Haga clic en los menús mostrados a continuación:

Stat>Basic Statistics>Display Descriptive Statistics

6. Aparece la ventana de diálogo Display Descriptive Statistics.
 - a) Haga clic en Variables y seleccione Ages (C1).
 - b) Haga clic en OK y aparece el resumen mostrado en la figura 2-1 en la ventana Session. (Para obtener estadísticas descriptivas adicionales, dé clic en Statistics y seleccione medidas descriptivas adicionales, antes del clic en OK).

FIGURA 2-20 Pantalla de Minitab de la ventana de diálogo Graphical Summary



**FIGURA 2-21** Pantalla de Minitab de Graphical Summary

- c) Para imprimir la ventana de la sesión que contiene un resumen de los estadísticos descriptivos, haga clic en:

File>Print Session Window

El resultado se ilustra en la figura 2-1.

7. Los siguientes comandos le permitirán a usted desarrollar un histograma, un diagrama de puntos y un diagrama de caja:

Graph>Histogram
Graph>Dotplot
Graph>Boxplot

Las instrucciones de cómo usar Minitab para correr los análisis de correlación y regresión se presentan al final del capítulo 6.

Aplicaciones de Excel

El problema. En el problema 1, Dick Hoover, propietario de Modern Office Equipment, está preocupado acerca de los costos de flete y de administración en que se incurre cuando los pedidos son pequeños.

Soluciones de Excel

1. Abra el programa Excel y aparecerá la pantalla de hoja de cálculo de la figura 1-2. Mueva el cursor a la celda A1 resaltada en la esquina superior izquierda de la hoja de cálculo.




FIGURA 2-22 Hoja de cálculo de Excel para el problema 1

- Introduzca el primer valor, 10, seguido por la tecla return (enter), luego introduzca el siguiente valor de los datos, y así sucesivamente.
- Después de que se hayan tecleado los 28 valores de datos en la columna A, se coloca el cursor en la celda donde se desean colocar los resultados del primer cálculo, A30.
- El promedio de los datos de las celdas A1 a A28 se calcula tecleando la fórmula en A30. Para introducir una fórmula, el signo = (igual) debe ir antes de ella. La fórmula es `= Average(A1:A28)`. *Nota:* Se muestra A30 a la izquierda de la barra de la fórmula e `= Average(A1:A28)` arriba a la derecha de la hoja de cálculo.
- El mismo enfoque se utiliza para calcular la desviación estándar. La fórmula `= Stdev(A1:A28)` se introduce en la celda A31. Los resultados se muestran en la figura 2-22.

También se pueden calcular el promedio y la desviación estándar usando la función Insert o la herramienta Data Analysis. Estos enfoques se estudiarán en capítulos posteriores.

Las instrucciones de cómo usar Excel para correr los análisis de correlación y de regresión se presentan al final del capítulo 6.

Si usted usa Minitab o Excel, se le sugiere que intente diferentes conjuntos de datos y rutinas estadísticas, para familiarizarse con estos poderosos programas. La habilidad que obtenga será muy útil cuando aprenda acerca de los procedimientos para elaboración de pronósticos en este texto.

Referencias

Anderson, D. R., D. J. Sweeney y T. A. Williams.

Essentials of Modern Business Statistics, 3a. ed.

Belmont, Calif.: Thomson/South-Western, 2007.

Keller, G. *Statistics for Management and Economics*, 7a

ed. Belmont, Calif.: Thomson/South-Western, 2005.

Moore, D. S., G. P. McCabe, W. M. Duckworth y S. L.

Sclove, *The Practice of Business Statistics*. Nueva

York: Freeman, 2003.

EXPLORACIÓN DE PATRONES DE DATOS E INTRODUCCIÓN A LAS TÉCNICAS DE PRONÓSTICOS

Una de las partes más difícil y que más tiempo consume en la elaboración de pronósticos es la recopilación de datos válidos y confiables. El personal de procesamiento de datos usa comúnmente la expresión “basura entra, basura sale”. Esta expresión también se aplica a la elaboración de pronósticos. Un pronóstico no puede ser tan preciso como los datos en que se basa. **El modelo de pronóstico más elaborado fallará si se aplica a datos poco confiables.**

El poder y la capacidad de las computadoras modernas han traído consigo la acumulación de una cantidad increíble de datos en casi todas las disciplinas. La difícil tarea a la que se enfrenta la mayoría de los pronosticadores es cómo obtener los datos adecuados que les ayuden a resolver sus problemas propios de toma de decisiones.

Para determinar qué datos serán útiles, se aplican cuatro criterios:

1. Los datos deben ser fidedignos y precisos. Se debe tener mucho cuidado en que los datos se obtengan de una fuente confiable, poniendo especial atención en la exactitud.
2. Los datos deberían ser relevantes. Los datos tienen que ser representativos de las circunstancias para las cuales se están usando.
3. Los datos tienen que ser consistentes. Cuando cambian las definiciones relacionadas con la recopilación de datos, se tienen que hacer los ajustes necesarios para conservar la consistencia en los patrones históricos. Esto quizá sea un problema, por ejemplo, cuando las dependencias gubernamentales cambian la miscelánea o la “canasta básica”, que se emplea al determinar el índice del costo de la vida. Hace varios años, las computadoras personales no formaban parte de la combinación de productos que compraban los consumidores; ahora sí lo son.
4. Los datos deberían ser oportunos. Los datos recopilados, resumidos y publicados oportunamente tendrán el mayor valor para el pronosticador. Puede haber muy pocos datos (una historia insuficiente sobre la cual apoyar resultados futuros) o demasiados datos (datos de periodos históricos irrelevantes lejanos en el pasado).

Generalmente, son dos los tipos de datos de interés para el pronosticador. El primer tipo son los datos recopilados en un periodo único, ya sea una hora, un día, una semana, un mes, o un trimestre. El segundo tipo son las observaciones de datos realizadas a través del tiempo. **Cuando todas las observaciones se hacen durante el mismo periodo, las llamamos datos de corte transversal.** El propósito es examinar esos datos y luego extrapolar o extender las relaciones identificadas a una población en general. Por ejemplo, la extracción de una muestra aleatoria de archivos del personal, para conocer la situación de los empleados de una compañía. La recopilación de datos sobre la antigüedad y el costo del mantenimiento de nueve autobuses de Spokane Transit Authority es otro. Un diagrama de dispersión, como el de la figura 3-1, nos ayuda a visualizar las relaciones y sugiere que la antigüedad podría ayudar en la elaboración del pronóstico del presupuesto anual de mantenimiento.