



CAPÍTULO 15

Regresión múltiple

CONTENIDO

LA ESTADÍSTICA
EN LA PRÁCTICA:
INTERNATIONAL PAPER

15.1 MODELO DE REGRESIÓN
MÚLTIPLE
Modelo de regresión y ecuación
de regresión
Ecuación de regresión múltiple
estimada

15.2 MÉTODO DE MÍNIMOS
CUADRADOS
Un ejemplo: Butler Trucking
Company
Nota sobre la interpretación de
los coeficientes

15.3 COEFICIENTE DE
DETERMINACIÓN MÚLTIPLE

15.4 SUPOSICIONES
DEL MODELO

15.5 PRUEBA DE
SIGNIFICANCIA
Prueba F
Prueba t
Multicolinealidad

15.6 USO DE LA ECUACIÓN
DE REGRESIÓN ESTIMADA
PARA ESTIMACIONES
Y PREDICCIONES

15.7 VARIABLES CUALITATIVAS
INDEPENDIENTES

Un ejemplo: Johnson Filtration
Inc.

Interpretación de los parámetros
Variables cualitativas más com-
plejas

15.8 ANÁLISIS RESIDUAL

Detección de observaciones
atípicas

Residuales estudentizados elimi-
nados y observaciones atípicas
Observaciones influyentes
Uso de la medida de la distancia
de Cook para identificar
observaciones influyentes

15.9 REGRESIÓN LOGÍSTICA

Ecuación de regresión logística
Estimación de la ecuación
de regresión logística
Prueba de significancia
Uso en la administración
Interpretación de la ecuación
de regresión logística
Transformación logit

LA ESTADÍSTICA en LA PRÁCTICA**INTERNATIONAL PAPER***

PURCHASE, NUEVA YORK

International Paper es la mayor empresa del mundo que se dedica a la producción de papel y productos forestales. Esta empresa da empleo a más de 117 000 personas en casi 50 países y exporta sus productos a más de 130 naciones. International Paper produce materiales de construcción como madera para construcción y madera de contrachapa; materiales de empaque como vasos y recipientes desechables; materiales para empaque industrial como cajas de cartón corrugado y embalaje de expedición, además de una gran variedad de papeles para fotocopadoras, impresoras, libros y material para publicidad.

En la fabricación de los productos de papel, se procesan virutas de madera y productos químicos en molinos de pulpa para obtener la pulpa de madera. Después, la pulpa de madera se emplea para producir los productos de papel. Para los productos de papel blanco, es necesario blanquear la pulpa con objeto de eliminar cualquier alteración cromática. El agente blanqueador esencial en este proceso es el dióxido de cloro, el cual, debido a su naturaleza combustible, suele producirse en un molino de pulpa, de donde, en forma de solución, es transportado a través de una tubería a la torre de blanqueo del molino de pulpa. Con objeto de mejorar uno de los procesos empleados en la producción del dióxido de cloro, se estudió el control y la eficiencia del proceso. Uno de los aspectos estudiados fue la velocidad de alimentación de las sustancias químicas que intervienen en la producción del dióxido de cloro.

En la producción del dióxido de cloro intervienen cuatro sustancias químicas que llegan, a velocidades controladas, al generador de dióxido de cloro. El dióxido de cloro producido en el generador se recibe en un absorbente, de donde el dióxido de cloro gaseoso es absorbido en agua helada formando una solución de dióxido de cloro. A continuación la solución pasa a un molino de papel. Parte esencial del control de este proceso es la velocidad de alimentación de las sustancias químicas. Antes, los operadores fijaban la velocidad de alimentación de las sustancias químicas, método que llevaba a un sobrecontrol del proceso. Debido a esto, los ingenieros químicos encargados del molino solicitaron que, como ayuda para fijar las velocidades de alimentación de estas sustancias, se obtuviera un



El análisis de regresión múltiple se empleó para obtener un mejor proceso de blanqueo en la fabricación de productos de papel blanco. © Lester Lefkowitz/Corbis.

conjunto de ecuaciones de control, una para la alimentación de cada una de las sustancias químicas.

Empleando el análisis de regresión múltiple, los analistas obtuvieron, para cada una de las cuatro sustancias químicas empleadas en el proceso, una ecuación de regresión múltiple estimada. Cada ecuación relaciona la producción de dióxido de cloro con la cantidad de la sustancia química empleada y con la concentración de la solución de dióxido de cloro. En cada uno de los molinos se programó en una microcomputadora el conjunto de las cuatro ecuaciones obtenidas. Con el nuevo sistema, los operadores ingresan al sistema la concentración de la solución de dióxido de cloro y la velocidad de producción deseadas; el paquete de software calcula la velocidad de alimentación de la sustancia química que permite obtener esa velocidad de producción deseada. Desde que los operadores empezaron a usar las ecuaciones de control, aumentó significativamente la eficiencia del generador de dióxido de cloro así como la cantidad de veces en las que la concentración de cloro caía dentro del rango aceptable.

Este ejemplo muestra el empleo del análisis de regresión múltiple en la obtención de mejores procesos de blanqueo para producir productos de papel blanco. En este capítulo se verá el uso de los paquetes de software para tales propósitos. La mayor parte de los conceptos presentados en el capítulo 14, para la regresión lineal simple, pueden extenderse a la regresión múltiple.

* Los autores agradecen a Mariam Williams y Hill Griggs por proporcionar este artículo para *La estadística en la práctica*. Esta aplicación fue elaborada por Champion International Corporation, empresa que en 2000 se volvió parte de International Paper.

En el capítulo 14 se presentó la regresión lineal simple y se mostró su uso en la obtención de una ecuación de regresión estimada que describe la relación entre dos variables. Recuérdese que la variable que se predice o explica es la variable dependiente y la variable que se usa para predecir o explicar la variable dependiente es la variable independiente. En este capítulo se continúa con el estudio del análisis de regresión considerando, ahora, las situaciones en las que intervienen dos o más variables independientes. Este estudio, al que se le conoce como **análisis de regresión múltiple**, permite tomar más factores en consideración y obtener estimaciones mejores que las que son posibles con la regresión lineal simple.

15.1

Modelo de regresión múltiple

El análisis de regresión múltiple estudia la relación de una variable dependiente con dos o más variables independientes. Para denotar el número de variables independientes se suele usar p .

Modelo de regresión y ecuación de regresión

Los conceptos de modelo de regresión y ecuación de regresión vistos en el capítulo previo, son aplicables en el caso de la regresión múltiple. A la ecuación que describe cómo está relacionada la variable dependiente y con las variables independientes $x_1, x_2, \dots, x_p$ se le conoce como **modelo de regresión múltiple**. Se supone que el modelo de regresión múltiple toma la forma siguiente

MODELO DE REGRESIÓN MÚLTIPLE

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \epsilon \quad (15.1)$$

En el modelo de regresión múltiple, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, son parámetros y el término del error ϵ (la letra griega épsilon) es una variable aleatoria. Examinando con atención este modelo se ve que y es una función lineal de $x_1, x_2, \dots, x_p$ (la parte $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$) más el término del error ϵ . El término del error corresponde a la variabilidad en y que no puede atribuirse o explicarse al efecto lineal de las p variables independientes.

En la sección 15.4 se discutirán los supuestos para el modelo de regresión múltiple y para ϵ . Uno de los supuestos es que la media o valor esperado de ϵ es cero. Una consecuencia de este supuesto es que la media o valor esperado de y , que se denota $E(y)$, es igual a $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$. A la ecuación que describe cómo está relacionada la media de y con $x_1, x_2, \dots, x_p$ se le conoce como **ecuación de regresión múltiple**.

ECUACIÓN DE REGRESIÓN MÚLTIPLE

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \quad (15.2)$$

Ecuación de regresión múltiple estimada

Si se conocieran los valores de $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, se podría usar la ecuación (15.2) para calcular la media de las y para valores dados de $x_1, x_2, \dots, x_p$. Desafortunadamente, los valores de estos parámetros no suelen conocerse, es necesario estimarlos a partir de datos muestrales. Para calcular los valores de los estadísticos muestrales $b_1, b_2, \dots, b_p$, que se usan como estimadores puntuales de los parámetros $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ se emplea una muestra aleatoria simple. Con los estadísticos muestrales se obtiene la siguiente **ecuación de regresión múltiple estimada**.

ECUACIÓN DE REGRESIÓN MÚLTIPLE ESTIMADA

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \cdots + b_px_p \quad (15.3)$$

donde

$b_0, b_1, b_2, \dots, b_p$ son las estimaciones de $\beta_0, \beta_1, \beta_2, \dots, \beta_p$
 $\hat{y}$ = valor estimado de la variable dependiente

Este proceso de estimación en la regresión múltiple se muestra en la figura 15.1.

15.2

Método de mínimos cuadrados


En el capítulo 14, se usó el **método de mínimos cuadrados** para obtener la ecuación de regresión estimada que permitía aproximar mejor la relación lineal entre las variables dependiente e independiente. Este método también se usa para obtener la ecuación de regresión múltiple estimada. El criterio en el método de mínimos cuadrados, como ya se dijo, es el siguiente.

CRITERIO DE MÍNIMOS CUADRADOS

$$\min \sum (y_i - \hat{y}_i)^2 \quad (15.4)$$

FIGURA 15.1 PROCESO DE ESTIMACIÓN EN LA REGRESIÓN MÚLTIPLE

En la regresión lineal simple, b_0 y b_1 son los estadísticos muestrales que se usan para estimar los parámetros β_0 y β_1 . En la regresión múltiple, en el proceso de inferencia estadística análogo, $b_0, b_1, b_2, \dots, b_p$ denotan los estadísticos muestrales que se usan para estimar los parámetros $\beta_0, \beta_1, \beta_2, \dots, \beta_p$.



donde

y_i = valor observado en la variable dependiente en la observación i

$\hat{y}_i$ = valor estimado para la variable dependiente en la observación i

Los valores estimados de la variable dependiente se calculan empleando la ecuación de regresión múltiple estimada

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \cdots + b_px_p$$

Como indica la expresión (15.4), el método de mínimos cuadrados emplea datos muestrales para obtener los valores de $b_0, b_1, b_2, \dots, b_p$ que hacen que la suma de los cuadrados de los residuales [las diferencias entre los valores observados de la variable dependiente (y_i) y los valores estimados de la variable dependiente ($\hat{y}_i$)] sea un mínimo.

En el capítulo 14 se dieron las fórmulas para calcular los estimadores b_0 y b_1 para la ecuación de regresión lineal simple estimada $\hat{y} = b_0 + b_1x$ empleando el método de mínimos cuadrados. Con conjuntos de datos relativamente pequeños, fue posible usar esas fórmulas para obtener b_0 y b_1 mediante cálculos manuales. En la regresión múltiple, en cambio, las fórmulas para calcular $b_0, b_1, b_2, \dots, b_p$ emplean álgebra de matrices y quedan fuera del alcance de este texto. Por esta razón, en el estudio de la regresión múltiple, se centrará la atención en el uso de los paquetes de software para obtener la ecuación de regresión estimada y algunas otras informaciones. Lo importante será la interpretación de los resultados que proporcionan estos paquetes de software y no cómo hacer los cálculos para la regresión múltiple.


Un ejemplo: Butler Trucking Company

Para ilustrar el análisis de regresión múltiple, se empleará un problema de la empresa Butler Trucking Company, una empresa que se dedica al transporte de objetos y mercancías en el sur de California. La actividad principal de esta empresa es hacer entregas en su área local. Para mejorar el horario de trabajo, los gerentes deseaban estimar el tiempo total de recorrido diario necesario para hacer las entregas.

Al principio, los gerentes creyeron que el tiempo total de recorrido diario estaba estrechamente relacionado con el número de millas recorridas para hacer las entregas. Partiendo de una muestra aleatoria simple de 10 entregas se obtuvieron los datos que se presentan en la tabla 15.1 y en el diagrama de dispersión de la figura 15.2. Después de observar el diagrama de dispersión, los gerentes consideraron que para describir la relación entre tiempo total de recorrido (y_i) y el número de millas recorridas (x_i) podía emplearse el modelo de regresión lineal simple

TABLA 15.1 DATOS PRELIMINARES DE BUTLER TRUCKING

Recorrido	x_1 = Millas recorridas	y = Tiempo de recorrido (horas)
1	100	9.3
2	50	4.8
3	100	8.9
4	100	6.5
5	50	4.2
6	80	6.2
7	75	7.4
8	65	6.0
9	90	7.6
10	90	6.1

FIGURA 15.2 DIAGRAMA DE DISPERSIÓN DE LOS DATOS PRELIMINARES DE BUTLER TRUCKING

$y = \beta_0 + \beta_1 x_1 + \epsilon$. Para estimar los parámetros β_0 y β_1 , se empleó el método de mínimos cuadrados obteniéndose la ecuación de regresión estimada

$$\hat{y} = b_0 + b_1 x_1 \quad (15.5)$$

En la figura 15.3 se presentan los resultados obtenidos con Minitab aplicando la regresión lineal simple a los datos de la tabla 15.1. La ecuación de regresión estimada es

$$\hat{y} = 1.27 + 0.0678x_1$$

Empleando como nivel de significancia 0.05, el valor- p correspondiente a F de 15.81, es 0.004; esto indica que la relación es significativa, es decir, que se puede rechazar $H_0: \beta_1 = 0$ debido a que el valor- p es menor a $\alpha = 0.05$. Obsérvese que empleando el valor t , 3.98, y su valor- p correspondiente, 0.004, se llega a la misma conclusión. Por lo tanto, se puede concluir que la relación entre el tiempo total de recorrido y el número de millas recorridas es significativa; recorridos de más duración corresponden a cantidades mayores de millas recorridas. Como el coeficiente de correlación (expresado como porcentaje) es $R\text{-sq} = 66.4\%$, se ve que 66.4% de la variabilidad en el tiempo de recorrido se puede explicar por el efecto lineal del número de millas recorridas. Este descubrimiento es bastante satisfactorio, sin embargo, los gerentes desearían considerar otra variable independiente más para explicar parte de la variabilidad restante de la variable dependiente.

Al tratar de encontrar otra variable independiente los gerentes encontraron que el número de entregas podía contribuir también a la duración total del recorrido. En la tabla 15.2 se presentan los datos de Butler Trucking después de agregar el número de entregas. En la figura 15.4 se presenta el resultado que da Minitab al considerar como variables independientes, tanto el número de millas recorridas (x_1) como el número de entregas (x_2) realizadas. La ecuación de regresión estimada es

$$\hat{y} = -0.869 + 0.0611x_1 + 0.923x_2 \quad (15.6)$$

FIGURA 15.3 RESULTADOS DE MINITAB PARA EL PROBLEMA DE BUTLER TRUCKING CON UNA VARIABLE INDEPENDIENTE

Los nombres de las variables Miles (millas) y Time (tiempo) que aparecen en los resultados de Minitab fueron ingresados en la hoja de cálculo como encabezados de las columnas correspondientes; por lo tanto, x_1 = Miles y y = Time.

The regression equation is
Time = 1.27 + 0.0678 Miles

Predictor	Coef	SE Coef	T	p
Constant	1.274	1.401	0.91	0.390
Miles	0.06783	0.01706	3.98	0.004

S = 1.002 R-sq = 66.4% R-sq(adj) = 62.2%

Analysis of Variance

SOURCE	DF	SS	MS	F	p
Regression	1	15.871	15.871	15.81	0.004
Residual Error	8	8.029	1.004		
Total	9	23.900			

En la sección siguiente se verá el uso del coeficiente de determinación múltiple para medir la bondad de ajuste de esta ecuación de regresión. Pero, antes, se examinarán con más detenimiento los valores $b_1 = 0.0611$ y $b_2 = 0.923$ de la ecuación (15.6).

Nota sobre la interpretación de los coeficientes

En este punto es útil hacer una observación sobre la relación entre la ecuación de regresión estimada en la que la única variable independiente es el número de millas recorridas y la ecuación en la que, como segunda variable independiente, se incluye el número de entregas. El valor de b_1 no es igual en ambos casos. En la regresión lineal simple, b_1 se interpreta como una estimación del cambio en y debido al cambio en una unidad de la variable independiente. En el análisis de regresión múltiple, esta interpretación cambia ligeramente. Es decir, en el análisis de regresión múltiple, cada uno de los coeficientes de regresión se interpreta como sigue: b_i representa la estimación del cambio en y debido a un cambio en una unidad en x_i mientras todas las demás variables independientes permanecen constantes. En el ejemplo de Butler Trucking con dos variables independientes, $b_1 = 0.0611$. Por lo tanto, 0.0611 horas es la estimación del aumen-

TABLA 15.2 DATOS DE BUTLER TRUCKING CON MILLAS RECORRIDAS (x_1) Y CANTIDAD DE ENTREGAS (x_2) COMO VARIABLES INDEPENDIENTES

Recorrido asignado	x_1 = Millas recorridas	x_2 = Cantidad de entregas	y = Tiempo de recorrido (horas)
1	100	4	9.3
2	50	3	4.8
3	100	4	8.9
4	100	2	6.5
5	50	2	4.2
6	80	2	6.2
7	75	3	7.4
8	65	4	6.0
9	90	3	7.6
10	90	2	6.1

FIGURA 15.4 RESULTADOS DE MINITAB PARA EL PROBLEMA DE BUTLER TRUCKING CON DOS VARIABLES INDEPENDIENTES

Los nombres de las variables Miles (millas), Deliveries (entregas) y Time (tiempo) que aparecen en los resultados de Minitab fueron ingresados en la hoja de cálculo como encabezados de las columnas; por lo tanto, x_1 = Miles, x_2 = Deliveries y y = Time.

The regression equation is

$$\text{Time} = -0.869 + 0.0611 \text{ Miles} + 0.923 \text{ Deliveries}$$

Predictor	Coef	SE Coef	T	p
Constant	-0.8687	0.9515	-0.91	0.392
Miles	0.061135	0.009888	6.18	0.000
Deliveries	0.9234	0.2211	4.18	0.004

S = 0.5731 R-sq = 90.4% R-sq(adj) = 87.6%

Analysis of Variance

SOURCE	DF	SS	MS	F	p
Regression	2	21.601	10.800	32.88	0.000
Residual Error	7	2.299	0.328		
Total	9	23.900			

to esperado en el tiempo de recorrido que corresponde al aumento en una milla en la distancia recorrida cuando el número de entregas permanece constante. De manera similar, como $b_2 = 0.923$, una estimación del aumento esperado en el tiempo de recorrido que corresponde al aumento de una entrega permaneciendo constante el número de millas recorridas es 0.923 horas.

Ejercicios

Nota a los estudiantes: Los ejercicios de esta sección y de las secciones siguientes en los que se dan datos están pensados para ser resueltos empleando un paquete de software.

Métodos

1. A continuación se da la ecuación de regresión estimada obtenida a partir de 10 observaciones para un modelo con dos variables independientes.

$$\hat{y} = 29.1270 + 0.5906x_1 + 0.4980x_2$$

- a. Interprete los coeficientes b_1 y b_2 de esta ecuación de regresión estimada.
 - b. Estime y para $x_1 = 180$ y $x_2 = 310$.
2. Considérense los datos siguientes que corresponden a la variable dependiente y y a las dos variables independientes x_1 y x_2 .

Autoexamen

archivo
en CD
Exer2

x_1	x_2	y
30	12	94
47	10	108
25	17	112
51	16	178
40	5	94
51	19	175
74	7	170

(continúa)

x_1	x_2	y
36	12	117
59	13	142
76	16	211

- Obtenga una ecuación de regresión estimada que relacione y con x_1 . Estime y si $x_1 = 45$.
 - Obtenga una ecuación de regresión estimada que relacione y con x_2 . Estime y si $x_2 = 15$.
 - Obtenga una ecuación de regresión estimada que relacione y con x_1 y x_2 . Estime y si $x_1 = 45$ y $x_2 = 15$.
3. En un análisis de regresión se emplean 30 observaciones y se obtiene la siguiente ecuación de regresión estimada.

$$\hat{y} = 17.6 + 3.8x_1 - 2.3x_2 + 7.6x_3 + 2.7x_4$$

- Interprete los coeficientes b_1 , b_2 , b_3 y b_4 de esta ecuación de regresión.
- Estime y para $x_1 = 10$, $x_2 = 5$, $x_3 = 1$ y $x_4 = 2$.

Aplicaciones

4. Para una zapatería se obtiene la siguiente ecuación de regresión estimada en la que se relacionan las ventas con la inversión en inventario y los gastos en publicidad.

$$\hat{y} = 25 + 10x_1 + 8x_2$$

donde

x_1 = inversión en inventario (en miles de \$)

x_2 = gasto en publicidad (en miles de \$)

y = ventas (en miles de \$)

- Estime las ventas si la inversión en inventario es de \$15 000 y el presupuesto para publicidad es de \$10 000.
 - Interprete b_1 y b_2 en esta ecuación de regresión estimada.
5. El dueño de Showtime Movie Theater, Inc., desea estimar el ingreso bruto semanal en función de los gastos en publicidad. A continuación se presentan los datos históricos de 10 semanas.

Autoexamen



Ingreso semanal bruto (en miles de \$)	Publicidad en televisión (en miles de \$)	Publicidad en periódicos (en miles de \$)
96	5.0	1.5
90	2.0	2.0
95	4.0	1.5
92	2.5	2.5
95	3.0	3.3
94	3.5	2.3
94	2.5	4.2
94	3.0	2.5

- Obtenga una ecuación de regresión estimada en la que el monto gastado en publicidad en televisión sea la variable independiente.
- Obtenga una ecuación de regresión estimada en la que los montos gastados en publicidad en televisión y en periódicos sean las variables independientes.
- ¿Es el coeficiente correspondiente a los gastos de publicidad en televisión de la ecuación de regresión estimada del inciso a) igual al del inciso b)? Interprete este coeficiente en cada caso.

- d. ¿Cuál es el ingreso semanal bruto en una semana en la que se gastan \$3500 en publicidad en televisión y \$1800 en publicidad en periódicos?
6. En el béisbol, el éxito de un equipo se suele considerar en función del desempeño en bateo y en lanzamiento del equipo. Una medida del desempeño en el bateo es la cantidad de cuadrangulares que anota el equipo y una medida del desempeño en lanzamiento es el promedio de carreras ganadas por el equipo que lanza. En general, se cree que los equipos que anotan más cuadrangulares (home run) y tienen un promedio menor de carreras ganadas ganan un mayor porcentaje de juegos. Los datos siguientes pertenecen a 16 equipos que participaron en la temporada de la Liga Mayor de Béisbol de 2003; se da la proporción de juegos ganados, la cantidad de cuadrangulares del equipo (HR, por sus siglas en inglés) y el promedio de carreras ganadas (ERA, por sus siglas en inglés) (www.usatoday.com, 17 de enero de 2004).



Equipo	Proporción de ganados	HR	ERA	Equipo	Proporción de ganados	HR	ERA
Arizona	0.519	152	3.857	Milwaukee	0.420	196	5.058
Atlanta	0.623	235	4.106	Montreal	0.512	144	4.027
Chicago	0.543	172	3.842	Nueva York	0.410	124	4.517
Cincinnati	0.426	182	5.127	Philadelphia	0.531	166	4.072
Colorado	0.457	198	5.269	Pittsburgh	0.463	163	4.664
Florida	0.562	157	4.059	San Diego	0.395	128	4.904
Houston	0.537	191	3.880	San Francisco	0.621	180	3.734
Los Ángeles	0.525	124	3.162	St. Louis	0.525	196	4.642

- a. Obtenga la ecuación de regresión estimada para predecir la proporción de juegos ganados en función de la cantidad de cuadrangulares.
- b. Obtenga la ecuación de regresión estimada para predecir la proporción de juegos ganados en función del promedio de carreras ganadas por los miembros del equipo que lanza.
- c. Obtenga la ecuación de regresión estimada para predecir la proporción de juegos ganados en función de la cantidad de cuadrangulares y del promedio de carreras ganadas por los miembros del equipo que lanza.
- d. En la temporada de 2003, San Diego ganó sólo el 39.5% de sus juegos, siendo el más bajo de la liga nacional. Para mejorar para el año siguiente, el equipo trató de adquirir nuevos jugadores que hicieran que la cantidad de cuadrangulares aumentara a 180 y que el promedio de carreras ganadas por el equipo que lanza disminuyera a 4.0. Use la ecuación de regresión estimada obtenida en el inciso c) para estimar el porcentaje de juegos que ganaría San Diego si tuviera 180 cuadrangulares y su promedio de carreras ganadas fuera 4.0.
7. Los diseñadores de mochilas usan materiales exóticos como supernailon Derlin, polietileno de alta densidad, aluminio para aviones o espumas termo-moldeadas para hacer que las mochilas sean más confortables y que el peso se distribuya uniformemente eliminándose así los puntos de mayor presión. En los datos siguientes se proporciona capacidad (en pulgadas cúbicas), evaluación del confort, y precio de 10 mochilas probadas por *Outside Magazine*. El confort está medido con una escala del 1 al 5, en la que 1 denota un confort mínimo y 5 un confort excelente. (*Outside Buyer's Guide*, 2001).



Fabricante y modelo	Capacidad	Confort	Precio
Camp Trails Paragon II	4330	2	\$190
EMS 5500	5500	3	219
Lowe Alpomayo 90+20	5500	4	249
Marmot Muir	4700	3	249
Kelly Bigfoot 5200	5200	4	250
Gregory Whitney	5500	4	340
Osprey 75	4700	4	389
Arc'Teryx Bora 95	5500	5	395
Dana Design Terraplane LTW	5800	5	439
The Works @ Mystery Ranch Jazz	5000	5	525

- a. Obtenga la ecuación de regresión estimada que permita predecir el precio de una mochila, dada su capacidad y la evaluación de su confort.
 - b. Interprete b_1 y b_2 .
 - c. Diga cuál será el precio de una mochila cuya capacidad sea 4500 pulgadas cúbicas y la evaluación de su confort sea 4.
8. En la tabla siguiente se da el rendimiento anual, la evaluación de la seguridad (0 = de alto riesgo, 10 segura) y el coeficiente de gastos anuales de 20 fondos extranjeros (*Mutual Funds*, marzo de 2000).



	Evaluación de seguridad	Coefficiente de gastos anuales (%)	Rendimiento anual (%)
Accessor Int'l Equity "Adv"	7.1	1.59	49
Aetna "I" International	7.2	1.35	52
Amer Century Int'l Discovery "Inv"	6.8	1.68	89
Columbia International Stock	7.1	1.56	58
Concert Inv "A" Int'l Equity	6.2	2.16	131
Dreyfus Founders Int'l Equity "F"	7.4	1.80	59
Driehaus International Growth	6.5	1.88	99
Excelsior "Inst" Int'l Equity	7.0	0.90	53
Julius Baer International Equity	6.9	1.79	77
Marshall International Stock "Y"	7.2	1.49	54
MassMutual Int'l Equity "S"	7.1	1.05	57
Morgan Grenfell Int'l Sm Cap "Inst"	7.7	1.25	61
New England "A" Int'l Equity	7.0	1.83	88
Pilgrim Int'l Small Cap "A"	7.0	1.94	122
Republic International Equity	7.2	1.09	71
Sit International Growth	6.9	1.50	51
Smith Barney "A" Int'l Equity	7.0	1.28	60
State St Research "S" Int'l Equity	7.1	1.65	50
Strong International Stock	6.5	1.61	93
Vontobel International Equity	7.0	1.50	47

- a. Obtenga la ecuación de regresión estimada que relaciona el rendimiento anual con la evaluación de la seguridad y con el coeficiente de gastos anuales.
 - b. Estime el rendimiento anual de una empresa cuya evaluación de seguridad es 7.5 y el coeficiente de gastos anuales es 2.
9. El ski acuático y el wakeboarding son dos deportes acuáticos muy actuales. Ya sea que se trate de ski acuático, de wakeboarding o de navegación, hallar el modelo que mejor se ajuste a las necesidades, puede no ser una tarea sencilla. La revista *Water Ski* probó 88 lanchas y proporcionó una amplia información como ayuda para los consumidores. A continuación se presenta una parte de los datos que publicaron sobre 20 lanchas de 20 y 22 pies longitud (*Water Ski*, enero/febrero 2006). La manga es el ancho máximo de la lancha (en pulgadas), HP son los caballos de fuerza del motor y velocidad máxima es la velocidad máxima que alcanza la lancha, en millas por hora.



Fabricante y modelo	Manga	HP	Velocidad máxima
Calabria Cal Air Pro V-2	100	330	45.3
Correct Craft Air Nautique 210	91	330	47.3
Correct Craft Air Nautique SV-211	93	375	46.9
Correct Craft Ski Nautique 206 Limited	91	330	46.7
Gekko GTR 22	96	375	50.1
Gekko GTS 20	83	375	52.2
Malibu Response LXi	93.5	340	47.2
Malibu Sunsetter LXi	98	400	46
Malibu Sunsetter 21 XTi	98	340	44

Fabricante y modelo	Manga	HP	Velocidad máxima
Malibu Sunscape 21 LSV	98	400	47.5
Malibu Wakesetter 21 XT _i	98	340	44.9
Malibu Wakesetter VLX	98	400	47.3
Malibu vRide	93.5	340	44.5
Malibu Ride XT _i	93.5	320	44.5
Mastercraft ProStar 209	96	350	42.5
Mastercraft X-1	90	310	45.8
Mastercraft X-2	94	310	42.8
Mastercraft X-9	96	350	43.2
MB Sports 190 Plus	92	330	45.3
Svfara SVONE	91	330	47.7

- Empleando estos datos obtenga la ecuación de regresión estimada que relaciona la velocidad máxima con la manga y los caballos de fuerza de la lancha.
 - La Sv fara SV 609 tiene una manga de 85 pulgadas y motor de 330 caballos de fuerza. Utilice la ecuación de regresión estimada obtenida en el inciso a) para estimar la velocidad máxima de la Sv fara SV609.
10. La Nacional Basketball Association (NBA) lleva un registro de diversos datos estadísticos de cada equipo. Cuatro de estos datos estadísticos son la proporción de juegos ganados (PCT), la proporción de anotaciones de campo (FG%), la proporción de tiros de tres puntos hechos por el equipo contrario (Opp 3 Pt%) y la cantidad de recuperaciones hechas por el equipo contrario (Opp TO). Los siguientes datos muestran los valores de estas estadísticas para los 29 equipos de la NBA en una fracción de la temporada 2004 (www.nba.com, enero 3, 2004)



Equipo	PCT	FG%	Opp 3 Pt%	Opp TO	Equipo	PCT	FG%	Opp 3 Pt%	Opp TO
Atlanta	0.265	0.435	0.346	13.206	Minnesota	0.677	0.473	0.348	13.839
Boston	0.471	0.449	0.369	16.176	Nueva Jersey	0.563	0.435	0.338	17.063
Chicago	0.313	0.417	0.372	15.031	Nueva Orleans	0.636	0.421	0.330	16.909
Cleveland	0.303	0.438	0.345	12.515	Neuva York	0.412	0.442	0.330	13.588
Dallas	0.581	0.439	0.332	15.000	Orlando	0.242	0.417	0.360	14.242
Denver	0.606	0.431	0.366	17.818	Philadelphia	0.438	0.428	0.364	16.938
Detroit	0.606	0.423	0.262	15.788	Phoenix	0.364	0.438	0.326	16.515
Golden State	0.452	0.445	0.384	14.290	Portland	0.484	0.447	0.367	12.548
Houston	0.548	0.426	0.324	13.161	Sacramento	0.724	0.466	0.327	15.207
Indiana	0.706	0.428	0.317	15.647	San Antonio	0.688	0.429	0.293	15.344
L.A. Clippers	0.464	0.424	0.326	14.357	Seattle	0.533	0.436	0.350	16.767
L.A. Lakers	0.724	0.465	0.323	16.000	Toronto	0.516	0.424	0.314	14.129
Memphis	0.485	0.432	0.358	17.848	Utah	0.531	0.456	0.368	15.469
Miami	0.424	0.410	0.369	14.970	Washington	0.300	0.411	0.341	16.133
Milwaukee	0.500	0.438	0.349	14.750					

- Obtenga una ecuación de regresión estimada que sirva para predecir la proporción de juegos ganados dada la proporción de anotaciones de campo del equipo.
- Interprete la pendiente de la ecuación de regresión estimada obtenida en el inciso a).
- Obtenga una ecuación de regresión estimada que sirva para predecir la proporción de juegos ganados dada la proporción de anotaciones de campo del equipo, la proporción de tiros de tres puntos hechos por el equipo contrario y la proporción de recuperaciones hechas por el equipo contrario.
- Analice las implicaciones prácticas de la ecuación de regresión estimada obtenida en el inciso c).
- Estime la proporción de juegos ganados por un equipo para el que los valores de las tres variables independientes son: $FG\% = 0.45$, $Opp\ 3\ Pt\% = 0.34$ y $Opp\ TO = 17$.

15.3

Coeficiente de determinación múltiple

En la regresión lineal simple se mostró que la suma de cuadrados se podía dividir o particionar en dos componentes: la suma de cuadrados debida a la regresión y la suma de cuadrados debida al error. Esto también aplica a la suma de cuadrados de la regresión múltiple.

RELACIÓN ENTRE STC, SCR Y SCE

$$STC = SCR + SCE \quad (15.7)$$

donde

$$STC = \text{suma total de cuadrados} = \sum (y_i - \bar{y})^2$$

$$SCR = \text{suma de cuadrados debida a la regresión} = \sum (\hat{y}_i - \bar{y})^2$$

$$SCE = \text{suma de cuadrados debida al error} = \sum (y_i - \hat{y}_i)^2$$

Debido a lo complejo de los cálculos de estas tres sumas de cuadrados, es necesario emplear un paquete de software para realizarlos. En los resultados de Minitab que se muestran en la figura 15.4, en la parte del análisis de varianza se presentan estos tres valores para el problema de Butler Trucking con dos variables independientes: $STC = 23\,900$, $SCR = 21.601$ y $SCE = 2.299$. Cuando se emplea una sola variable independiente (número de millas recorridas) en los resultados de Minitab de la figura 15.3 se observa que $STC = 23\,900$, $SCR = 15.871$ y $SCE = 8.029$. El valor de la STC es el mismo en ambos casos debido a que este valor no depende de $\hat{y}$, pero al agregar otra variable (el número de entregas), SCR aumenta y SCE disminuye. Esto tiene como consecuencia que la ecuación de regresión estimada tenga un mejor ajuste a los datos observados.

En el capítulo 14, se empleó el coeficiente de determinación, $r^2 = SCR/STC$, para medir la bondad de ajuste de la ecuación de regresión estimada. El mismo concepto es válido en la regresión múltiple. El término **coeficiente de determinación múltiple** indica que mide la bondad de ajuste de la ecuación de regresión múltiple estimada. El coeficiente de determinación múltiple, que se denota R^2 , se calcula como sigue.

COEFICIENTE DE DETERMINACIÓN MÚLTIPLE

$$R^2 = \frac{SCR}{STC} \quad (15.8)$$

El coeficiente de determinación múltiple puede interpretarse como la proporción de la variabilidad en la variable dependiente que es explicada por la ecuación de regresión estimada. Por lo tanto, el producto de este coeficiente por 100, se interpreta como el porcentaje de la variabilidad en y que es explicada por la ecuación de regresión estimada.

Cuando se emplean dos variables independientes en el ejemplo de Butler Truckin, como $SCR = 21.601$ y $STC = 23.900$, se tiene

$$R^2 = \frac{21.601}{23.900} = 0.904$$

Por lo tanto, 90.4% de la variabilidad en el tiempo de recorrido y es explicada por la ecuación de regresión estimada en la que las variables independientes son las millas recorridas y el número de entregas. En la figura 15.4 se observa que en el resultado proporcionado por Minitab aparece también el coeficiente de determinación múltiple, que se denota $R\text{-sq} = 90.4\%$

Al aumentar el número de variables independientes los errores de predicción se hacen más pequeños, con lo que se reduce la suma de cuadrados debida al error, SCE. Como $SCR = STC - SCE$, cuando SCE se reduce, SCR aumenta, lo que ocasiona que $R^2 = SCR/STC$ aumente.

Cuando se agrega una variable al modelo, R^2 se vuelve más grande, aun cuando la variable agregada no sea estadísticamente significativa. El coeficiente de determinación múltiple ajustado compensa el número de variables independientes en el modelo.

En la figura 15.3 el valor de R-sq para la ecuación de regresión estimada con una sola variable, número de millas recorridas (x_1), es 66.4%. Por lo tanto, al agregar el número de entregas como una variable independiente más, el porcentaje de variabilidad en el tiempo de recorrido, explicado por la ecuación de regresión estimada, aumenta de 66.4% a 90.4%. En general, siempre que se agrega una variable independiente al modelo, R^2 aumenta.

Muchos analistas prefieren ajustar R^2 al número de variables independientes para evitar sobreestimar el efecto que tiene agregar una variable independiente sobre la cantidad de la variabilidad explicada por la ecuación de regresión estimada. Siendo n el número de observaciones y p el número de variables independientes, el **coeficiente de determinación ajustado** se calcula como sigue.

COEFICIENTE DE DETERMINACIÓN MÚLTIPLE AJUSTADO

$$R_a^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} \quad (15.9)$$

En el ejemplo de Butler Trucking, como $n = 10$ y $p = 2$, se tiene

$$R_a^2 = 1 - (1 - 0.904) \frac{10 - 1}{10 - 2 - 1} = 0.88$$

Por lo tanto, una vez que el coeficiente de determinación se ha ajustado a dos variables independientes, su valor es 0.88. En los resultados de Minitab de la figura 15.4 este valor se presenta como $R\text{-sq}(\text{adj}) = 87.6\%$; la diferencia con el valor calculado arriba se debe a que en los cálculos de arriba se empleó un valor redondeado de R^2 .

NOTAS Y COMENTARIOS

Si el valor de R^2 es pequeño y el número de variables independientes en el modelo es grande, el coeficiente de determinación ajustado puede ser

negativo; en tales casos, Minitab da, como coeficiente de determinación ajustado, cero.

Ejercicios

Métodos

- En el ejercicio 1 se presentó la siguiente ecuación de regresión estimada basada en 10 Observaciones.

$$\hat{y} = 29.1270 + 0.5906x_1 + 0.4980x_2$$

Los valores de STC y SCR son 6724.125 y 6216.375, respectivamente.

- Halle SCE.
 - Calcule R^2 .
 - Calcule R_a^2 .
 - Analice la bondad de ajuste.
- En el ejercicio 2, se presentaron 10 observaciones dando los valores de la variable dependiente y de dos variables independientes x_1 y x_2 ; con estos datos $STC = 15\ 182.9$ y $SCR = 14\ 052.2$.
 - Calcule R^2 .
 - Calcule R_a^2 .
 - ¿Explica la ecuación de regresión estimada una proporción grande de la variabilidad de los datos? Explique.

13. En el ejercicio 3 se presentó la siguiente ecuación de regresión estimada basada en 30 Observaciones.

$$\hat{y} = 17.6 + 3.8x_1 - 2.3x_2 + 7.6x_3 + 2.7x_4$$

Los valores de STC y SCR son 1805 y 1760, respectivamente.

- Calcule R^2 .
- Calcule R_a^2 .
- Analice la bondad de ajuste.

Aplicaciones

14. En el ejercicio 4, se dio la siguiente ecuación de regresión estimada, la cual relacionaba las ventas con la inversión en inventario y los gastos de publicidad.

$$\hat{y} = 25 + 10x_1 + 8x_2$$

Los datos empleados para desarrollar este modelo eran los datos de 10 tiendas; con estos datos STC = 16 000 y SCR = 12 000.

- Calcule R^2 para la ecuación de regresión estimada.
- Calcule R_a^2 .
- ¿Parece explicar este modelo una gran cantidad de la variabilidad de los datos? Explique.

15. En el ejercicio 5, el propietario de Showtime Movie Theater, Inc. empleó el análisis de regresión múltiple para predecir el ingreso bruto (y) en función de la publicidad en televisión (x_1) y de la publicidad en los periódicos (x_2). La ecuación de regresión estimada fue

$$\hat{y} = 83.2 + 2.29x_1 + 1.30x_2$$

La solución obtenida con un paquete de software proporcionó STC = 25.2 y SCR = 23.435.

- Calcule e interprete R^2 y R_a^2 .
- Cuando la publicidad en televisión era la variable independiente, $R^2 = 0.653$ y $R_a^2 = 0.595$. ¿Prefiere los resultados de la regresión múltiple? Explique.

16. En el ejercicio 6 se presentaron los datos siguientes de 16 equipos de la Liga mayor de béisbol de 2003: proporción de juegos ganados, cantidad de cuadrangulares anotados por el equipo y promedio de carreras ganadas por el equipo que lanza (<http://www.usatoday.com>, 7 de enero de 2004).

- ¿Proporciona un buen ajuste la ecuación de regresión estimada que para predecir la proporción de juegos ganados tiene como única variable independiente la cantidad de cuadrangulares? Explique.
- Analice la ventaja de usar tanto la cantidad de cuadrangulares como el promedio de carreras ganadas para predecir la proporción de juegos ganados.

17. En el ejercicio 9 se obtuvo una ecuación de regresión estimada que relacionaba la velocidad máxima de una lancha con la manga y los caballos de fuerza de la lancha.

- Calcule e interprete R^2 y R_a^2 .
- ¿Proporciona esta ecuación de regresión estimada un buen ajuste? Explique.

18. Vuelva al ejercicio 10, en el que se presentaron varios datos estadísticos de 29 equipos de la Nacional Basketball Association en parte de la temporada de 2004 (www.nba.com, 3 de enero de 2004).

- En el inciso c) del ejercicio 10, se obtuvo una ecuación de regresión estimada que proporcionaba la proporción de juegos ganados dado el porcentaje de anotaciones de campo hechas por el equipo, la proporción de tiros de tres puntos hechas por el equipo contrario y la cantidad de recuperaciones (turnover) hechas por el equipo contrario. ¿Cuáles son los valores de R^2 y R_a^2 ?
- ¿Proporciona esta ecuación de regresión estimada un buen ajuste a los datos?

Autoexamen



15.4

Suposiciones del modelo

En la sección 15.1 se presentó el siguiente modelo de regresión múltiple.

MODELO DE REGRESIÓN MÚLTIPLE

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \epsilon \quad (15.10)$$

Las suposiciones acerca del término del error ϵ en el modelo de regresión múltiple son análogas a las suposiciones en el modelo de regresión lineal simple.

SUPOSICIONES SOBRE EL TÉRMINO DEL ERROR ϵ EN EL MODELO DE REGRESIÓN MÚLTIPLE $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \epsilon$

1. El término del error ϵ es una variable aleatoria cuya media o valor esperado es cero, es decir, $E(\epsilon) = 0$.

Consecuencia: Para valores dados de $x_1, x_2, \dots, x_p$, el valor esperado o valor promedio de y está dado por

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p. \quad (15.11)$$

La ecuación (15.11) es la ecuación de regresión múltiple presentada en la sección 15.1. En esta ecuación, $E(y)$ representa el promedio de todos los valores que puede tomar y para valores dados de $x_1, x_2, \dots, x_p$.

2. La varianza de ϵ se denota σ^2 y es la misma para todos los valores de las variables independientes $x_1, x_2, \dots, x_p$.

Consecuencia: La varianza de y respecto a la línea de regresión es σ^2 y es la misma para todos los valores de $x_1, x_2, \dots, x_p$.

3. Los valores de ϵ son independientes.

Consecuencia: El valor de ϵ para un determinado conjunto de valores de las variables independientes no está relacionado con el valor de ϵ de ningún otro conjunto de valores.

4. El término del error ϵ es una variable aleatoria distribuida normalmente y que refleja la desviación entre el valor de y y el valor esperado de y dado por $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$.


Consecuencia: Como $\beta_0, \beta_1, \dots, \beta_p$ son constantes para los valores dados de $x_1, x_2, \dots, x_p$, la variable dependiente y es también una variable aleatoria distribuida normalmente.

Para entender mejor la forma de la relación dada por la ecuación 15.11, considérese la siguiente ecuación de regresión múltiple con dos variables independientes.

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

La gráfica de esta ecuación es un plano en el espacio tridimensional. La figura 15.5 es un ejemplo de gráfica de este tipo. Obsérvese que, como se indica, el valor de ϵ es la diferencia entre el verdadero valor de y y el valor esperado de y , $E(y)$, cuando $x_1 = x_1^*$ y $x_2 = x_2^*$.

FIGURA 15.5 GRÁFICA DE LA ECUACIÓN DE REGRESIÓN EMPLEADA EN EL ANÁLISIS DE REGRESIÓN CON DOS VARIABLES INDEPENDIENTES



En el análisis de regresión, suele emplearse del término *variable de respuesta* en lugar del término *variable dependiente*. Además, como la ecuación de regresión múltiple genera un plano o superficie, a su gráfica se le llama superficie de respuesta.

15.5

Prueba de significancia

En esta sección se muestra cómo realizar una prueba de significancia para una relación de regresión múltiple. Las pruebas de significancia que se usaron en la regresión lineal simple fueron la prueba t y la prueba F . En la regresión lineal simple, estas dos pruebas llevan a la misma conclusión; es decir, si se rechaza la hipótesis nula, se concluye que $b_1 \neq 0$. En la regresión múltiple, la prueba t y la prueba F tienen propósitos diferentes.

1. La prueba F se usa para determinar si existe una relación de significancia entre la variable dependiente y el conjunto de todas las variables independientes; a esta prueba F se le llama prueba de *significancia global*.
2. Si la prueba F indica que hay significancia global, se usa la prueba t para ver si cada una de las variables individuales es significativa. Para cada una de las variables independientes del modelo se realiza una prueba t . A cada una de estas pruebas t se le conoce como prueba de *significancia individual*.

A continuación se explican la prueba F y la prueba t y se aplican al ejemplo de Butler Trucking.

Prueba F

El modelo de regresión múltiple que se definió en la sección 15.4 es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \epsilon$$

La hipótesis de la prueba F comprende los parámetros del modelo de regresión múltiple.

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

$$H_a: \text{Uno o más de los parámetros es distinto de cero}$$

Cuando se rechaza H_0 , la prueba proporciona evidencia estadística suficiente para concluir que uno o más de los parámetros no es igual a cero y que la relación global entre y y el conjunto de variables independientes $x_1, x_2, \dots, x_p$ es significativa. En cambio, si no se puede rechazar H_0 , no se tiene evidencia suficiente para concluir que exista una relación significativa.

Antes de describir los pasos de la prueba F , es necesario revisar el concepto de *cuadrado medio*. Un cuadrado medio es una suma de cuadrados dividida entre sus correspondientes grados de libertad. En el caso de la regresión múltiple, la suma de cuadrados del total tiene $n - 1$ grados de libertad, la suma de cuadrados debida a la regresión (SCR) tiene p grados de libertad y la suma de cuadrados debida al error tiene $n - p - 1$ grados de libertad. Por tanto, el cuadrado medio debido a la regresión (CMR) es SCR/p y el cuadrado medio debido al error (CME) es $SCE/(n - p - 1)$.

$$CMR = \frac{SCR}{p} \quad (15.12)$$

y

$$CME = \frac{SCE}{n - p - 1} \quad (15.13)$$

Como se vio en el capítulo 14, CME proporciona una estimación insesgada de σ^2 , la varianza del término del error ϵ . Si $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$ es verdadera, CMR también proporciona un estimador insesgado de σ^2 y el valor de CMR/CME será cercano a 1. Pero, si H_0 es falsa, el CMR sobreestima σ^2 y el valor de CMR/CME será mayor. Para determinar qué tan grande debe ser CMR/CME para que se rechace H_0 , se hace uso del hecho de que si H_0 es verdadera y las suposiciones acerca del modelo de regresión múltiple son válidas, la distribución muestral de CMR/CME es una distribución F con p grados de libertad en el numerador y $n - p - 1$ en el denominador. A continuación se presenta un resumen de la prueba F de significancia para la regresión múltiple.

PRUEBA F DE SIGNIFICANCIA GLOBAL

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

H_a : Uno o más de los parámetros no son iguales a cero.

ESTADÍSTICO DE PRUEBA

$$F = \frac{CMR}{CME} \quad (15.14)$$

REGLA DE RECHAZO

Valor aproximado p : Rechazar H_0 si valor $p \leq \alpha$

Valor crítico aproximado: Rechazar H_0 si $F \geq F_\alpha$

donde F_α pertenece a la distribución F con p grados de libertad en el numerador y $n - p - 1$ grados de libertad en el denominador.

A continuación se presenta la aplicación de la prueba F al problema de regresión múltiple de la empresa Butler Trucking. Como se tienen dos variables independientes, las hipótesis se expresan como sigue.

$$H_0: \beta_1 = \beta_2 = 0$$

H_a : β_1 o β_2 no es igual a cero

FIGURA 15.6 RESULTADOS DE MINITAB PARA EL EJEMPLO DE BUTLER TRUCKING CON DOS VARIABLES INDEPENDIENTES, MILLAS RECORRIDAS (x_1) Y NÚMERO DE ENTREGAS (x_2)

The regression equation is

Time = - 0.869 + 0.0611 Miles + 0.923 Deliveries

Predictor	Coef	SE Coef	T	p
Constant	-0.8687	0.9515	-0.91	0.392
Miles	0.061135	0.009888	6.18	0.000
Deliveries	0.9234	0.2211	4.18	0.004

S = 0.5731 R-sq = 90.4% R-sq(adj) = 87.6%

Analysis of Variance

SOURCE	DF	SS	MS	F	p
Regression	2	21.601	10.800	32.88	0.000
Residual Error	7	2.299	0.328		
Total	9	23.900			

En la figura 15.6 se presentan los resultados que da Minitab para el modelo de regresión múltiple con dos variables independientes, millas recorridas (x_1) y número de entregas (x_2). En la parte de los resultados que corresponde al análisis de varianza, se ve que $CMR = 10.8$ y $CME = 0.328$. Empleando la ecuación (15.14) se obtiene el valor del estadístico de prueba.

$$F = \frac{10.8}{0.328} = 32.9$$

Obsérvese que el valor de F en los resultados de Minitab es $F = 32.88$; este valor difiere del calculado aquí debido a que aquí en los cálculos se emplearon los valores redondeados de CMR y CME . Usando $\alpha = 0.01$, el valor- $p = 0.000$ que aparece en la última columna de la tabla del análisis de varianza (figura 15.6) indica que se puede rechazar $H_0: \beta_1 = \beta_2 = 0$ debido a que el valor- p es menor a 0.01. De manera alternativa, en la tabla 4 del apéndice B se observa que con dos grados de libertad en el numerador y siete grados de libertad en el denominador, $F_{0.01} = 9.55$. Como $32.9 > 9.55$, se rechaza $H_0: \beta_1 = \beta_2 = 0$ y se concluye que existe una relación significativa entre el tiempo de recorrido y las dos variables independientes, millas recorridas y número de entregas.

Como ya se indicó, el error cuadrado medio proporciona un estimador insesgado de σ^2 , la varianza del término del error ϵ . Observando la figura 15.6 se ve que la estimación de σ^2 es $CME = 0.328$. La raíz cuadrada del CME es la estimación de la desviación estándar del término del error. Como se definió en la sección 14.5, esta desviación estándar es el error estándar de estimación, que se denota s . Por tanto, se tiene que $s = \sqrt{CME} = \sqrt{0.328} = 0.573$. Observe que este valor del error estándar de estimación aparece en los resultados de Minitab que se muestran en la figura 15.6.

La tabla 15.3 es la tabla general para el análisis de varianza (ANOVA) que proporciona los resultados de la prueba F para un modelo de regresión múltiple. El valor del estadístico de prueba F aparece en la última columna y debe compararse con F_α con p grados de libertad en el numerador y $n - p - 1$ grados de libertad en el denominador, para obtener la conclusión de la prueba de hipótesis. Revisando los resultados de Minitab para el ejemplo de Butler Trucker Company de la figura 15.6 se ve que la tabla del análisis de varianza contiene esta información. Además, Minitab proporciona también el correspondiente valor- p para el estadístico de prueba F .

TABLA 15.3 TABLA ANOVA PARA EL MODELO DE REGRESIÓN MÚLTIPLE CON p VARIABLES INDEPENDIENTES

Fuente	Suma de cuadrados	Grados de libertad	Cuadrado medio	F
Regresión	SCR	p	$CMR = \frac{SCR}{p}$	$F = \frac{CMR}{CME}$
Error	SCE	$n - p - 1$	$CME = \frac{SCE}{n - p - 1}$	
Total	STC	$n - 1$		

Prueba t

Si la prueba F indica que la relación de regresión múltiple es significativa, se puede realizar una prueba t para determinar la significancia de cada uno de los parámetros. A continuación se presenta la prueba t de significancia para cada uno de los parámetros.

PRUEBA t DE SIGNIFICANCIA PARA CADA UNO DE LOS PARÁMETROS

Para cualquier parámetro β_i

$$H_0: \beta_i = 0$$

$$H_a: \beta_i \neq 0$$

ESTADÍSTICO DE PRUEBA

$$t = \frac{b_i}{s_{b_i}} \quad (15.15)$$

REGLA DE RECHAZO

Método del valor- p : Rechazar H_0 si valor- $p \leq \alpha$

Método del valor crítico: Rechazar H_0 si $t \leq -t_{\alpha/2}$ o si $t \geq t_{\alpha/2}$

donde $t_{\alpha/2}$ es un valor de la distribución t con $n - p - 1$ grados de libertad.

En el estadístico de prueba, s_{b_i} es la estimación de la desviación estándar de b_i . El paquete de software proporciona el valor de s_{b_i} .

A continuación se realiza la prueba t utilizando el problema de regresión de Butler Trucking. Consúltese la sección de la figura 15.6 en la que se dan los resultados de Minitab para el cálculo del cociente t . Los valores de b_1 , s_{b_1} , b_2 y s_{b_2} , son los siguientes

$$b_1 = 0.061135 \quad s_{b_1} = 0.009888$$

$$b_2 = 0.9234 \quad s_{b_2} = 0.2211$$

Usando la ecuación (15.15), se obtienen los estadísticos de prueba para las hipótesis en que intervienen β_1 y β_2

$$t = 0.061135/0.009888 = 6.18$$

$$t = 0.9234/0.2211 = 4.18$$

Obsérvese que los valores de estos dos cocientes t y sus correspondientes valores- p aparecen en los resultados de Minitab de la figura 15.6. Usando, $\alpha = 0.01$, los valores- p 0.000 y 0.004 que aparecen en los resultados de Minitab indican que se pueden rechazar $H_0: \beta_1 = 0$ y $H_0: \beta_2 = 0$. Por lo tanto, ambos parámetros son estadísticamente significativos. También, en la tabla 2 del apéndice B se encuentra que para $n - p - 1 = 10 - 2 - 1 = 7$ grados de libertad, $t_{0.005} = 3.499$. Como $6.18 > 3.499$, se rechaza $H_0: \beta_1 = 0$. De manera similar, como $4.18 > 3.499$, se rechaza $H_0: \beta_2 = 0$.

Multicolinealidad

En el análisis de regresión el término *variable independiente* se usa para referirse a cualquier variable que se usa para predecir o explicar el valor de la variable dependiente. Sin embargo, este término no significa que estas variables independientes sean independientes entre ellas, en sentido estadístico. Al contrario, en un problema de regresión múltiple, la mayoría de las variables independientes están, en cierto grado, correlacionadas unas con otras. En el ejemplo de Butler Trucking con dos variables independientes x_1 (millas recorridas) y x_2 (número de entregas), las millas recorridas pueden tratarse como la variable dependiente y el número de entregas como la variable independiente para determinar si estas dos variables están relacionadas entre sí. Después puede calcularse el coeficiente de correlación muestral $r_{x_1x_2}$ para determinar la magnitud de la relación entre estas dos variables. Al hacer esto se obtiene $r_{x_1x_2} = 0.16$. Por lo tanto, se encuentra que existe cierto grado de relación lineal entre estas dos variables independientes. En el análisis de regresión múltiple **multicolinealidad** se refiere a la correlación entre las variables independientes.

Para tener una mejor visión de los problemas potenciales de la multicolinealidad, se considerará una modificación al ejemplo de Butler Trucking. En lugar de que x_2 sea el número de entregas, sea x_2 el número de galones de gasolina consumidos. Es claro que x_1 (las millas recorridas) y x_2 están relacionadas, es decir, se sabe que el número de galones de gasolina consumidos depende del número de millas recorridas. Por lo tanto, se concluirá que x_1 y x_2 son variables independientes fuertemente correlacionadas.

Supóngase que se obtiene la ecuación $\hat{y} = b_0 + b_1x_1 + b_2x_2$ y que se encuentra que la prueba F indica que esta relación es significativa. Después supóngase que se realiza la prueba t para β_1 para determinar si $\beta_1 \neq 0$ y no puede rechazarse $H_0: \beta_1 = 0$. ¿Significa esto que el tiempo de recorrido no esté relacionado con las millas recorridas? No necesariamente. Lo que probablemente significa es que estando x_2 en el modelo, x_1 no tiene una contribución significativa en la determinación del valor de y . En el presente ejemplo, esta interpretación parece razonable; conociendo la cantidad de gasolina consumida, no se gana mucha más información para la predicción de y al conocer el número de millas recorridas. De manera similar, una prueba t puede llevar a la conclusión de que $\beta_2 = 0$ con base en que, cuando está x_1 en el modelo, al saber la cantidad de gasolina consumida, no se gana mucho.

Resumiendo, en las pruebas t para la significancia de cada uno de los parámetros, la dificultad ocasionada por la multicolinealidad hace posible concluir que ninguno de los parámetros es significativamente distinto de cero cuando la prueba F sobre la ecuación de regresión múltiple general indica que hay una relación significativa. Este problema se evita cuando existe poca correlación entre las variables independientes.

Para determinar si la multicolinealidad es lo suficientemente alta para ocasionar problemas se han desarrollado diversas pruebas. De acuerdo con la prueba de la regla práctica, la multicolinealidad es un problema potencial si el valor absoluto del coeficiente de correlación muestral es mayor a 0.7 para cualquier par de variables independientes. Otros tipos de pruebas son más avanzadas y quedan fuera del alcance de este libro.

Siempre que sea posible, debe evitarse incluir variables independientes que estén fuertemente correlacionadas. Sin embargo, en la práctica, la estricta adherencia a esta conducta no suele ser posible. Cuando las personas que toman las decisiones tienen razones para creer que existe una multicolinealidad importante, se darán cuenta de que es difícil separar los efectos de cada una de las variables independientes sobre la variable dependiente.

Una regla práctica que previene de potenciales problemas de multicolinealidad es que el coeficiente de correlación muestral sea mayor a + 0.7 o menor a - 0.7

Cuando las variables independientes están fuertemente correlacionadas, es imposible determinar el efecto, por separado, de cada una de las variables independientes sobre la variable dependiente.

NOTAS Y COMENTARIOS

Por lo general, la multicolinealidad no afecta la manera en que se realiza el análisis de regresión o en que se interpretan los resultados de un estudio. Pero, si la multicolinealidad es severa se pueden tener dificultades al interpretar los resultados de las pruebas t acerca de cada uno de los parámetros. Además del tipo de problemas ilustrados en esta sección, se ha demostrado que los casos severos de multicolinealidad dan como resultado estimaciones por mínimos cuadrados con signo erróneo. Esto es, en estudios simulados en los que los in-

vestigadores crearon el modelo de regresión subyacente y después emplearon el método de mínimos cuadrados para obtener estimaciones de β_0 , β_1 , β_2 , etc., se ha demostrado que en condiciones de fuerte multicolinealidad, las estimaciones obtenidas por mínimos cuadrados pueden tener signo opuesto al del parámetro que se estima. Por ejemplo, β_2 puede ser en realidad $+10$ y su estimación b_2 puede resultar ser -2 . Por lo tanto, si existe una fuerte multicolinealidad podrá tenerse poca confianza en los coeficientes.

Ejercicios

Métodos

Autoexamen

19. En el ejercicio 1 se presentó la siguiente ecuación de regresión estimada basada en 10 observaciones.

$$\hat{y} = 29.1270 + 0.5906x_1 + 0.4980x_2$$

Aquí $STC = 6724.125$, $SCR = 6216.375$, $s_{b_1} = 0.0813$ y $s_{b_2} = 0.0567$.

- Calcule CMR y CME
 - Calcule F y realice la prueba F adecuada. Use $\alpha = 0.05$.
 - Realice una prueba t para la significancia de b_1 . Use $\alpha = 0.05$.
 - Realice una prueba t para la significancia de b_2 . Use $\alpha = 0.05$.
20. Consulte los datos presentados en el ejercicio 2. La ecuación de regresión estimada de estos datos es

$$\hat{y} = -18.4 + 2.01x_1 + 4.74x_2$$

Aquí $STC = 15\ 182$, $SCR = 14\ 052$, $s_{b_1} = 0.2471$.

- Realice una prueba para ver si hay una relación significativa entre x_1 , x_2 y y . Use $\alpha = 0.05$.
 - ¿Es significativo β_1 ? Use $\alpha = 0.05$.
 - ¿Es significativo β_2 ? Use $\alpha = 0.05$.
21. Se obtuvo la ecuación de regresión estimada siguiente para un modelo con dos variables independientes.

$$\hat{y} = 40.7 + 8.63x_1 + 2.71x_2$$

Después de eliminar x_2 del modelo, se empleó el método de mínimos cuadrados para obtener una ecuación de regresión estimada con una sola variable independiente, x_1 .

$$\hat{y} = 42.0 + 9.01x_1$$

- Dé la interpretación del coeficiente de x_1 en ambos modelos.
- ¿Podría explicar la multicolinealidad por qué el coeficiente de x_1 es diferente en los dos modelos? Si es así, ¿cómo?

Aplicaciones

22. En el ejercicio 4 se dio la siguiente ecuación de regresión estimada que relacionaba las ventas con la inversión en inventario y los gastos de publicidad.

$$\hat{y} = 25 + 10x_1 + 8x_2$$

Los datos empleados para obtener el modelo provinieron de un estudio realizado a 10 tiendas; para estos datos $STC = 16\,000$ y $SCR = 12\,000$.

- Calcule SCE, CME y CMR.
 - Use la prueba F y 0.05 como nivel de significancia para determinar si existe una relación entre las variables.
23. Véase el ejercicio 5.
- Use $\alpha = 0.01$ para probar las hipótesis

$$H_0: \beta_1 = \beta_2 = 0$$

$$H_a: \beta_1 \text{ o } \beta_2 \text{ no son iguales a cero}$$

En el modelo $y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \epsilon$, donde

x_1 = publicidad en televisión (en miles de dólares)

x_2 = publicidad en periódicos (en miles de dólares)

- Use $\alpha = 0.05$ para probar la significancia de β_1 ¿Debe x_1 ser eliminada del modelo?
 - Use $\alpha = 0.05$ para probar la significancia de β_2 ¿Debe x_2 ser eliminada del modelo?
24. Véanse los datos del ejercicio 6. Emplee la cantidad de cuadrangulares del equipo y el promedio de carreras ganadas por el equipo que lanza para predecir la proporción de juegos ganados.
- Use la prueba F para determinar la significancia global de la relación. ¿Cuál es la conclusión empleando 0.05 como nivel de significancia?
 - Use la prueba t para determinar la significancia de cada una de las variables independientes. ¿Cuál es la conclusión empleando 0.05 como nivel de significancia?
25. *Borron's* realiza revisiones anuales de los corredores de bolsa en línea, en la que se incluyen tanto corredores a los que se les puede contactar vía un explorador de Internet, así como corredores que tienen acceso directo y que ponen al cliente en contacto directo con el servidor de una red de corredores de bolsa. La oferta y el desempeño de cada corredor se evalúa en seis áreas, empleando para cada área una escala de 0 a 5. Los resultados se ponderan para obtener una evaluación general y a cada corredor se le asigna una evaluación final que va de cero a cinco estrellas. Tres de las áreas evaluadas son ejecución de la operación, facilidad de uso y gama de ofertas. Un 5 en ejecución de la operación significa que la llegada del pedido y el proceso de ejecución fluyó con facilidad de un paso a otro. En facilidad de uso, 5 significa que el sitio es de fácil uso y que se puede ajustar para ver lo que le interesa al usuario ver. Un 5 en gama de ofertas significa que todas las transacciones pueden realizarse en línea. En los datos siguientes se presentan las puntuaciones obtenidas en ejecución de la operación, facilidad de uso y gama de ofertas y el número de estrellas obtenidas por los integrantes de una muestra de 10 corredores de bolsa (*Barron's*, 10 de marzo de 2003).

Corredor	Ejecución de la operación	Uso	Gama	Estrellas
Wall St. Access	3.7	4.5	4.8	4.0
E*TRADE (Power)	3.4	3.0	4.2	3.5
E*TRADE (Standard)	2.5	4.0	4.0	3.5
Preferred Trade	4.8	3.7	3.4	3.5
my Track	4.0	3.5	3.2	3.5
TD Waterhouse	3.0	3.0	4.6	3.5
Brown & Co.	2.7	2.5	3.3	3.0
Brokerage America	1.7	3.5	3.1	3.0
Merrill Lynch Direct	2.2	2.7	3.0	2.5
Strong Funds	1.4	3.6	2.5	2.0

Autoexamen

archivo
en CD
MLB

archivo
en CD
Brokers



- a. Determine la ecuación de regresión estimada que se puede usar para predecir el número de estrellas dadas las evaluaciones a ejecución, facilidad de uso y gama de ofertas.
 - b. Emplee la prueba F para determinar la significancia global de la relación. Empleando como nivel de significancia 0.95, ¿cuál es la conclusión?
 - c. Emplee la prueba t para determinar la significancia de cada una de las variables independientes. Empleando como nivel de significancia 0.05, ¿cuál es la conclusión?
 - d. Elimine cualquiera de las variables independientes que no sea significativa para la ecuación de regresión estimada. ¿Cuál es la ecuación de regresión estimada que recomienda? Compare R^2 con el valor de R^2 para el inciso a). Analice las diferencias.
26. En el ejercicio 10 se obtuvo una ecuación de regresión estimada que da la proporción de juegos ganados cuando se conocía la proporción de anotaciones de campo hechas por el equipo, la proporción de tiros de tres puntos hechas por el equipo contrario y la cantidad de recuperaciones realizadas por el equipo contrario.
- a. Emplee la prueba F para determinar la significancia global de la relación. Empleando como nivel de significancia 0.05, ¿cuál es la conclusión?
 - b. Emplee la prueba t para determinar la significancia de cada una de las variables independientes. Empleando como nivel de significancia 0.05, ¿cuál es la conclusión?

15.6

Uso de la ecuación de regresión estimada para estimaciones y predicciones

Los procedimientos empleados en la regresión múltiple para estimar el valor medio de y y para predecir el valor de un solo valor de y son similares a los empleados en el análisis de regresión para una sola variable independiente. Recuerdese, primero, que en el capítulo 14 se mostró que la estimación puntual del valor esperado de y para un valor dado de x y la estimación puntual de un solo valor de y es la misma. En ambos casos se usó como estimación puntual $\hat{y} = b_0 + b_1x$.

En la regresión múltiple se emplea el mismo procedimiento, es decir, los valores dados de $x_1, x_2, \dots, x_p$ se sustituyen en la ecuación de regresión y como estimación puntual se emplea el correspondiente valor de $\hat{y}$. Supóngase que en el ejemplo de Butler Trucking se desea usar la ecuación de regresión estimada con x_1 (millas recorridas) y x_2 (número de entregas) para obtener dos estimaciones por intervalo:

1. Un *intervalo de confianza* para la media del tiempo de recorrido de todos los camiones que recorren 100 millas y hacen dos entregas.
2. Un *intervalo de predicción* para el tiempo de recorrido de un determinado camión que recorre 100 millas y hace dos entregas.

Utilizando la ecuación de regresión estimada $\hat{y} = -0.869 + 0.0611x_1 + 0.923x_2$ con $x_1 = 100$ y $x_2 = 2$, se obtiene

$$\hat{y} = -0.869 + 0.0611(100) + 0.923(2) = 7.09$$

Por lo tanto, en ambos casos, la estimación puntual del tiempo de recorrido es aproximadamente 7 horas.

Para obtener las estimaciones por intervalo para el valor medio de y y para un solo valor de y se emplean procedimientos similares a los empleados en el análisis de regresión con una sola variable. Las fórmulas que se necesitan quedan fuera del alcance de este libro, sin embargo, los paquetes de software para el análisis de regresión múltiple suelen proporcionar intervalos de confianza, una vez que los valores $x_1, x_2, \dots, x_p$ hayan sido especificados por el usuario. En la tabla 15.4 se presentan los intervalos de confianza y de predicción para algunos valores de x_1 y x_2 del ejemplo de Butler Trucking; estos valores se obtuvieron empleando Minitab. Obsérvese que las estimaciones por intervalo para un solo valor de y proporcionan valores más amplios que las estimaciones por intervalo para el valor esperado de y . Esta diferencia refleja simplemente el hecho de que dados los valores x_1 y x_2 , se puede estimar con mayor precisión el tiempo medio de recorrido de todos los camiones, que predecir el tiempo medio de recorrido de un determinado camión.

TABLA 15.4 INTERVALOS DE 95% DE CONFIANZA Y DE PREDICCIÓN PARA EL EJEMPLO DE BUTLER TRUCKING

Valor de x_1	Valor de x_2	Intervalo de confianza		Intervalo de predicción	
		Límite inferior	Límite superior	Límite inferior	Límite superior
50	2	3.146	4.924	2.414	5.656
50	3	4.127	5.789	3.368	6.548
50	4	4.815	6.948	4.157	7.607
100	2	6.258	7.926	5.500	8.683
100	3	7.385	8.645	6.520	9.510
100	4	8.135	9.742	7.362	10.515

Ejercicios

Métodos

27. En el ejercicio 1 se presentó la siguiente ecuación de regresión estimada basada en 10 observaciones.

$$\hat{y} = 29.1270 + 0.5906x_1 + 0.4980x_2$$

- Obtenga una estimación puntual del valor medio de y para $x_1 = 180$ y $x_2 = 310$.
- Obtenga una estimación puntual para un solo valor de y siendo $x_1 = 180$ y $x_2 = 310$.

28. Véanse los datos del ejercicio 2. La ecuación de regresión estimada para estos datos es

$$\hat{y} = -18.4 + 2.01x_1 + 4.74x_2$$

- Obtenga un intervalo de 95% de confianza para el valor medio de y cuando $x_1 = 45$ y $x_2 = 15$.
- Obtenga un intervalo de predicción de 95% para el valor de y cuando $x_1 = 45$ y $x_2 = 15$.

Aplicaciones

29. En el ejercicio 5, el propietario de Showtime Movie Theater, Inc. empleó el análisis de regresión múltiple para predecir el ingreso bruto (y) en función de la publicidad en televisión (x_1) y de la publicidad en periódicos (x_2). La ecuación de regresión estimada fue

$$\hat{y} = 83.2 + 2.29x_1 + 1.30x_2$$

- ¿Cuál será el ingreso bruto esperado en una semana en la que se gastan \$3500 en publicidad en televisión ($x_1 = 3.5$) y \$1800 en publicidad en periódicos ($x_2 = 1.8$)?
 - Dé un intervalo de 95% de confianza para el ingreso medio de todas las semanas en las que los gastos sean los indicados en el inciso a).
 - Dé un intervalo de predicción de 95% para la media del ingreso de una semana en las que los gastos sean los indicados en el inciso a).
30. En el ejercicio 9 se obtuvo una ecuación de regresión estimada que relacionaba la máxima velocidad de una lancha con su manga y sus caballos de fuerza.
- Dé un intervalo de 95% de confianza para la media de la velocidad máxima de una lancha cuya manga sea 85 y cuyo motor tenga 330 caballos de fuerza.

Autoexamen

Autoexamen

- b. La manga de la Sv fara SV 609 es de 85 pulgadas y su motor tiene 330 caballos de fuerza. Dé un intervalo de 95% de confianza para la media de la velocidad máxima de la Sv fara 609.
31. La sección “Guía para el usuario” del sitio en la Red de la revista *Car and Driver* proporciona información sobre pruebas viales (road test) de automóviles, camiones, SUV (acrónimo en inglés de Sport Utility Vehicle) y vans. Abajo se presentan las puntuaciones generales para calidad general, modelo de vehículo, frenado, manejo, economía de combustible, confort interior, aceleración, confiabilidad, ajuste y terminado, transmisión dadas a diversos vehículos empleando una escala del 1 (lo peor) a 10 (lo mejor). Aquí se presenta una parte de los datos de 14 automóviles Deportivos/GT (www.caranddriver.com, 7 de enero de 2004).



Deportivos/GT	General	Manejo	Confiabilidad	Ajuste y terminado
Acura 3.2CL	7.80	7.83	8.17	7.67
Acura RSX	9.02	9.46	9.35	8.97
Audi TT	9.00	9.58	8.74	9.38
BMW 3-Series/M3	8.39	9.52	8.39	8.55
Chevrolet Corvette	8.82	9.64	8.54	7.87
Ford Mustang	8.34	8.85	8.70	7.34
Honda Civic Si	8.92	9.31	9.50	7.93
Infiniti G35	8.70	9.34	8.96	8.07
Mazda RX-8	8.58	9.79	8.96	8.12
Mini Cooper	8.76	10.00	8.69	8.33
Mitsubishi Eclipse	8.17	8.95	8.25	7.36
Nissan 350Z	8.07	9.35	7.56	8.21
Porsche 911	9.55	9.91	8.86	9.55
Toyota Celica	8.77	9.29	9.04	7.97

- a. Dé una ecuación de regresión estimada usando manejo, confiabilidad, y ajuste y terminado para predecir la calidad general.
- b. Otro de los automóviles deportivos/GT evaluados por *Car and Driver* es el Honda Accord. Las evaluaciones de manejo, confiabilidad, y ajuste y terminado dadas a este automóvil fueron 8.28, 9.06 y 8.07, respectivamente. Estime la evaluación general dada a este automóvil.
- c. Dé un intervalo de 95% de confianza para la calidad general de todos los automóviles deportivos y GT con las características enumeradas en el inciso a).
- d. Dé un intervalo de predicción de 95% para la calidad general del Honda Accord descrito en el inciso b).
- e. La evaluación general dada por *Car and Driver* para el Honda Accord fue 8.65. Compare esta evaluación con las estimaciones obtenidas en los incisos b) y d).

15.7

Variables cualitativas independientes

Las variables independientes pueden ser cualitativas o cuantitativas.

En los ejemplos considerados hasta ahora, las variables han sido variables independientes cuantitativas como, por ejemplo, población de estudiantes, distancia recorrida y número de entregas. Sin embargo, en muchas situaciones, se tiene que trabajar con **variables independientes cualitativas** como género (masculino o femenino), modo de pago (efectivo, tarjeta de crédito, cheque), etc. En esta sección, el objetivo es mostrar cómo se emplean las variables cualitativas en el análisis de regresión. Para ilustrar el uso e interpretación de las variables independientes cualitativas se empleará un problema de Johnson Filtration, Inc.

Un ejemplo: Johnson Filtration, Inc.

Johnson Filtration Inc. da servicio de mantenimiento a los sistemas de filtración en el sur de Florida. Los clientes llaman a Johnson Filtration, Inc. solicitando un servicio de mantenimiento para sus sistemas de filtración de agua para estimar el tiempo que se requerirá para el servicio y el

TABLA 15.5 DATOS PARA EL EJEMPLO DE JOHNSON FILTRATION

Solicitud de servicio	Meses transcurridos desde el último servicio	Tipo de reparación	Tiempo en horas necesario para la reparación
1	2	eléctrico	2.9
2	6	mecánico	3.0
3	8	eléctrico	4.8
4	3	mecánico	1.8
5	2	eléctrico	2.9
6	7	eléctrico	4.9
7	9	mecánico	4.2
8	8	mecánico	4.8
9	4	eléctrico	4.4
10	6	eléctrico	4.5

costo del mismo, los administradores de Johnson desean poder predecir este tiempo para cada solicitud de servicio. Por lo tanto, el tiempo, en horas, requerido para la reparación es la variable dependiente. Se cree que el tiempo requerido para una reparación está relacionado con dos factores, meses transcurridos desde el último servicio de mantenimiento y tipo del problema (mecánico o eléctrico). En la tabla 15.5 se presentan los datos correspondientes a una muestra de 10 solicitudes de servicio.

Sea y el tiempo, en horas, necesario para la reparación y x_1 los meses transcurridos desde el último mantenimiento. El modelo de regresión en el que sólo se usa x_1 para predecir y es

$$y = \beta_0 + \beta_1 x_1 + \epsilon$$

Empleando Minitab para obtener la ecuación de regresión estimada se tienen los resultados que se presentan en la figura 15.7. La ecuación de regresión estimada es

$$\hat{y} = 2.15 + .304x_1 \quad (15.16)$$

Empleando como nivel de significancia 0.05, el valor- p para la prueba t (o F), que es 0.016, indica que los meses transcurridos desde el último mantenimiento están relacionados significativamente con el tiempo que se requiere para la reparación. $R\text{-sq} = 53.4\%$ indica que x_1 explica sólo el 53.4% de la variabilidad en el tiempo que se requiera para una reparación.

FIGURA 15.7 RESULTADOS DE MINITAB PARA EL PROBLEMA DE JOHNSON FILTRATION EMPLEANDO COMO VARIABLE INDEPENDIENTE (x_1) EL NÚMERO DE MESES DESDE EL ÚLTIMO SERVICIO

Los nombres de las variables Months (meses) y Time (tiempo) fueron ingresados en la hoja de cálculo como títulos de las columnas; por tanto, $x_1 = \text{Months}$ y $y = \text{Time}$.

The regression equation is
Time = 2.15 + 0.304 Months

Predictor	Coef	SE Coef	T	p
Constant	2.1473	0.6050	3.55	0.008
Months	0.3041	0.1004	3.03	0.016

S = 0.7810 R-sq = 53.4% R-sq(adj) = 47.6%

Analysis of Variance

SOURCE	DF	SS	MS	F	p
Regression	1	5.5960	5.5960	9.17	0.016
Residual Error	8	4.8800	0.6100		
Total	9	10.4760			

TABLA 15.6 DATOS PARA EL EJEMPLO DE JOHNSON FILTRATION INDICANDO EL TIPO DE REPARACIÓN POR MEDIO DE UNA VARIABLE FICTICIA ($x_2 = 0$ PARA FALLA MECÁNICA; $x_2 = 1$ PARA FALLA ELÉCTRICA)

Cliente	Meses transcurridos desde el último mantenimiento (x_1)	Tipo de reparación (x_2)	Tiempo en horas necesarias para la reparación (y)
1	2	1	2.9
2	6	0	3.0
3	8	1	4.8
4	3	0	1.8
5	2	1	2.9
6	7	1	4.9
7	9	0	4.2
8	8	0	4.8
9	4	1	4.4
10	6	1	4.5



Para incorporar en el modelo el tipo de reparación, se define la variable siguiente.

$$x_2 = \begin{cases} 0 & \text{si el tipo de reparación es mecánica} \\ 1 & \text{si el tipo de reparación es eléctrica} \end{cases}$$

En el análisis de regresión a x_2 se le llama **variable ficticia** o variable *indicadora*. Empleando esta variable ficticia, el modelo de regresión múltiple se expresa como sigue.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$$

En la tabla 15.6 se presentan los datos de la tabla 15.5, incluyendo los valores de la variable ficticia. Con Minitab y los datos de la tabla 15.6 se obtienen estimaciones para los parámetros del modelo. En el resultado de Minitab de la figura 15.8 se indica que la ecuación de regresión múltiple estimada es

$$\hat{y} = 0.93 + 0.388x_1 + 1.26x_2 \quad (15.17)$$

Empleando 0.05 como nivel de significancia, el valor- p correspondiente al estadístico de prueba F ($F = 21.36$) es 0.001, lo cual indica que la relación de regresión es significativa. En la figura 15.8, en la parte de los resultados de Minitab que corresponde a la prueba t , se observa que tanto meses transcurridos desde el último servicio (valor- $p = 0.000$) como tipo de reparación (valor- $p = 0.005$) son estadísticamente significativos. Además, $R\text{-sq} = 85.9\%$ y $R\text{-sq}(\text{adj}) = 81.9\%$ indican que la ecuación de regresión estimada explica adecuadamente la variabilidad en el tiempo necesitado para la reparación. Por lo tanto, la ecuación 15.17 sí es útil para estimar el tiempo necesario para la reparación de las diversas solicitudes de servicio.

Interpretación de los parámetros

La ecuación de regresión múltiple para el ejemplo de Johnson Filtration es

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \quad (15.18)$$

Para entender cómo interpretar los parámetros β_0 , β_1 , y β_2 , cuando hay una variable cualitativa, considérese el caso en que $x_2 = 0$ (reparación mecánica). Usando $E(y \mid \text{mecánica})$ para denotar la media o valor esperado del tiempo necesario para una reparación *dado* que se trata de una reparación mecánica, se tiene

$$E(y \mid \text{mecánica}) = \beta_0 + \beta_1 x_1 + \beta_2(0) = \beta_0 + \beta_1 x_1 \quad (15.19)$$

FIGURA 15.8 RESULTADOS DE MINITAB PARA EL EJEMPLO DE JOHNSON FILTRATION TENIENDO MESES DESDE EL ÚLTIMO SERVICIO (x_1) Y TIPO DE REPARACIÓN (x_2) COMO VARIABLES INDEPENDIENTES

Los nombres de las variables Months (meses) y Time (tiempo) que aparecen en los resultados de Minitab fueron ingresados en la hoja de cálculo de Minitab como títulos de las columnas; por tanto, $x_1 =$ Months, $x_2 =$ Type (tipo) y $y =$ Time.

The regression equation is

$$\text{Time} = 0.930 + 0.388 \text{ Months} + 1.26 \text{ Type}$$

Predictor	Coef	SE Coef	T	p
Constant	0.9305	0.4670	1.99	0.087
Months	0.38762	0.06257	6.20	0.000
Type	1.2627	0.3141	4.02	0.005

S = 0.4590 R-sq = 85.9% R-sq(adj) = 81.9%

Analysis of Variance

SOURCE	DF	SS	MS	F	p
Regression	2	9.0009	4.5005	21.36	0.001
Residual Error	7	1.4751	0.2107		
Total	9	10.4760			

De manera similar, en el caso de una reparación eléctrica ($x_2 = 1$), se tiene

$$\begin{aligned} E(y \mid \text{eléctrica}) &= \beta_0 + \beta_1 x_1 + \beta_2(1) = \beta_0 + \beta_1 x_1 + \beta_2 \\ &= (\beta_0 + \beta_2) + \beta_1 x_1 \end{aligned} \quad (15.20)$$

Comparando las ecuaciones (15.19) y (15.20) se ve que la media del tiempo requerido para hacer una reparación es función lineal de x_1 tanto cuando se trata de reparaciones mecánicas como de reparaciones eléctricas. La pendiente en ambas ecuaciones es β_1 , pero la intersección con el eje y varía. En la ecuación (15.19), para las reparaciones mecánicas, la intersección con el eje y es β_0 y en la ecuación (15.20), la ecuación para reparaciones eléctricas, la intersección es $(\beta_0 + \beta_2)$. La interpretación de β_2 es que indica la diferencia entre la media del tiempo que se requiere para una reparación eléctrica y la media del tiempo que se requiere para una reparación mecánica.

Si β_2 es positiva la media del tiempo necesario para una reparación eléctrica será mayor que para una reparación mecánica.; si β_2 es negativa la media del tiempo requerido para una reparación eléctrica será menor que para una reparación mecánica. Por último, si $\beta_2 = 0$, no hay diferencia entre las medias del tiempo que necesita para reparaciones eléctricas y mecánicas y el tipo de reparación no está relacionado con el tiempo necesario para hacer una reparación.

Empleando la ecuación de regresión múltiple estimada $\hat{y} = 0.93 + 0.388x_1 + 1.26x_2$, se ve que 0.93 es la estimación de β_0 y la estimación de β_2 es 1.26. Por lo tanto, cuando $x_2 = 0$ (reparación mecánica)


$$\hat{y} = 0.93 + 0.388x_1 \quad (15.21)$$

y cuando $x_2 = 1$ (reparación eléctrica)

$$\begin{aligned} \hat{y} &= 0.93 + 0.388x_1 + 1.2(1) \\ &= 2.19 + 0.388x_1 \end{aligned} \quad (15.22)$$

De esta manera, el uso de una variable ficticia proporciona dos ecuaciones que sirven para predecir el tiempo requerido para una reparación, una ecuación corresponde a las reparaciones me-

FIGURA 15.9 DIAGRAMA DE DISPERSIÓN



cánicas y la otra a las reparaciones eléctricas. Además, como $b_2 = 1.26$, se sabe que, en promedio, en las reparaciones eléctricas se necesitan 1.26 horas más que en las reparaciones mecánicas.

En la figura 15.9 se presenta una gráfica con los datos de la tabla 15.6. El tiempo de reparación, en horas, se ha representado en el eje vertical y los meses transcurridos desde el último servicio se han representado en el eje horizontal. Los puntos de la gráfica que corresponden a una reparación eléctrica se han indicado con una E y los que corresponden a una reparación mecánica con una M. En esta gráfica se han representado también las ecuaciones (15.21) y (15.22) con objeto de mostrar gráficamente las dos ecuaciones que sirven para predecir el tiempo que se requerirá para una reparación mecánica y para una reparación eléctrica.

Variables cualitativas más complejas

En el caso del ejemplo de Johnson Filtration, como la variable cualitativa tenía dos niveles (mecánico y eléctrico), fue fácil definirla empleando cero para indicar una reparación mecánica y uno para indicar una reparación eléctrica. Sin embargo, cuando una variable cualitativa tiene más de dos niveles, habrá que tener cuidado tanto al definir como al interpretar estas variables ficticias. Como se verá a continuación, si una variable ficticia tiene k niveles, se necesitan $k - 1$ variables ficticias, cada una de las cuales tomará el valor 0 o 1.

Supóngase, por ejemplo, que un fabricante de fotocopadoras divide un estado en tres regiones de ventas A, B y C. Sus gerentes desean emplear el análisis de regresión para predecir las ventas semanales. Empleando como variable dependiente el número de fotocopadoras vendidas, están considerando varias variables independientes (el número de vendedores, gastos en publicidad, etc.). Supóngase que los gerentes piensan que la región de ventas puede ser también un factor importante en la predicción del número de fotocopadoras vendidas. Como región es una

Para modelar una variable cualitativa que tenga k niveles se requieren $k - 1$ variables ficticias. Se debe ser cuidadoso al definir e interpretar variables ficticias.

variable cualitativa que tiene tres niveles, A, B y C, para representar la región de ventas se necesitarán $3 - 1 = 2$ variables ficticias. Cada variable tomará los valores 0 o 1.

$$x_1 = \begin{cases} 1 & \text{si la región de ventas es B} \\ 0 & \text{si no es así} \end{cases}$$

$$x_2 = \begin{cases} 1 & \text{si la región de ventas es C} \\ 0 & \text{si no es así} \end{cases}$$

De acuerdo con esta definición, para x_1 y x_2 se tienen los valores siguientes.

Región	x_1	x_2
A	0	0
B	1	0
C	0	1

En las observaciones correspondientes a la región A se tendrá $x_1 = 0, x_2 = 0$; en las observaciones correspondientes a la región B se tendrá $x_1 = 1, x_2 = 0$, y en las observaciones correspondientes a la región C se tendrá $x_1 = 0, x_2 = 1$.

La ecuación de regresión que relaciona el valor esperado del número de fotocopadoras vendidas $E(y)$, con las variables ficticias se expresa como sigue.

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Para interpretar los parámetros β_0 , β_1 , y β_2 , considérense las siguientes tres variaciones de la ecuación de regresión.

$$E(y \mid \text{región A}) = \beta_0 + \beta_1(0) + \beta_2(0) = \beta_0$$

$$E(y \mid \text{región B}) = \beta_0 + \beta_1(1) + \beta_2(0) = \beta_0 + \beta_1$$

$$E(y \mid \text{región C}) = \beta_0 + \beta_1(0) + \beta_2(1) = \beta_0 + \beta_2$$

Por lo tanto, β_0 , es la media o valor esperado de las ventas en la región A; β_1 es la diferencia entre la media del número de unidades vendidas en la región B y la media del número de unidades vendidas en la región A, y β_2 es la diferencia entre la media del número de unidades vendidas en la región C y la media del número de unidades vendidas en la región A.

Se necesitaron dos variables ficticias debido a que la región de ventas es una variable cualitativa que tiene tres niveles. Sin embargo, la asignación que se hizo al usar $x_1 = 0, x_2 = 0$ para identificar la región A, $x_1 = 1, x_2 = 0$ para identificar la región B y $x_1 = 0, x_2 = 1$ para identificar la región C fue arbitraria. De igual manera se podría haber elegido, por ejemplo, $x_1 = 1, x_2 = 0$ para identificar la región A, $x_1 = 0, x_2 = 0$ para identificar la región B y $x_1 = 0, x_2 = 1$ para identificar la región C. En ese caso, β_1 se habría interpretado como la media de la diferencia entre las regiones A y B, y β_2 como la media de la diferencia entre las regiones C y B.

Es importante recordar que en el análisis de regresión múltiple, cuando una variable cualitativa tiene k niveles, se requieren $k - 1$ variables ficticias. Entonces, si en el ejemplo de las regiones de ventas hubiera una cuarta región, D, se necesitarían tres variables ficticias. Por ejemplo las tres variables ficticias

$$x_1 = \begin{cases} 1 & \text{si la región es B} \\ 0 & \text{si no es así} \end{cases} \quad x_2 = \begin{cases} 1 & \text{si la región es C} \\ 0 & \text{si no es así} \end{cases} \quad x_3 = \begin{cases} 1 & \text{si la región es D} \\ 0 & \text{si no es así} \end{cases}$$

Ejercicios

Métodos

Autoexamen

32. Considere un estudio de regresión en el que intervienen una variable dependiente y , una variable independiente cuantitativa x_1 y una variable cualitativa de dos niveles (nivel 1 y nivel 2).
- Dé la ecuación de regresión múltiple que relaciona x_1 y la variable cualitativa con y .
 - ¿Cuál es el valor esperado de y que corresponde al nivel 1 de la variable cualitativa?
 - ¿Cuál es el valor esperado de y que corresponde al nivel 2 de la variable cualitativa?
 - Interprete los parámetros de la ecuación de regresión.
33. Considere un estudio de regresión en el que intervienen una variable dependiente y , una variable independiente cuantitativa x_1 y una variable cualitativa de tres niveles (nivel 1, nivel 2 y nivel 3).
- ¿Cuántas variables ficticias se requieren para representar la variable cualitativa?
 - Dé una ecuación de regresión múltiple que relacione x_1 y la variable cualitativa con y .
 - Interprete los parámetros de la ecuación de regresión.

Aplicaciones

Autoexamen

34. El administrador propuso el siguiente modelo de regresión para predecir las ventas en un punto de venta de comida rápida.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \epsilon$$

donde

x_1 = número de competidores a no más de una milla

x_2 = población a no más de una milla (en miles)

$$x_3 = \begin{cases} 1 & \text{si tiene ventanilla para conductores} \\ 0 & \text{si no es así} \end{cases}$$

y = ventas (en miles de \$)

Se obtuvo la siguiente ecuación de regresión estimada con los datos de 20 puntos de venta.

$$\hat{y} = 10.1 - 4.2x_1 + 6.8x_2 + 15.3x_3$$

- ¿Cuál es la cantidad esperada de ventas atribuible a la ventana para conductores?
 - Pronostique las ventas de un negocio que tiene dos competidores y una población de 8000 a no más de una milla y ventanilla para los conductores.
 - Pronostique las ventas de un negocio que tiene un competidor y una población de 3000 a no más de una milla y ventanilla para los conductores.
35. Véase el problema de Johnson Filtration presentado en esta sección. Supóngase que además de la información sobre los meses transcurridos desde el último servicio y de si se trata de una reparación mecánica o eléctrica, los administradores presentan una lista con las personas que realizaron las reparaciones. A continuación se presentan los nuevos datos.

archivo
en
Repair

CD

Tiempo en horas requerido para la reparación	Meses desde el último servicio	Tipo de reparación	Persona que realiza la reparación
2.9	2	eléctrica	Dave Newton
3.0	6	mecánica	Dave Newton
4.8	8	eléctrica	Bob Jones

(continúa)

Tiempo en horas requerido para la reparación	Meses desde el último servicio	Tipo de reparación	Persona que realiza la reparación
1.8	3	mecánica	Dave Newton
2.9	2	eléctrica	Dave Newton
4.9	7	eléctrica	Bob Jones
4.2	9	mecánica	Bob Jones
4.8	8	mecánica	Bob Jones
4.4	4	eléctrica	Bob Jones
4.5	6	eléctrica	Dave Newton

- Por ahora ignore los meses transcurridos desde el último servicio (x_1) y la persona que realizó la reparación. Obtenga la ecuación de regresión lineal simple estimada para predecir el tiempo que se requiere para la reparación (y) dado el tipo de reparación (x_2). Recuerde que $x_2 = 0$ si se trata de una reparación mecánica, y $x_2 = 1$ si se trata de una reparación eléctrica.
 - ¿Proporciona la ecuación obtenida en el inciso a) un buen ajuste a los datos observados? Explique.
 - Por ahora ignore los meses transcurridos desde el último servicio y el tipo de reparación. Obtenga la ecuación de regresión lineal simple estimada para predecir el tiempo necesario para la reparación dada la persona que realizó la reparación. Sea $x_3 = 0$ si la reparación fue hecha por Bob Jones, y $x_3 = 1$ si la reparación fue hecha por Dave Newton.
 - ¿Proporciona la ecuación obtenida en el inciso c) un buen ajuste a los datos observados? Explique.
36. Este problema es una extensión del ejercicio 35.
- Obtenga la ecuación de regresión estimada que permita predecir el tiempo que se requiere para una reparación dados los meses transcurridos desde la última reparación, el tipo de reparación y la persona que realizó la reparación.
 - Empleando como nivel de significancia 0.05, realice una prueba para ver si la ecuación de regresión estimada obtenida en el inciso a) representa una relación significativa entre las variables independientes y la variable dependiente.
 - ¿Es estadísticamente significativo agregar la variable x_3 , la persona que realizó la reparación? Use $\alpha = 0.05$. ¿Qué explicación puede dar para los resultados observados?
37. La Liga nacional de fútbol americano de Estados Unidos (National Football League) evalúa a sus prospectos con una escala que va del 5 al 9. Estas evaluaciones se interpretan como sigue: 8 – 9 deberá empezar el año próximo; 7.0 – 7.9 deberá empezar; 6.0 – 6.9 servirán de respaldo al equipo, y 5.0 – 5.9 pueden formar parte del club y contribuir. En la tabla siguiente se da posición, peso, tiempo en segundos para correr 40 yardas y la evaluación dada por la NFL a 25 prospectos (*USA Today*, 14 de abril de 2000).
- Dé una variable ficticia para la posición de los jugadores.

	Posición	Peso (libras)	Tiempo (segundos)	Evaluación
Cosey Coleman	Guardia	322	5.38	7.4
Travis Claridge	Guardia	303	5.18	7.0
Kaulana Noa	Guardia	317	5.34	6.8
Leander Jordan	Guardia	330	5.46	6.7
Chad Clifton	Guardia	334	5.18	6.3
Manula Savea	Guardia	308	5.32	6.1
Ryan Johanningmeir	Guardia	310	5.28	6.0
Mark Tauscher	Guardia	318	5.37	6.0
Blaine Saipaia	Guardia	321	5.25	6.0
Richard Mercier	Guardia	295	5.34	5.8
Damion McIntosh	Guardia	328	5.31	5.3

	Posición	Peso (libras)	Tiempo (segundos)	Evaluación
Jeno James	Guardia	320	5.64	5.0
Al Jackson	Guardia	304	5.20	5.0
Chris Samuels	Tackle	325	4.95	8.5
Stockar McDougle	Tackle	361	5.50	8.0
Chris McIngosh	Tackle	315	5.39	7.8
Adrian Klemm	Tackle	307	4.98	7.6
Todd Wade	Tackle	326	5.20	7.3
Marvel Smith	Tackle	320	5.36	7.1
Michael Thompson	Tackle	287	5.05	6.8
Bobby Williams	Tackle	332	5.26	6.8
Darnell Alford	Tackle	334	5.55	6.4
Terrance Beadles	Tackle	312	5.15	6.3
Tutan Reyes	Tackle	299	5.35	6.1
Greg Robinson-Ran	Tackle	333	5.59	6.0

- Obtenga una ecuación de regresión estimada que muestre la relación entre la evaluación y posición, peso y tiempo requerido para correr 40 yardas.
 - Empleando como nivel de significancia 0.05, pruebe si la ecuación de regresión estimada obtenida en el inciso b) indica que existe una relación significativa entre las variables independientes y la variable dependiente.
 - ¿Proporciona la ecuación de regresión estimada un buen ajuste a los datos observados? Explique.
 - ¿Es la posición un factor significativo en la evaluación de los jugadores? Use $\alpha = 0.05$. Explique.
 - Suponga que hay un nuevo prospecto de tackle que pesa 300 libras y corre 40 yardas en 5.1 segundos. Utilice la ecuación de regresión estimada obtenida en el inciso b) para estimar la evaluación de este jugador.
38. Un estudio realizado a lo largo de 10 años por la American Heart Association proporcionó datos sobre la relación que tienen la edad, la presión sanguínea y el fumar sobre el riesgo de sufrir un infarto. Los datos que se dan a continuación se obtuvieron como parte de este estudio. El riesgo se interpreta como la probabilidad (multiplicada por 100) de que el paciente sufra un infarto en los próximos 10 años. Para fumar, defina una variable ficticia que tome el valor 1 si la persona es fumadora y el valor 0 si no es fumadora.



Riesgo	Edad	Presión	Fumador
12	57	152	No
24	67	163	No
13	58	155	No
56	86	177	Sí
28	59	196	No
51	76	189	Sí
18	56	155	Sí
31	78	120	No
37	80	135	Sí
15	78	98	No
22	71	152	No
36	70	173	Sí
15	67	135	Sí
48	77	209	Sí
15	60	199	No
36	82	119	Sí
8	66	166	No
34	80	125	Sí
3	62	117	No
37	59	207	Sí

- Obtenga la ecuación de regresión estimada que relaciona el riesgo de infarto con la edad, la presión sanguínea y el fumar o no fumar.
- ¿Es el fumar un factor significativo para el riesgo de infarto? Explique. Use $\alpha = 0.05$.
- ¿Cuál es la probabilidad de que Art Apeen sufra un infarto en los próximos 10 años, si tiene 68 años, fuma y su presión sanguínea es 175? ¿Qué recomendará el médico hacer a este paciente?

15.8

Análisis residual

En el capítulo 14 se indicó que los residuales estandarizados suelen emplearse en las gráficas de residuales y en la identificación de observaciones atípicas. A continuación se presenta la fórmula general para obtener el residual estandarizado de la observación i .

RESIDUAL ESTANDARIZADO DE LA OBSERVACIÓN i

$$\frac{y_i - \hat{y}_i}{s_{y_i - \hat{y}_i}} \quad (15.23)$$

donde

$$s_{y_i - \hat{y}_i} = \text{desviación estándar del residual } i$$

La fórmula general para obtener la desviación estándar del residual i está definida como se indica a continuación.

DESVIACIÓN ESTÁNDAR DEL RESIDUAL i

$$s_{y_i - \hat{y}_i} = s\sqrt{1 - h_i} \quad (15.24)$$

donde

$$s = \text{error estándar de estimación}$$

$$h_i = \text{influencia de la observación } i$$

Como se dijo en el capítulo 14, la **influencia** de una observación está determinada por qué tan lejos de sus medias están los valores de las variables independientes. En el análisis de regresión múltiple, calcular h_i y $s_{y_i - \hat{y}_i}$, y por lo tanto el residual estandarizado de la observación i es muy complicado como para hacerlo a mano. Sin embargo, los residuales estandarizados se obtienen fácilmente como parte de los resultados de los paquetes de software para estadística. En la tabla 15.7 se presentan valores pronosticados, residuales y residuales estandarizados empleando los datos del ejemplo de Butler Trucking presentado previamente en este capítulo; estos valores se obtuvieron empleando Minitab. Los valores pronosticados que aparecen en la tabla están basados en la ecuación de regresión estimada $\hat{y} = -0.869 + 0.0611x_1 + 0.923x_2$.

Los residuales estandarizados y los valores pronosticados de y de la tabla 15.7 se emplearon en la figura 15.10, la gráfica de residuales estandarizados para el ejemplo de regresión múltiple de Butler Trucking. En esta gráfica de residuales estandarizados no se observa ninguna anomalía. Además, todos los residuales estandarizados se encuentran entre -2 y $+2$; por lo tanto no hay ninguna razón para cuestionar la suposición de que el término del error esté distribuido normalmente. Así, se concluye que las suposiciones del modelo son razonables.


TABLA 15.7 RESIDUALES Y RESIDUALES ESTANDARIZADOS CORRESPONDIENTES AL ANÁLISIS DE REGRESIÓN DE BUTLER TRUCKING.

Millas recorridas (x_1)	Entregas (x_2)	Tiempo de recorrido (y)	Valor pronosticado ($\hat{y}$)	Residual ($y - \hat{y}$)	Residual estandarizado
100	4	9.3	8.93846	0.361541	0.78344
50	3	4.8	4.95830	-0.158304	-0.34962
100	4	8.9	8.93846	-0.038460	-0.08334
100	2	6.5	7.09161	-0.591609	-1.30929
50	2	4.2	4.03488	0.165121	0.38167
80	2	6.2	5.86892	0.331083	0.65431
75	3	7.4	6.48667	0.913331	1.68917
65	4	6.0	6.79875	-0.798749	-1.77372
90	3	7.6	7.40369	0.196311	0.36703
90	2	6.1	6.48026	-0.380263	-0.77639

Para determinar si la distribución de ϵ parece ser normal, puede emplearse también una gráfica de probabilidad normal. En la sección 14.8 se discutió el procedimiento y la interpretación de una gráfica de probabilidad normal. Ese mismo procedimiento es adecuado para la regresión múltiple. Para obtener la gráfica de probabilidad normal también se hace uso de un paquete de software para estadística que realice los cálculos.

Detección de observaciones atípicas

Una **observación atípica** es una observación que es inusual en relación con el resto de los datos; en otras palabras, una observación atípica no sigue el patrón del resto de los datos. En el capítulo 14 se mostró un ejemplo en el que había una observación atípica y se vio el empleo de los residuales estandarizados para detectar observaciones atípicas. Minitab clasifica una observación

FIGURA 15.10 GRÁFICA DE RESIDUALES ESTANDARIZADOS EMPLEANDO EL EJEMPLO DE BUTLER TRUCKING

como observación atípica si el valor de su residual estandarizado es menor a -2 o mayor a $+2$. Aplicando esta regla a los residuales estandarizados del ejemplo de Butler Trucking (tabla 15.7), en este conjunto de datos no se detecta ninguna observación atípica.

En general, la presencia de una o más observaciones atípicas en un conjunto de datos tiende a incrementar s , el error estándar de estimación y, por lo tanto, a incrementar $s_{y_i - \hat{y}_i}$, la desviación estándar del residual i . Dado que $s_{y_i - \hat{y}_i}$ aparece como denominador en la fórmula (15.23) del residual estandarizado, el tamaño del residual estandarizado disminuirá a medida que s aumente. Esto da como resultado que aún cuando un residual sea inusualmente grande, el denominador de la fórmula (15.23), que será grande, hará que la regla del residual estandarizado falle para la identificación de una observación como observación atípica. Es posible sortear esta dificultad empleando una forma de los residuales estandarizados conocida como **residuales estudentizados**.

Residuales estudentizados eliminados y observaciones atípicas

Supóngase que del conjunto de datos se elimina la observación i y que de las $n - 1$ observaciones restantes se obtiene una nueva ecuación de regresión estimada. Sea $s_{(i)}$ el error estándar de estimación obtenido del conjunto de datos en los que se ha eliminado la observación i . Si se calcula la desviación estándar del residual i usando $s_{(i)}$ en lugar de s y después se calcula el residual estandarizado de la observación i empleando el nuevo valor de $s_{y_i - \hat{y}_i}$, al residual estandarizado que se obtiene se le llama residual eliminado estudentizado. Si la observación i es una observación atípica, $s_{(i)}$ será menor a s . Por lo tanto, el valor absoluto del residual eliminado estudentizado i será mayor que el valor absoluto del residual estandarizado. De esta manera, los residuales eliminados estudentizados pueden detectar observaciones atípicas que los residuales estandarizados no detectan.

Muchos de los paquetes de software para estadística proporcionan una opción para obtener residuales eliminados estudentizados. Empleando Minitab se obtuvieron los residuales eliminados estudentizados para el ejemplo de Butler Trucking; los resultados obtenidos se presentan en la tabla 15.8. Para determinar si los residuales eliminados estudentizados indican la presencia de observaciones atípicas se emplea la distribución t . Recuérdese que p denota el número de variables independientes y n el número de observaciones. Por lo tanto, si se elimina la observación i , el número de observaciones en el nuevo conjunto de datos es $n - 1$; en este caso, la suma de cuadrados del error tiene $(n - 1) - p - 1$ grados de libertad. Como en el ejemplo de Butler Trucking $n = 10$ y $p = 2$, los grados de libertad para la suma de cuadrados del error es $9 - 2 - 1 = 6$. Empleando como nivel de significancia 0.05, en la distribución t (tabla 2 del apéndice B) para seis grados de libertad se obtiene, $t_{0.025} = 2.337$. Se concluye que la observación i es una observación atípica si el residual eliminado estudentizado es menor a -2.447 o mayor a $+2.447$. En la tabla 15.8 se observa que los residuales eliminados estudentizados no se encuentran fuera de estos límites; por lo tanto se concluye que en este conjunto de datos no hay observaciones atípicas.

TABLA 15.8 RESIDUALES ELIMINADOS ESTUDENTIZADOS CORRESPONDIENTES AL EJEMPLO DE BUTLER TRUCKING

Millas recorridas (x_1)	Entregas (x_2)	Tiempo recorrido (y)	Residual estandarizado	Residual eliminado estudentizado
100	4	9.3	0.78344	0.75939
50	3	4.8	-0.34962	-0.32654
100	4	8.9	-0.08334	-0.07720
100	2	6.5	-1.30929	-1.39494
50	2	4.2	0.38167	0.35709
80	2	6.2	0.65431	0.62519
75	3	7.4	1.68917	2.03187
65	4	6.0	-1.77372	-2.21314
90	3	7.6	0.36703	0.34312
90	2	6.1	-0.77639	-0.75190

TABLA 15.9 INFLUENCIA Y DISTANCIA DE COOK CORRESPONDIENTES AL EJEMPLO DE BUTLER TRUCKING

Millas recorridas (x_1)	Entregas (x_2)	Tiempo de recorrido (y)	Influencia (h_i)	D Cook (D_i)
100	4	9.3	0.351704	0.110994
50	3	4.8	0.375863	0.024536
100	4	8.9	0.351704	0.001256
100	2	6.5	0.378451	0.347923
50	2	4.2	0.430220	0.036663
80	2	6.2	0.220557	0.040381
75	3	7.4	0.110009	0.117562
65	4	6.0	0.382657	0.650029
90	3	7.6	0.129098	0.006656
90	2	6.1	0.269737	0.074217

Observaciones influyentes

En la sección 14.9 se vio cómo se puede usar la influencia de una observación para identificar observaciones cuyo valor de la variable independiente puede tener una influencia fuerte en los resultados de la regresión. Como se indicó al hablar de los residuales estandarizados, la influencia de una observación, que se denota h_i , mide qué tan lejos de sus medias se encuentran los valores de las variables independientes. Los valores de la influencia se pueden obtener como parte de los resultados que proporcionan los paquetes de software para estadística. Minitab calcula los valores de la influencia y para detectar **observaciones influyentes** emplea la regla $h_i > 3(p + 1)/n$. En el ejemplo de Butler Trucking como hay $p = 2$ variables independientes y $n = 10$ observaciones, el valor crítico para la influencia es $3(2 + 1)/10 = 0.9$. En la tabla 15.9 se presentan los valores de la influencia correspondientes al ejemplo de Butler Trucking obtenidos con Minitab. Como ninguno de los valores h_i es mayor a 0.9, en este conjunto de datos no se detectan observaciones influyentes.

Uso de la medida de la distancia de Cook para identificar observaciones influyentes

Un problema que puede presentarse al usar la influencia para identificar observaciones influyentes es que puede que se identifique una observación como una observación que tiene una gran influencia sin que necesariamente sea influyente en términos de la ecuación de regresión estimada que se obtiene. Por ejemplo, en la tabla 15.10 se presenta un conjunto de datos que consta de 10 observaciones y sus correspondientes valores de influencia (obtenidos usando Minitab). Como la influencia de la última observación es $0.91 > 0.75$ (el valor de influencia crítico), se identificará a esta observación como una observación influyente. Sin embargo antes de aceptar una conclusión final, considérese la situación desde una perspectiva diferente.

En la figura 15.11 se presenta el diagrama de dispersión que corresponde al conjunto de datos de la tabla 15.10. Empleando Minitab se obtuvo a partir de estos datos la ecuación de regresión estimada siguiente.

$$\hat{y} = 18.2 + 1.39x$$

La línea recta que se observa en la figura 15.11 es la gráfica de esta ecuación. Ahora, si de este conjunto de datos se elimina la observación $x = 15$, $y = 39$ y con las siete observaciones restantes se obtiene una nueva ecuación, la nueva ecuación de regresión estimada es


$$\hat{y} = 18.1 + 1.42x$$

Se observa que en la nueva ecuación la intersección con el eje y y la pendiente no tienen valores significativamente diferentes a los de la ecuación en la que se usan todos los datos. A pesar de

TABLA 15.10

CONJUNTO DE DATOS QUE ILUSTRAN EL PROBLEMA POTENCIAL QUE EXISTE USANDO EL CRITERIO DE LA INFLUENCIA

x_i	y_i	Influencia h_i
1	18	0.204170
1	21	0.204170
2	22	0.164205
3	21	0.138141
4	23	0.125977
4	24	0.125977
5	26	0.127715
15	39	0.909644

FIGURA 15.11 DIAGRAMA DE DISPERSIÓN OBTENIDO CON LOS DATOS DE LA TABLA 15.10

que con el criterio de la influencia se identificó a la octava observación con observación influyente, es claro que esta observación tiene poca influencia en los resultados. Por lo tanto, hay casos en los que emplear únicamente la influencia para identificar las observaciones influyentes puede llevar a conclusiones erróneas.

En la **medida de la distancia de Cook** se utiliza tanto la influencia de la observación i , h_i , como el residual de la observación i , $(y_i - \hat{y}_i)$, para determinar si una observación es influyente.

MEDIDA DE LA DISTANCIA DE COOK

$$D_i = \frac{(y_i - \hat{y}_i)^2}{(p - 1)s^2} \left[\frac{h_i}{(1 - h_i)^2} \right] \quad (15.25)$$

donde

- D_i = medida de la distancia de Cook para la observación i
- $y_i - \hat{y}_i$ = residual de la observación i
- h_i = influencia de la observación i
- p = número de variables independientes
- s = error estándar de estimación

Si el residual o la influencia es grande, la medida de la distancia de Cook será grande e identificará una observación influyente. Como regla general se acepta que si $D_i > 1$ la observación i es influyente y debe ser analizada con más detenimiento. En la última columna de la tabla 15.9 se presentan las medidas de la distancia de Cook correspondientes al problema Butler Trucking obtenidas con Minitab. La observación con mayor influencia es la observación 8, para la que $D_i = 0.650029$. Aplicando la regla $D_i > 1$ se ve que no hay por qué preocuparse acerca de la presencia de observaciones influyentes en el conjunto de datos de Butler Trucking.

NOTAS Y COMENTARIOS

1. Los procedimientos para la detección de observaciones atípicas o de observaciones influyentes permiten estar alerta acerca de los efectos potenciales que algunas observaciones puedan tener en los resultados de la regresión. Cada observación atípica u observación influyente justifica un examen cuidadoso. Si se encuentran errores en los datos, se pueden corregir los errores y repetir el análisis de regresión. En general, las observaciones atípicas y las observaciones influyentes no deben ser eliminadas del conjunto de datos a menos que haya una evidencia clara que indique que no provienen de elementos de la población en estudio y que no tenían que ser incluidos en el conjunto de datos original.
2. Para determinar si el valor de una medida de la distancia de Cook D_i es lo suficientemente grande como para concluir que la observación i es influyente, también puede compararse el valor de D_i con el percentil 50 de una distribución F (denotado $F_{0.50}$) con $p + 1$ grados de libertad en el numerador y $n - p - 1$ grados de libertad en el denominador. Para esta prueba se necesita contar con tablas F a un nivel de significancia de 0.50. La regla práctica dada antes ($D_i > 1$) se basa en el hecho de que en muchos de los casos los valores en la tabla son cercanos a 1.

Ejercicios

Métodos

Autoexamen

39. A continuación se dan datos para las variables x y y .

x_i	1	2	3	4	5
y_i	3	7	5	11	14

- a. Obtenga una ecuación de regresión estimada para estos datos.
 - b. Grafique los residuales estandarizados contra $\hat{y}$. ¿Parece haber alguna observación atípica en este conjunto de datos? Explique.
 - c. Calcule los residuales eliminados estandarizados de estos datos. Empleando como nivel de significancia 0.05, ¿puede clasificarse cualquiera de estas observaciones como observación atípica? Explique.
40. A continuación se dan datos para las variables x y y .

x_i	22	24	26	28	40
y_i	12	21	31	35	70

- a. Obtenga una ecuación de regresión estimada para estos datos.
- b. Calcule los residuales eliminados estandarizados de estos datos. Empleando como nivel de significancia 0.05, ¿puede clasificarse cualquiera de estas observaciones como observación atípica? Explique.
- c. Calcule los valores de influencia de estos datos. ¿Parece haber alguna observación influyente en estos datos? Explique.
- d. Calcule la medida de la distancia de Cook de estos datos. ¿Es alguna de las observaciones una observación influyente? Explique.

Aplicaciones

Autoexamen



41. En el ejercicio 5 se presentaron los datos siguientes sobre el ingreso semanal bruto y publicidad tanto en televisión como en periódicos de Showtime Movie Theater.

Ingreso semanal bruto (en miles de \$)	Publicidad en televisión (en miles \$)	Publicidad en periódicos (en miles de \$)
96	5.0	1.5
90	2.0	2.0
95	4.0	1.5
92	2.5	2.5
95	3.0	3.3
94	3.5	2.3
94	2.5	4.2
94	3.0	2.5

- Dé una ecuación de regresión estimada que relacione el ingreso semanal bruto con los gastos en publicidad en televisión y periódicos.
 - Grafique los residuales estandarizados contra $\hat{y}$. ¿Respalda la gráfica de residuales las suposiciones acerca de ϵ ? Explique.
 - Revise que no haya observaciones atípicas en estos datos. ¿A qué conclusión llega?
 - ¿Hay alguna observación influyente?
42. En los datos siguientes se presenta peso en vacío, caballos de fuerza y velocidad en $\frac{1}{4}$ de milla de 10 automóviles deportivos y GT. Supóngase que se tiene también el precio de cada uno de estos automóviles. Todo el conjunto de datos es el siguiente.



Automóvil deportivo y GT	Precio (miles de \$)	Peso en vacío (lb)	Caballos de fuerza (lb)	Velocidad en $\frac{1}{4}$ de milla (mph)
Accura Integra Type R	25 035	2577	195	90.7
Accura NSX-T	93 758	3066	290	108.0
BMW Z3 2.8	40 900	2844	189	93.2
Chevrolet Camaro Z28	24 865	3439	305	103.2
Chevrolet Corvette Convertible	50 144	3246	345	102.1
Dodge Viper RT/10	69 742	3319	450	116.2
Ford Mustang GT	23 200	3227	225	91.7
Honda Prelude Type SH	26 382	3042	195	89.7
Mercedes-Benz CLK320	44 988	3240	215	93.0
Mercedes-Benz SLK230	42 762	3025	185	92.3
Mitsubishi 3000GT VR-4	47 518	3737	320	99.0
Nissan 240SX SE	25 066	2862	155	84.6
Pontiac Firebird Trans Am	27 770	3455	305	103.2
Porsche Boxster	45 560	2822	201	93.2
Toyota Supra Turbo	40 989	3505	320	105.0
Volvo C70	41 120	3285	236	97.0

- Obtenga la ecuación de regresión estimada en la que se emplee precio y caballos de fuerza para predecir la velocidad en $\frac{1}{4}$ de milla.
- Grafique los residuales estandarizados contra $\hat{y}$. ¿Respalda la gráfica de residuales las suposiciones respecto a ϵ ? Explique.
- Verifique si hay observaciones atípicas. ¿A qué conclusión llega?
- ¿Hay alguna observación influyente? Explique.



43. La Ladies Professional Golfers Association (LPGA) lleva estadísticas sobre el desempeño y los ingresos de sus miembros en el LPGA Tour. En el archivo titulado LPGA del disco compacto se presentan las estadísticas de fin de año sobre el desempeño de las 30 jugadoras que tuvieron los mejores ingresos en el LPGA Tour del 2005 (www.lpga.com, 2006). Earnings (ingresos) (\$1000) son los ingresos totales en miles de dólares; Scoring Avg es el promedio de golpes en todo el evento; Greens in Reg. es el porcentaje de las veces que un jugador logra un *green* en regulación, y Putting Avg es el promedio de *putts* por *green* en regulación. Un *green* se considera en regulación cuando se alcanza en dos golpes menos que el par del hoyo
- Obtenga una ecuación de regresión estimada que sirva para obtener Scoring Avg conociendo Greens in Reg. y Putting Avg.
 - Grafique los residuales estandarizados contra $\hat{y}$. ¿Confirma esta gráfica de residuales las suposiciones hechas acerca de ϵ ?
 - Verifique si existen observaciones atípicas. ¿A qué conclusión llega?
 - ¿Hay alguna observación influyente? Explique.

15.9

Regresión logística

En muchas de las aplicaciones de la regresión la variable dependiente asume sólo dos valores discretos. Por ejemplo, en un banco suele necesitarse una ecuación de regresión estimada para predecir si a una persona se le aprobará su solicitud de tarjeta de crédito. A esta variable dependiente pueden dársele los valores $y = 1$ si la solicitud de tarjeta de crédito es aprobada, y $y = 0$ si es rechazada. Con la regresión logística, dado un conjunto particular de valores de las variables independientes elegidas, se estima la probabilidad de que el banco apruebe la solicitud de tarjeta de crédito.

A continuación se considera una aplicación de la regresión logística. La empresa Simmons Stores va a realizar una promoción por correo. Simmons Stores es una cadena nacional de ropa para dama. Ha mandado imprimir 5000 costosos catálogos de venta a cuatro colores y en cada catálogo incluye un cupón de \$50 de descuento en la compra de \$200 o más.

Como este catálogo es costoso, Simmons desea enviarlo sólo a aquellos clientes que tengan mayor probabilidad de usar el cupón. Los gerentes consideran que la cantidad gastada anualmente por el cliente en las tiendas Simmons, así como si posee o no una tarjeta de crédito de Simmons son dos variables que pueden servir para predecir si ese cliente usará el cupón. Simmons realiza un estudio piloto usando una muestra aleatoria de 50 clientes con tarjeta de crédito de Simmons y 50 clientes sin tarjeta de crédito de la empresa. Simmons envió los catálogos a cada uno de estos 100 clientes elegidos. Al final del periodo de prueba, Simmons anota si los clientes han hecho uso o no del cupón. En la tabla 15.11 se presentan los datos muestrales de las 10 primeras personas que recibieron el catálogo. En esta tabla se da: cantidad, en miles de dólares, gastada por el cliente en las tiendas Simmons durante el año anterior; información sobre si tiene o no tarjeta de crédito de Simmons, codificada como 1 si el cliente tiene tarjeta de crédito de Simmons y 0 si no la tiene. En la columna correspondiente al cupón, 1 significa el cliente usó el cupón y 0 significa no lo usó.

Para ayudar a Simmons a predecir si las personas que reciban el catálogo usarán o no el cupón, se podría pensar en construir, con los datos de la tabla 15.11, un modelo de regresión múltiple. Las variables independientes serían cantidad gastada anualmente en Simmons Stores y tarjeta de crédito, y la variable dependiente sería cupón. Sin embargo, el modelo común de regresión múltiple no se puede emplear debido a que la variable dependiente sólo puede tomar los valores 0 y 1. Con este ejemplo se ilustra el tipo de situación para la cual fue creada la regresión logística. A continuación se verá el empleo de la regresión logística para ayudar a Simmons Stores a pronosticar qué tipo de clientes es más probable que aprovechen esta promoción.

TABLA 15.11 DATOS MUESTRALES DE SIMMONS STORES



Cliente	Gastos anual (miles de \$)	Tarjeta de Simmons	Cupón
1	2.291	1	0
2	3.215	1	0
3	2.135	1	0
4	3.924	0	0
5	2.528	1	0
6	2.473	0	1
7	2.384	0	0
8	7.076	0	0
9	1.182	1	1
10	3.345	0	0

Ecuación de regresión logística

La regresión logística se parece en muchos aspectos a la regresión común. Se necesita una variable dependiente y y una o varias variables independientes. En el análisis de regresión múltiple, a la media o valor esperado de y se le conoce como la ecuación de regresión múltiple.

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \quad (15.26)$$

En la regresión logística, tanto la teoría como la práctica estadística han demostrado que la relación existente entre $E(y)$ y $x_1, x_2, \dots, x_p$, queda descrita mediante la siguiente ecuación no lineal.

ECUACIÓN DE REGRESIÓN LOGÍSTICA

$$E(y) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p}} \quad (15.27)$$


Como los dos valores de la variable dependiente y son 0 y 1, el valor de $E(y)$ en la ecuación (15.27) dará la *probabilidad* de que $y = 1$ para un conjunto dado de valores de las variables independientes $x_1, x_2, \dots, x_p$. Como $E(y)$ se interpreta como una probabilidad, la **ecuación de regresión logística** suele expresarse de la manera siguiente.

INTERPRETACIÓN DE $E(y)$ COMO PROBABILIDAD EN LA REGRESIÓN LOGÍSTICA

$$E(y) = P(y = 1 | x_1, x_2, \dots, x_p) \quad (15.28)$$

Para entender mejor las características de la ecuación de regresión logística, supóngase que en el modelo se tiene sólo una variable independiente x y que los valores de los parámetros del modelo son $\beta_0 = -7$ y $\beta_1 = 3$. La ecuación de regresión logística correspondiente a estos valores de los parámetros es

$$E(y) = P(y = 1 | x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{e^{-7 + 3x}}{1 + e^{-7 + 3x}} \quad (15.29)$$

FIGURA 15.12 ECUACIÓN DE REGRESIÓN LOGÍSTICA EN LA QUE $\beta_0 = -7$ Y $\beta_1 = 3$ 

En la figura 15.12 se muestra la gráfica de la ecuación (15.29). Obsérvese que la gráfica tiene forma de S. El valor de $E(y)$ va desde 0 hasta 1, aproximándose gradualmente a 1 a medida que el valor de x aumenta, y a 0 a medida que el valor de x disminuye. Obsérvese también que el valor de $E(y)$, que representa probabilidad, aumenta rápidamente al aumentar x de 2 a 3. El hecho de que los valores de $E(y)$ vayan de 0 a 1 y que la curva tenga forma de S hacen que la ecuación (15.29) sea ideal para modelar la probabilidad de que la variable dependiente sea igual a 1.

Estimación de la ecuación de regresión logística

En la regresión lineal simple y en la regresión múltiple se emplea el método de mínimos cuadrados para calcular las estimaciones $b_0, b_1, \dots, b_p$, de los parámetros $\beta_0, \beta_1, \dots, \beta_p$ del modelo. Debido a la forma no lineal de la ecuación de regresión logística, el método para calcular estas estimaciones es más complejo y queda fuera del alcance de este libro. Para obtener estas estimaciones se empleará un paquete de software. La **ecuación de regresión logística estimada** es

ECUACIÓN DE REGRESIÓN LOGÍSTICA ESTIMADA

$$\hat{y} = \text{estimación de } P(y = 1 | x_1, x_2, \dots, x_p) = \frac{e^{b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p}}{1 + e^{b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p}} \quad (15.30)$$

Aquí $\hat{y}$ es una estimación de la probabilidad de que $y = 1$, para un determinado conjunto de valores de las variables independientes.

Volviendo ahora al ejemplo de Simmons Stores, las variables en este estudio están definidas como sigue:

$$y = \begin{cases} 0 & \text{si el cliente no usó el cupón} \\ 1 & \text{si el cliente usó el cupón} \end{cases}$$

$$x_1 = \text{cantidad anual gastada en Simmons Stores (en miles de \$)}$$

$$x_2 = \begin{cases} 0 & \text{si el cliente no tiene tarjeta de crédito de Simmons} \\ 1 & \text{si el cliente tiene tarjeta de crédito de Simmons} \end{cases}$$

FIGURA 15.13 RESULTADOS DE LA REGRESIÓN LOGÍSTICA PARCIAL PARA EL PROBLEMA DE LAS TIENDAS SIMMONS

En los resultados de Minitab
 x_1 = Spending (cantidad gastada)
 x_2 = Card (tarjeta de crédito)

Logistic Regression Table								
Predictor	Coef	SE Coef	Z	p	Odds Ratio	95% CI		
Constant	-2.1464	0.5772	-3.72	0.000				
Spending	0.3416	0.1287	2.66	0.008	1.41	1.09	1.81	
Card	1.0987	0.4447	2.47	0.013	3.00	1.25	7.17	
Log-Likelihood = -60.487								
Test that all slopes are zero: G = 13.628, DF = 2, P-Value = 0.001								

Por lo tanto, se elige una ecuación de regresión logística con dos variables independientes.

$$E(y) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2}} \quad (15.31)$$

En el apéndice 15.3 se muestra cómo se usa Minitab para generar el resultado que se muestra en la figura 15.13.

Para calcular las estimaciones de los parámetros β_0 , β_1 , y β_2 del modelo se aplicó el procedimiento de regresión logística binaria de Minitab a los datos muestrales de la tabla 15.11. En la figura 15.13 se muestra parte de los resultados obtenidos. Como se ve, $b_0 = -2.1464$, $b_1 = 0.3416$ y $b_2 = 1.0987$. Por lo tanto, la ecuación de regresión logística estimada es

$$\hat{y} = \frac{e^{b_0 + b_1 x_1 + b_2 x_2}}{1 + e^{b_0 + b_1 x_1 + b_2 x_2}} = \frac{e^{-2.1464 + 0.3416x_1 + 1.0987x_2}}{1 + e^{-2.1464 + 0.3416x_1 + 1.0987x_2}} \quad (15.32)$$

Ahora usando la ecuación (15.32) se estima la probabilidad de que un determinado tipo de clientes use el cupón. Por ejemplo, para estimar la probabilidad de que los clientes que tienen un gasto anual de \$2000 en Simmons Stores y que no tienen tarjeta de crédito de Simmons usen el cupón, en la ecuación (15.32) se sustituyen $x_1 = 2$ y $x_2 = 0$.

$$\hat{y} = \frac{e^{-2.1464 + 0.3416(2) + 1.0987(0)}}{1 + e^{-2.1464 + 0.3416(2) + 1.0987(0)}} = \frac{e^{-1.4632}}{1 + e^{-1.4632}} = \frac{0.2315}{1.2315} = 0.1880$$

Por lo tanto, la probabilidad estimada de que este tipo de clientes use el cupón es 0.19. De manera similar, la probabilidad de que aquellos clientes que tienen un gasto anual de \$2000 en Simmons Stores y que tiene tarjeta de crédito de Simmons usen el cupón, se estima sustituyendo en la ecuación (15.32) $x_1 = 2$ y $x_2 = 1$.

$$\hat{y} = \frac{e^{-2.1464 + 0.3416(2) + 1.0987(1)}}{1 + e^{-2.1464 + 0.3416(2) + 1.0987(1)}} = \frac{e^{-0.3645}}{1 + e^{-0.3645}} = \frac{0.6945}{1.6945} = 0.4099$$

Por lo tanto, la probabilidad de que los clientes de este grupo usen el cupón es aproximadamente 0.41. Parece ser que los clientes que tienen tarjeta de crédito de Simmons son los que tienen mayor probabilidad de usar el cupón. Pero antes de llegar a una conclusión, es necesario evaluar la significancia estadística de este modelo.

Prueba de significancia

La prueba de significancia en la regresión logística es similar a la prueba de significancia en la regresión múltiple. Primero se hace una prueba para probar la significancia global. En el ejemplo de Simmons Stores, las hipótesis para probar la significancia global son las siguientes:

$$H_0: \beta_1 = \beta_2 = 0$$

$$H_a: \text{Uno o los dos parámetros son distintos de cero}$$

La prueba de significancia global del modelo se basa en el valor del estadístico de prueba G . Si la hipótesis nula es verdadera, la distribución muestral de G es una distribución chi-cuadrada con grados de libertad igual al número de variables independientes en el modelo. El cálculo de G queda fuera del alcance de este libro, pero este valor de G y su correspondiente valor- p pueden obtenerse de los resultados de regresión logística binaria que da Minitab. En el último renglón de la figura 15.13 se encuentra que el valor de G es 13.628, sus grados de libertad son 2 y su correspondiente valor- p es 0.001. Por lo tanto, empleando cualquier nivel de significancia $\alpha \geq 0.001$, se rechazará la hipótesis nula y se concluirá que el modelo global es significativo.

Una vez que la prueba G ha indicado que sí existe una significancia global, para determinar si la contribución de cada una de las variables independientes al modelo es significativa, se suele realizar una prueba z . Para cada una de las variables independientes x_i las hipótesis son

$$H_0: \beta_i = 0$$

$$H_a: \beta_i \neq 0$$

Si la hipótesis nula es verdadera, el valor del coeficiente estimado dividido entre su error estándar seguirá una distribución de probabilidad normal estándar. En los resultados de Minitab, en la columna que tiene como título Z se presentan los valores de $z_i = b_i/s_{b_i}$ correspondientes a cada uno de los coeficientes estimados, y en la columna que tiene como título p se encuentran sus valores $-p$ correspondientes. Supóngase que en el modelo de Simmons se emplea $\alpha = 0.05$ para probar la significancia de las variables independientes. Para la variable independiente x_1 , el valor z es 2.66 y su correspondiente valor- p es 0.008. Por lo tanto, para el nivel de significancia 0.05 se rechaza $H_0: \beta_1 = 0$. De la misma manera se rechaza $H_0: \beta_2 = 0$ dado que el valor- p correspondiente a $z = 2.47$ es 0.013. Por lo tanto, empleando como nivel de significancia 0.05, ambas variables son estadísticamente significativas.

Uso en la administración

Ya se describió cómo obtener la ecuación de regresión logística estimada y cómo probar su significancia. Ahora se usará esto para hacer una recomendación para la decisión que tienen que tomar en Simmons Stores respecto a la promoción con su catálogo. Ya se calcularon $P(y = 1|x_1 = 2, x_2 = 1) = 0.4099$ y $P(y = 1|x_1 = 2, x_2 = 0) = 0.1880$. De acuerdo con estas probabilidades, se ve que entre aquellos clientes que cuyo gasto anual en Simmons Stores es de \$2000, los clientes que tienen tarjeta de crédito de Simmons tienen mayor probabilidad de hacer uso del cupón. En la tabla 15.12 se presentan las probabilidades estimadas correspondientes a clientes, tanto con tarjeta de crédito como sin tarjeta de crédito de Simmons, cuyos desembolsos anuales en Simmons Stores son desde \$1000 hasta \$7000. ¿Cómo puede Simmons emplear esta información para elegir los clientes a los que dirigirá la nueva promoción? Supóngase que Simmons desea enviar este catálogo promocional únicamente a clientes cuya probabilidad de hacer uso del cupón sea 0.40 o mayor. Empleando las probabilidades estimadas que aparecen en la tabla 15.12 la estrategia en esta promoción de Simmons sería:

Clientes que tienen tarjeta de crédito de Simmons: Enviar el catálogo a todos los clientes que durante el pasado año hayan gastado \$2000 o más.

TABLA 15.12 PROBABILIDADES ESTIMADAS PARA SIMMONS STORES

		Cantidad anual gastada						
		\$1000	\$2000	\$3000	\$4000	\$5000	\$6000	\$7000
Tarjeta de crédito	Sí	0.3305	0.4099	0.4943	0.5790	0.6593	0.7314	0.7931
	No	0.1413	0.1880	0.2457	0.3143	0.3921	0.4758	0.5609

Cientes sin tarjeta de crédito de Simmons: Enviar el catálogo a todos los clientes que durante el pasado año hayan gastado \$6000 o más.

Sin embargo, observando con más detenimiento las probabilidades estimadas se ve que la probabilidad de que usen el cupón aquellos clientes sin tarjeta de crédito de Simmons que gastaron \$5000 en Simmons en un año, es 0.3921. Por lo tanto, será conveniente que Simmons reconsidere su estrategia e incluya en ella a aquellos clientes que no tienen tarjeta de crédito pero que gasten en Simmons \$5000 o más en un año.

Interpretación de la ecuación de regresión logística

Para interpretar una ecuación de regresión se necesita relacionar las variables independientes de la ecuación con la cuestión de negocios a la que se trató de responder con esa ecuación. En la regresión logística, debido a que la ecuación de regresión logística no es lineal, es difícil interpretar directamente la relación entre las variables independientes y la probabilidad de que $y = 1$. Sin embargo, se ha demostrado que esta relación se puede interpretar indirectamente empleando un concepto llamado cociente de posibilidades (en inglés, odds ratio).

Las **posibilidades a favor de que ocurra un evento** se definen como la probabilidad de que ocurra el evento, dividida entre la probabilidad de que no ocurra el evento. En la regresión logística el evento de interés es siempre $y = 1$. Dado un determinado conjunto de valores de las variables independientes, las posibilidades a favor de $y = 1$ se calculan como sigue:

$$\text{odds} = \frac{P(y = 1 | x_1, x_2, \dots, x_p)}{P(y = 0 | x_1, x_2, \dots, x_p)} = \frac{P(y = 1 | x_1, x_2, \dots, x_p)}{1 - P(y = 1 | x_1, x_2, \dots, x_p)} \quad (15.33)$$

El **cociente de posibilidades** mide el efecto que tiene sobre estas posibilidades el aumento en una unidad de una sola de las variables independientes. El cociente de posibilidades es la probabilidad de que $y = 1$ cuando una de las variables independientes es incrementada en una unidad (odds_1) dividida entre las posibilidades de que $y = 1$ cuando no ha habido cambio en los valores de las variables independientes (odds_0).

COCIENTE DE POSIBILIDADES

$$\text{Cociente de posibilidades} = \frac{\text{odds}_1}{\text{odds}_0} \quad (15.34)$$

Por ejemplo, supóngase que se desean comparar las posibilidades de que use el cupón un cliente que gasta \$2000 anuales y tiene tarjeta de crédito de Simmons ($x_1 = 2$ y $x_2 = 1$) con las posibilidades de que use el cupón un cliente que gasta \$2000 anuales y no tiene tarjeta de crédito de Simmons ($x_1 = 2$ y $x_2 = 0$). Lo que interesa es interpretar el efecto que tiene un incremento de la variable independiente x_2 en una unidad. En este caso

$$\text{odds}_1 = \frac{P(y = 1 | x_1 = 2, x_2 = 1)}{1 - P(y = 1 | x_1 = 2, x_2 = 1)}$$

y

$$\text{odds}_0 = \frac{P(y = 1 | x_1 = 2, x_2 = 0)}{1 - P(y = 1 | x_1 = 2, x_2 = 0)}$$

Como ya se demostró, la estimación de la probabilidad de que $y = 1$ cuando $x_1 = 2$ y $x_2 = 1$ es 0.4099 y la estimación de que $y = 1$ cuando $x_1 = 2$ y $x_2 = 0$ es 0.1880. Por lo tanto,

$$\text{estimación de odds}_1 = \frac{0.4099}{1 - 0.4099} = 0.6946$$

y

$$\text{estimación de odds}_0 = \frac{0.1880}{1 - 0.1880} = 0.2315$$

La estimación del cociente de posibilidades es

$$\text{Estimación del cociente de posibilidades} = \frac{0.6946}{0.2315} = 3.00$$

Por lo tanto, se puede concluir que las posibilidades estimadas de que usen el cupón los clientes que gastaron \$2000 el año pasado y tienen tarjeta de crédito de Simmons son tres veces mayores que las posibilidades estimadas de que usen el cupón los clientes que gastaron \$2000 el año pasado y no tienen tarjeta de crédito de Simmons.

El cociente de posibilidades de cada una de las variables independientes se calcula manteniendo constantes todas las demás variables. Sin embargo, qué valores constantes se usen para todas las demás variables no tiene importancia. Por ejemplo, si se calcula el cociente de posibilidades para la variable tarjeta de crédito de Simmons (x_2) empleando, como valor de la variable cantidad de gasto anual (x_1), \$3000 en lugar de \$2000, el valor obtenido para el cociente de posibilidad estimado será el mismo (3.00). Por lo tanto, se concluye que las posibilidades estimadas de que use el cupón un cliente que tiene tarjeta de crédito de Simmons son tres veces mayores que las posibilidades estimadas de que use el cupón un cliente que no tiene tarjeta de crédito de Simmons.

El cociente de posibilidades aparece en los resultados estándar de la regresión logística proporcionados por los paquetes de software para estadística. Refiérase a los resultados de Minitab que se presentan en la figura 15.13. En la columna titulada Odds Ratio aparecen los cocientes de posibilidad estimados correspondientes a cada una de las variables independientes. El cociente de posibilidad estimada para x_1 es 1.41 y el cociente de posibilidad estimada para x_2 es 3.00. Ya se indicó antes cómo interpretar el coeficiente de posibilidad estimada en el caso de la variable binaria independiente x_2 . Ahora se considerará la interpretación del cociente de posibilidades en el caso de la variable continua independiente x_1 .

El valor 1.41 en la columna titulada Odds Ratio (cociente de posibilidades) de los resultados de Minitab indica que la posibilidad estimada de que use el cupón un cliente que gastó \$3000 durante el año pasado es 1.41 veces mayor que la probabilidad estimada de que use el cupón un cliente que gastó \$2000 durante el año pasado. Más aún, esta interpretación es correcta para cualquier cambio en una unidad de x_1 . Por ejemplo, las posibilidades estimadas de que use el cupón un cliente cuyo gasto anual el año pasado fue \$5000 son 1.41 veces mayores que las posibilidades estimadas de que use el cupón un cliente cuyo gasto anual el año pasado fue \$4000. Pero, supóngase que interesa la variación en las posibilidades cuando hay un incremento de más de una unidad en cualquiera de las variables independientes. Obsérvese que x_1 toma valores desde 1 hasta 7. El cociente de posibilidades presentado en los resultados de Minitab no responde a esta pregunta. Para responder a esta pregunta es necesario explorar la relación entre el cociente de posibilidades y los coeficientes de regresión.

Existe una relación única entre el cociente de posibilidades de una variable y su correspondiente coeficiente de regresión. Se puede demostrar que para toda variable independiente de una ecuación de regresión logística

$$\text{Cociente de posibilidades} = e^{\beta_i}$$

Para ilustrar esta relación, empleando el ejemplo de Simmons Stores considérese la variable independiente x_1 . El cociente de posibilidades estimado para x_1 es

$$\text{Cociente de posibilidades estimado} = e^{b_1} = e^{0.3416} = 1.41$$

De manera similar, el cociente de posibilidades estimado para x_2 es

$$\text{Cociente de posibilidades estimado} = e^{b_2} = e^{1.0987} = 3.00$$

Esta relación entre el cociente de posibilidades y los coeficientes de las variables independientes facilitan el cálculo del cociente de posibilidades una vez obtenidas las estimaciones de los parámetros del modelo. Además, esto permite también investigar cambios en el cociente de posibilidades cuando hay cambios mayores o menores a una unidad en una de las variables continuas independientes.

El cociente de posibilidades de una variable independiente representa la variación que hay en las posibilidades por una variación de una unidad en la variable independiente permaneciendo constantes todas las demás variables independientes. Supóngase que se desea conocer el efecto de una variación de más de una unidad, por ejemplo de c unidades. Supóngase que, en el ejemplo de Simmons, se quieren comparar las posibilidades de que use el cupón un cliente que gasta \$5000 anuales ($x_1 = 5$) con las posibilidades de que use el cupón un cliente que gasta \$2000 anuales ($x_1 = 2$). En este caso $c = 5 - 2 = 3$ y el correspondiente cociente de posibilidades es

$$e^{cb_1} = e^{3(0.3416)} = e^{1.0248} = 2.79$$

Esto indica que las posibilidades estimadas de que usen el cupón los clientes cuyo gasto anual es de \$5000 son 2.70 veces mayores que las posibilidades estimadas de que usen el cupón los clientes cuyo gasto anual es de \$2000. En otras palabras, el cociente de posibilidades estimado para un aumento de \$3000 en los gastos anuales es 2.79.

En general, el cociente de posibilidades permite comparar las posibilidades de dos eventos diferentes. Si el cociente de posibilidades es 1, los dos eventos tienen las mismas posibilidades. Por lo tanto, si la variable independiente que se considera (como, por ejemplo, el estatus respecto a la tarjeta de crédito de Simmons) tiene efecto positivo sobre la probabilidad de que ocurra el evento el cociente de posibilidades correspondiente será mayor a 1. La mayor parte de los paquetes de software para estadística dan también un intervalo de confianza para el cociente de posibilidades. En la figura 15.13 los resultados de Minitab presentados proporcionan un intervalo de 95% de confianza para cada uno de los cocientes de posibilidades. Por ejemplo, la estimación puntual del cociente de posibilidad de x_1 es 1.41 y el intervalo de 95% de confianza va de 1.09 a 1.81. Como el intervalo de confianza no contiene el valor 1, se concluye que x_1 tiene un efecto significativo sobre el cociente de posibilidades estimado. De manera similar, el intervalo de 95% de confianza para el cociente de posibilidades de x_2 va de 1.25 a 7.17. Como este intervalo tampoco contiene el valor 1, se puede concluir también que x_2 tiene un efecto significativo sobre el cociente de posibilidades.

Transformación logit

Entre las posibilidades a favor de $y = 1$ y el exponente de e en la ecuación de regresión logística, se puede observar una interesante relación. Se puede demostrar que

$$\ln(\text{odds}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Esta ecuación indica que el logaritmo natural de las posibilidades a favor de $y = 1$ es función lineal de las variables independientes. A esta función lineal se le llama **logit**. Para denotar el logit se empleará la notación $g(x_1, x_2, \dots, x_p)$.

LOGIT

$$g(x_1, x_2, \dots, x_p) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \quad (15.35)$$

Sustituyendo en la ecuación (15.27) $\beta_1 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$ por $g(x_1, x_2, \dots, x_p)$, la ecuación de regresión logística se puede expresar como

$$E(y) = \frac{e^{g(x_1, x_2, \dots, x_p)}}{1 + e^{g(x_1, x_2, \dots, x_p)}} \quad (15.36)$$

Una vez estimados los parámetros de la ecuación de regresión logística, se puede calcular una estimación del logit. Empleando $\hat{g}(x_1, x_2, \dots, x_p)$ para denotar el **logit estimado**, se tiene

LOGIT ESTIMADO

$$\hat{g}(x_1, x_2, \dots, x_p) = b_0 + b_1 x_1 + b_2 x_2 + \cdots + b_p x_p \quad (15.37)$$

Por lo tanto, en términos del logit estimado, la ecuación de regresión estimada es

$$\hat{y} = \frac{e^{b_0 + b_1 x_1 + b_2 x_2 + \cdots + b_p x_p}}{1 + e^{b_0 + b_1 x_1 + b_2 x_2 + \cdots + b_p x_p}} = \frac{e^{\hat{g}(x_1, x_2, \dots, x_p)}}{1 + e^{\hat{g}(x_1, x_2, \dots, x_p)}} \quad (15.38)$$

En el ejemplo de Simmons Stores, el logit estimado es

$$\hat{g}(x_1, x_2) = -2.1464 + 0.3416x_1 + 1.0987x_2$$

y la ecuación de regresión estimada es

$$\hat{y} = \frac{e^{\hat{g}(x_1, x_2)}}{1 + e^{\hat{g}(x_1, x_2)}} = \frac{e^{-2.1464 + 0.3416x_1 + 1.0987x_2}}{1 + e^{-2.1464 + 0.3416x_1 + 1.0987x_2}}$$

Por lo tanto, debido a la relación única que existe entre el logit estimado y la ecuación de regresión logística estimada, es posible calcular las probabilidades estimadas para Simmons Stores dividiendo $e^{\hat{g}(x_1, x_2)}$ entre $1 + e^{\hat{g}(x_1, x_2)}$.

NOTAS Y COMENTARIOS

1. Debido a la relación única que existe entre los coeficientes estimados del modelo y los correspondientes cocientes de posibilidades, la prueba general de significancia basada en el estadístico G es también una prueba general de significancia para los cocientes de posibilidades. Además, la prueba z para la significancia de cada uno de los parámetros del modelo es también una prueba estadística para los correspondientes cocientes de posibilidades.
2. En la regresión simple y en la regresión múltiple, se usa el coeficiente de determinación para medir la bondad de ajuste. En la regresión logística no hay una sola medida que tenga una interpretación similar. El estudio de la bondad de ajuste queda fuera del alcance de esta introducción a la regresión logística.

Ejercicios

Aplicaciones

44. Vaya al ejemplo de Simmons Stores presentado en esta sección. La variable dependiente es $y=1$ si el cliente usó el cupón y $y=0$ si no lo usó. Supóngase que la única información de que se dispone para predecir si un cliente usará o no el cupón es el estatus del cliente respecto a la posesión de una tarjeta de crédito de la empresa, que es $x=1$ si el cliente tiene tarjeta de crédito de Simmons y $x=0$ si no es así.
 - a. Dé la ecuación de regresión logística que relaciona x y y .
 - b. ¿Cuál es la interpretación de $E(y)$ cuando $x=0$?

- c. Empleando los datos de Simmons presentados en la tabla 15.11, use Minitab para calcular el logit estimado.
 - d. Empleando el logit estimado obtenido en el inciso c), obtenga una estimación de la probabilidad de que usen el cupón los clientes que no tienen tarjeta de crédito de Simmons y una estimación de la probabilidad de que usen el cupón los clientes que no tienen tarjeta de crédito de Simmons.
 - e. De la estimación del cociente de posibilidades. ¿Cuál es su interpretación?
45. En la tabla 15.12 se proporcionaron estimaciones de las probabilidades de uso del cupón en la promoción mediante catálogo de Simmons Stores. Para cada combinación de valores de las variables independientes se obtuvo un valor diferente.
- a. Calcule las posibilidades de que use el cupón un cliente cuyo gasto anual en Simmons es de \$4000 y que no tiene tarjeta de crédito de Simmons ($x_1 = 4$, $x_2 = 0$).
 - b. Use la información de la tabla 15.12 y el inciso a) para calcular el cociente de posibilidades para la variable tarjeta de crédito de Simmons $x_2 = 0$ manteniendo constantes los gastos anuales en $x_1 = 4$.
 - c. En el libro, el cociente de posibilidades para la variable tarjeta de crédito se calculó empleando la información presentada en la columna \$2000 de la tabla 15.12. ¿Obtuvo, en el inciso b), la misma información para el valor del cociente de posibilidades?
46. El Community Bank desea aumentar la cantidad de clientes a los que les depositan directamente su nómina. El gerente está considerando una campaña que requerirá que cada gerente de sucursal llame a cada cliente que no reciba directamente su nómina. Como incentivo para aceptar recibir directamente su nómina, se les ofrecerá revisión gratuita de su cuenta durante dos años. Debido al tiempo y a los costos de esta campaña, el gerente desea que esta campaña se dirija a aquellos clientes que tengan la mayor probabilidad de aceptar recibir directamente su nómina. El gerente piensa que el saldo promedio mensual en la cuenta de cheques del cliente puede ser un predictor útil para determinar si un cliente aceptará o no recibir directamente su nómina. Para investigar la relación entre estas dos variables, Community Bank prueba la nueva campaña utilizando una muestra de cuentas de cheques de 50 clientes que actualmente no reciben directamente su nómina. En los datos muestrales se presenta el saldo mensual promedio en la cuenta de cheques (en miles de dólares) y si el cliente aceptó recibir directamente el depósito de su nómina (1 significa aceptó el depósito directo de su nómina y 0 significa el cliente no aceptó el depósito directo de su nómina). Estos datos se encuentran en el archivo Bank del disco compacto; a continuación se presenta parte de estos datos.



Cliente	x = saldo mensual	y = depósito directo
1	1.22	0
2	1.56	0
3	2.10	0
4	2.25	0
5	2.89	0
6	3.55	0
7	3.56	0
8	3.65	1
.	.	.
.	.	.
48	18.45	1
49	24.98	0
50	26.05	1

- a. Dé la ecuación de regresión logística que relaciona x y y .
- b. Empleando los datos de Community Bank, use Minitab para calcular la ecuación de regresión logística estimada.
- c. Realice una prueba de significancia empleando el estadístico de prueba G . Use $\alpha = 0.05$.

- d. Estime la probabilidad de que los clientes cuyo saldo mensual promedio sea \$1000 acepten recibir directamente el depósito de su nómina.
- e. Supóngase que Community Bank desea contactar únicamente a los clientes para los que la probabilidad de aceptar recibir directamente su nómina sea de 0.50 o mayor. ¿Cuál es el saldo promedio requerido para tener esta probabilidad?
- f. Dé la estimación del cociente de posibilidades. ¿Cuál es su interpretación?
47. En los últimos años en Lakeland Collage ha aumentado el porcentaje de estudiantes que abandonan sus estudios después del primer año. El año pasado, Lakeland Collage inició un programa voluntario de orientación para ayudar a los estudiantes de primer año a que se adapten a la vida del campus. Si Lakeland Collage demuestra que ese programa tiene resultados positivos, se considerará la posibilidad de que el programa sea obligatorio para todos los estudiantes de primer año. La administración de Lakeland Collage supone que los estudiantes que tienen GPA bajo son los que tienen mayor probabilidad de abandonar los estudios al final del primer año. Con objeto de investigar la relación de estas variables con la permanencia de los estudiantes en la escuela, Lakeland Collage tomó una muestra aleatoria de 100 estudiantes de primer año. Los datos se encuentran en el archivo Lakeland del disco compacto; a continuación se reproduce parte de esos datos.



Estudiante	GPA	Programa	Resultado
1	3.78	1	1
2	2.38	0	1
3	1.30	0	0
4	2.19	1	0
5	3.22	1	1
6	2.68	1	1
⋮	⋮	⋮	⋮
98	2.57	1	1
99	1.70	1	1
100	3.85	1	1

La variable dependiente toma el valor $y = 1$ si el estudiante permanece en la escuela y $y = 0$ si no es así. Las dos variables independientes son

$x_1 =$ GPA al final del primer semestre

$x_2 = \begin{cases} 0 & \text{si el estudiante participa en el programa de orientación} \\ 1 & \text{si el estudiante no participa en el programa de orientación} \end{cases}$

- a. Dé la ecuación de regresión logística que relaciona x_1 y x_2 con y .
- b. Dé la interpretación de $E(y)$ cuando $x_2 = 0$.
- c. Use las dos variables independientes y Minitab para calcular el logit estimado.
- d. Realice una prueba de significancia global empleando $\alpha = 0.05$.
- e. Empleando $\alpha = 0.05$, determine si cada una de las variables independientes son significativas.
- f. Use el logit estimado del inciso c) para obtener una estimación de la probabilidad de que un estudiante cuyo GPA es 2.5 y que no participó en el programa de orientación permanezca en la escuela. ¿Cuál es la estimación de esta probabilidad para un estudiante cuyo GPA es 2.5 y que sí participó en el programa de orientación?
- g. Dé la estimación del cociente de posibilidades para el programa de orientación. Interprete.
- h. ¿Recomendaría convertir el programa de orientación en un programa obligatorio? ¿Por qué sí o por qué no?
48. *Consumer Report* le realizó una prueba de sabor a 19 marcas de chocolates. En los datos a continuación se da el precio por porción, en base al tamaño de porción de la FDA que es de 1.4 onzas, así como una evaluación de la calidad de los 19 chocolates tomados para la prueba (*Consumer Report*, febrero 2002).



Fabricante	Precio	Evaluación
Bernard Callebaut	3.17	muy bueno
Candinas	3.58	excelente
Fannie May	1.49	bueno
Godiva	2.91	muy bueno
Hershey's	0.76	bueno
L.A. Burdick	3.70	muy bueno
La Maison du Chocolate	5.08	excelente
Leonidas	2.11	muy bueno
Lindt	2.20	bueno
Martine's	4.76	excelente
Michael Recchiuti	7.05	muy bueno
Neuchatel	3.36	bueno
Neuchatel Sugar Free	3.22	bueno
Richard Donnelly	6.55	muy bueno
Russell Stover	0.70	bueno
See's	1.06	muy bueno
Teuscher Lake of Zurich	4.66	muy bueno
Whitman's	0.70	regular
Whitman's Sugar Free	1.21	regular

Suponga que desea determinar si los productos que son más caros son mejor evaluados. Para los propósitos de este ejercicio, emplee la siguiente variable binaria dependiente.

$y = 1$ si la evaluación de la calidad fue excelente o muy buena
 $y = 0$ si la evaluación de la calidad fue buena o regular.

- Dé la ecuación de regresión logística que relaciona x = precio por porción con y .
- Use Minitab para calcular el logit estimado.
- Use el logit estimado que obtuvo en el inciso b) para obtener una estimación de la probabilidad de que la evaluación de un chocolate cuyo precio por porción es \$4.00 sea muy bueno o excelente.
- Dé la estimación del cociente de posibilidades. Dé su interpretación.

Resumen

En este capítulo se presentó la regresión múltiple como extensión del análisis de regresión lineal simple presentado en el capítulo 14. El análisis de regresión múltiple permite entender cómo está relacionada una variable dependiente con dos o más variables independientes. La ecuación de regresión $E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$ indica que el valor esperado o valor medio de la variable dependiente y está relacionado con los valores de las variables independientes $x_1, x_2, \dots, x_p$. Para obtener la ecuación de regresión estimada $\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p$ se emplean los datos muestrales y el método de mínimos cuadrados. En efecto $b_1, b_2, \dots, b_p$ son estadísticos muestrales que se emplean para estimar los parámetros desconocidos $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ del modelo. Para hacer énfasis en el hecho de que los paquetes de software para estadística son los únicos medios realistas para realizar los numerosos cálculos que se requieren en el análisis de regresión múltiple, a lo largo de todo el capítulo se emplearon las impresiones de computadora.

El coeficiente de determinación múltiple se presentó como una medida de la bondad de ajuste de la ecuación de regresión estimada. Este coeficiente determina la proporción de la variación en y que puede ser explicada por la ecuación de regresión estimada. El coeficiente de determinación múltiple ajustado es una medida similar de bondad de ajuste que se adapta al número de variables independientes evitando, de esta manera, sobreestimar el efecto de la adición de más variables independientes.

Como un medio para determinar estadísticamente si la relación entre las variables era significativa se presentaron una prueba F y una prueba t . La prueba F sirve para determinar si existe

una relación global significativa entre la variable dependiente y el conjunto de todas las variables independientes. La prueba t se usa para determinar si existe una relación significativa entre la variable dependiente y una determinada variable independiente del modelo de regresión. Se trató la relación entre las variables independientes, a lo cual se le llama multicolinealidad.

En la sección sobre variables cualitativas independientes se mostró el uso de variables ficticias para incorporar datos cualitativos en el análisis de regresión múltiple. En la sección sobre análisis residual se mostró el uso del análisis residual para confirmar las suposiciones del modelo, detectar observaciones atípicas e identificar observaciones influyentes. Se estudiaron los residuales estandarizados, la influencia, los residuales eliminados estudentizados y la medida de la distancia de Cook. El capítulo se concluyó con una sección sobre el uso de la regresión logística para modelar situaciones en las que la variable dependiente sólo puede asumir dos valores.

Glosario

Análisis de regresión múltiple Análisis de regresión en el que hay dos o más variables independientes.

Modelo de regresión múltiple Ecuación matemática que describe cómo está relacionada la variable dependiente y con las variables independientes $x_1, x_2, \dots, x_p$ y con el término del error ϵ .

Ecuación de regresión múltiple Ecuación matemática que relaciona el valor esperado o valor medio de la variable dependiente con los valores de las variables independientes. Es decir $E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$.

Ecuación de regresión múltiple estimada Estimación de la ecuación de regresión múltiple que se basa en datos muestrales y en el método de mínimos cuadrados; es $\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p$.

Método de mínimos cuadrados Método empleado para obtener la ecuación de regresión estimada. Mediante este método se minimiza la suma de los cuadrados de los residuales (la desviación (diferencia) que existe entre los valores observados de la variable dependiente, y_i , y los valores estimados de la variable dependiente $\hat{y}_i$).

Coefficiente de determinación múltiple Medida de la bondad de ajuste de la ecuación de regresión múltiple estimada. Se puede interpretar como la proporción en la variabilidad de la variable dependiente que es explicada por la ecuación de regresión estimada.

Coefficiente de determinación múltiple ajustado Medida de la bondad de ajuste de la ecuación de regresión múltiple estimada, pero modifica de acuerdo con el número de variables independientes en el modelo para evitar, de esta manera, sobreestimar el efecto que tiene agregar más variables independientes.

Multicolinealidad Término usado para describir la correlación entre las variables independientes.

Variable cualitativa independiente Variable independiente con datos cualitativos.

Variable ficticia Variable usada para modelar el efecto de las variables cualitativas independientes. Las variables ficticias sólo toman los valores cero y uno.

Influencia Mide qué tan lejos de su media se encuentran los valores de las variables independientes.

Observación atípica Observación que se sale del patrón que sigue el resto de las observaciones.

Residuales eliminados estudentizados Residuales estandarizados que se basan en un error estándar de estimación corregido que se obtuvo al eliminar la observación i del conjunto de datos y realizar después el análisis de regresión y los cálculos.

Observación influyente Observación que tiene una gran influencia en los resultados de la regresión.

Medida de la distancia de Cook Medida de la influencia de una observación que se basa tanto en la influencia (leverage) de la observación i como en el residual de la observación i .

Ecuación de regresión logística Ecuación matemática que relaciona $E(y)$, la probabilidad de que $y = 1$, con los valores de las variables independientes; es decir $E(y) = P(y = 1 | x_1, x_2, \dots, x_p) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}$.

Ecuación de regresión logística estimada Estimación de la ecuación de regresión logística que se basa en datos muestrales; es decir $\hat{y}$ = estimación de $P(y = 1|x_1, x_2, \dots, x_p) =$

$$\frac{e^{b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p}}{1 + e^{b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p}}.$$

Posibilidades a favor de la ocurrencia de un evento Probabilidad de que ocurra el evento entre la probabilidad de que no ocurra el evento.

Cociente de posibilidades El cociente que se obtiene al dividir la posibilidad de que $y = 1$ dado que una de las variables independientes aumentó en una unidad (odds_1) entre la posibilidad de que $y = 1$ dado que no hay ninguna variación en los valores de las variables independientes (odds_0); es decir, cociente de posibilidades (odds ratio) = (odds_1)/(odds_0).

Logit Logaritmo natural de las posibilidades a favor de $y = 1$; es decir $g(x_1, x_2, \dots, x_p) = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p$.

Logit estimado Estimación del logit basada en datos muestrales; es decir $\hat{g}(x_1, x_2, \dots, x_p) = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p$.

Fórmulas clave

Modelo de regresión múltiple

$$y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p + \epsilon \quad (15.1)$$

Ecuación de regresión múltiple

$$E(y) = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p \quad (15.2)$$

Ecuación de regresión múltiple estimada

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p \quad (15.3)$$

Criterio de mínimos cuadrados

$$\min \sum (y_i - \hat{y}_i)^2 \quad (15.4)$$

Relación entre STC, SCR y SCE

$$\text{STC} = \text{SCR} + \text{SCE} \quad (15.7)$$

Coefficiente de determinación múltiple

$$R^2 = \frac{\text{SCR}}{\text{STC}} \quad (15.8)$$

Coefficiente de determinación múltiple ajustado

$$R_a^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} \quad (15.9)$$

Cuadrado medio debido a la regresión

$$\text{CMR} = \frac{\text{SCR}}{p} \quad (15.12)$$

Cuadrado medio debido al error

$$\text{CME} = \frac{\text{SCE}}{n - p - 1} \quad (15.13)$$

Estadístico de prueba F

$$F = \frac{\text{CMR}}{\text{CME}} \quad (15.14)$$

Estadístico de prueba t

$$t = \frac{b_i}{s_{b_i}} \quad (15.15)$$

Residual estandarizado de la observación i

$$\frac{y_i - \hat{y}_i}{s_{y_i - \hat{y}_i}} \quad (15.23)$$

Desviación estándar del residual i

$$s_{y_i - \hat{y}_i} = s\sqrt{1 - h_i} \quad (15.24)$$

Medida de la distancia de Cook

$$D_i = \frac{(y_i - \hat{y}_i)^2}{(p - 1)s^2} \left[\frac{h_i}{(1 - h_i)^2} \right] \quad (15.25)$$

Ecuación de regresión logística

$$E(y) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}} \quad (15.27)$$

Ecuación de regresión logística estimada

$$\hat{y} = \text{estimación de } P(y = 1 | x_1, x_2, \dots, x_p) = \frac{e^{b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p}}{1 + e^{b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p}} \quad (15.30)$$

Cociente de posibilidades (*odds ratio*)

$$\text{Cociente de posibilidades (Odds ratio)} = \frac{\text{odds}_1}{\text{odds}_0} \quad (15.34)$$

Logit

$$g(x_1, x_2, \dots, x_p) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (15.35)$$

Logit estimado

$$\hat{g}(x_1, x_2, \dots, x_p) = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p \quad (15.37)$$

Ejercicios complementarios

49. El departamento de admisión de Clearwater Collage obtuvo la siguiente ecuación de regresión estimada en la que relaciona el promedio final obtenido en la universidad (GPA) con la puntuación del estudiante en el área de matemáticas del examen de admisión a la universidad (SAT) y con su promedio final (GAP) en bachillerato.

$$\hat{y} = -1.41 + 0.0235x_1 + 0.00486x_2$$

donde

x_1 = promedio final en el bachillerato

x_2 = puntuación en el área de matemáticas
admisión (SAT)

y = promedio final en la universidad

- Interprete los coeficientes de esta ecuación de regresión estimada.
 - Estime el promedio final (GPA) en la universidad de un estudiante cuyo promedio en el bachillerato sea 84 y cuya puntuación en el área de matemáticas del examen de admisión (SAT) es 540.
50. El director de personal de Electronics Associates obtuvo la siguiente ecuación de regresión estimada que relaciona la puntuación obtenida por un empleado en un examen sobre su satisfacción con el trabajo con la antigüedad y el salario del empleado.

$$\hat{y} = 14.4 - 8.69x_1 + 13.5x_2$$

donde

x_1 = antigüedad (años)

x_2 = salario (dólares)

y = puntuación en el examen sobre satisfacción
con el trabajo (puntuaciones más altas corres-
ponden a mayor satisfacción con el trabajo)

- Interprete los coeficientes de esta ecuación de regresión estimada.
 - Estime la puntuación obtenida en el examen sobre satisfacción con el trabajo que tendrá un empleado cuya antigüedad es de cuatro años y que gana \$6.50 por hora.
51. A continuación se presentan los resultados, incompletos, obtenidos con un paquete de software para un análisis de regresión.

The regression equation is
 $Y = 8.103 + 7.602 X1 + 3.111 X2$

Predictor	Coef	SE Coef	T
Constant	_____	2.667	_____
X1	_____	2.105	_____
X2	_____	0.613	_____

S = 3.335 R-sq = 92.3% R-sq(adj) = _____%

Analysis of Variance

SOURCE	DF	SS	MS	F
Regression	_____	1612	_____	_____
Residual Error	12	_____	_____	_____
Total	_____	_____	_____	_____

- a. Calcule los cocientes t adecuados
 - b. Pruebe la significancia de β_1 y β_2 empleando $\alpha = 0.05$.
 - c. Calcule las cantidades que faltan en las columnas DF, SS y MS.
 - d. Calcule R_a^2 .
52. En el ejercicio 49, se vio que el departamento de admisión de Clearwater Collage obtuvo la siguiente ecuación de regresión estimada en la que relacionaba el promedio final obtenido en la universidad (GPA) con la puntuación de un estudiante en el área de matemáticas del examen de admisión a la universidad (SAT) y con su promedio final (GAP) en bachillerato.

$$\hat{y} = -1.41 + 0.0235x_1 + 0.00486x_2$$

donde

- x_1 = promedio final en el bachillerato
 x_2 = puntuación en el área de matemáticas del examen de admisión (SAT)
 y = promedio final en la universidad

A continuación se presentan los resultados, incompletos, obtenidos con Minitab.

The regression equation is

$$Y = -1.41 + .0235 X_1 + .00486 X_2$$

Predictor	Coef	SE Coef	T
Constant	-1.4053	0.4848	_____
X1	0.023467	0.008666	_____
X2	_____	0.001077	_____

S = 0.1298 R-sq = _____ R-sq(adj) = _____

Analysis of Variance

SOURCE	DF	SS	MS	F
Regression	_____	1.76209	_____	_____
Residual Error	_____	_____	_____	_____
Total	9	1.88000	_____	_____

- a. Calcule las cantidades faltantes en estos resultados.
 - b. Calcule F y empleando como nivel de significancia $\alpha = 0.05$ pruebe si existe una relación significativa.
 - c. ¿Proporciona la ecuación de regresión estimada un buen ajuste a los datos? Explique.
 - d. Use la prueba t y $\alpha = 0.05$ para probar $H_0: \beta_1 = 0$ y $H_0: \beta_2 = 0$.
53. En el ejercicio 50 se vio que el director de personal de Electronics Associates obtuvo la siguiente ecuación de regresión estimada que relacionaba la puntuación obtenida por un empleado en un examen sobre su satisfacción con el trabajo con la antigüedad y el salario del empleado.

$$\hat{y} = 14.4 - 8.69x_1 + 13.5x_2$$

donde

- x_1 = antigüedad (años)
 x_2 = salario (dólares)
 y = puntuación en el examen sobre satisfacción con el trabajo (puntuaciones más altas corresponden a mayor satisfacción con el trabajo)

A continuación se presentan los resultados, incompletos, obtenidos con Minitab

The regression equation is

$$Y = 14.4 - 8.69 X_1 + 13.52 X_2$$

Predictor	Coef	SE Coef	T
Constant	14.448	8.191	1.76
X1	<u> </u>	1.555	<u> </u>
X2	13.517	2.085	<u> </u>

S = 3.773 R-sq = % R-sq(adj) = %

Analysis of Variance

SOURCE	DF	SS	MS	F
Regression	2	<u> </u>	<u> </u>	<u> </u>
Residual Error	<u> </u>	71.17	<u> </u>	
Total	7	720.0		

- Calcule las cantidades faltantes en estos resultados.
 - Calcule F y empleando como nivel de significancia 0.05 pruebe si la relación es significativa.
 - ¿Proporciona la ecuación de regresión estimada un buen ajuste a los datos? Explique.
 - Use la prueba t y $\alpha = 0.05$ para probar $H_0: \beta_1 = 0$ y $H_0: \beta_2 = 0$.
54. La revista *SmartMoney* evaluó 65 zonas metropolitanas para determinar si el valor de las casas (*home values*) estaba cambiando (are headed). La puntuación para una ciudad ideal era 100 y significaba que todos los factores medidos eran tan favorables como era posible. Zonas cuya puntuación era 60 o más, eran zonas en las que era posible una revalorización de los precios; zonas cuya puntuación era menor a 50 eran zonas que podrían ver una disminución en el valor de la vivienda. Dos de los factores evaluados fueron resistencia a la recesión y accesibilidad de la zona. Estos dos factores se evaluaron empleando una escala de 0 (evaluación más baja) a 10 (evaluación más alta). A continuación se presentan los datos obtenidos en una muestra de 20 ciudades evaluadas por *SmartMoney* (*SmartMoney*, febrero de 2002).

Área metropolitana	Resistencia a la recesión	Accesibilidad	Puntuación
Tucson	10	7	70.7
Fort Worth	10	7	68.5
San Antonio	6	8	65.5
Richmond	8	6	63.6
Indianapolis	4	8	62.5
Philadelphia	0	10	61.9
Atlanta	2	6	60.7
Phoenix	4	5	60.3
Cincinnati	2	7	57.0
Miami	6	5	56.5
Hartford	0	7	56.2
Birmingham	0	8	55.7
San Diego	8	2	54.6
Raleigh	2	7	50.9
Oklahoma City	1	6	49.6
Orange County	4	2	49.1
Denver	4	4	48.6
Los Ángeles	0	7	45.7
Detroit	0	5	44.3
Nueva Orleáns	0	5	41.2

- a. Dé una ecuación de regresión estimada que sirva para dar la puntuación conociendo la resistencia a la recesión. Empleando como nivel de significancia 0.05, pruebe la significancia de la relación
- b. ¿Proporciona la ecuación obtenida en el inciso a) un buen ajuste a los datos? Explique.
- c. Obtenga una ecuación de regresión estimada que sirva para predecir la puntuación a partir de la resistencia a la recesión y la accesibilidad. Empleando como nivel de significancia 0.05 pruebe la significancia global.
55. *Consumer Reports* examinó ampliamente y presentó las evaluaciones de 24 caminadoras. A cada caminadora se le dio una calificación general que se basaba principalmente en su facilidad de uso, ergonomía, gama de ejercicio y calidad. En general, una mejor calificación corresponde a un mejor funcionamiento. En la información a continuación se presenta el precio, la evaluación de la calidad y la puntuación general de las 24 caminadoras (*Consumer Reports*, febrero de 2006).



Marca y modelo	Precio	Calidad	Calificación
Landice L7	2900	Excelente	86
NordicTrack S3000	3500	Muy buena	85
SportsArt 3110	2900	Excelente	82
Precor	3500	Excelente	81
True Z4 HRC	2300	Excelente	81
Vision Fitness T9500	2000	Excelente	81
Precor M 9.31	3000	Excelente	79
Vision Fitness T9200	1300	Muy buena	78
Star Trac TR901	3200	Muy buena	72
Trimline T350HR	1600	Muy buena	72
Schwinn 820p	1300	Muy buena	69
Bowflex 7-Series	1500	Excelente	83
NordicTrack S1900	2600	Muy buena	83
Horizon Fitness PST8	1600	Muy buena	82
Horizon Fitness 5.2T	1800	Muy buena	80
Evo by Smooth Fitness FX30	1700	Muy buena	75
ProForm 1000S	1600	Muy buena	75
Horizon Fitness CST4.5	1000	Muy buena	74
Keys Fitness 320t	1200	Muy buena	73
Smooth Fitness 7.1HR Pro	1600	Muy buena	73
NordicTrack C2300	1000	Bueno	70
Spirit Inspire	1400	Muy buena	70
ProForm 750	1000	Buena	67
Image 19.0 R	600	Buena	66

- a. Con estos datos obtenga una ecuación de regresión estimada que sirva para estimar la calificación general cuando se conoce el precio.
- b. Use $\alpha = 0.05$ para probar la significancia general.
- c. Para incorporar el efecto de la calidad, una variable cualitativa de tres niveles, se emplearon dos variables ficticias. Calidad-E y Calidad-MB. Cada variable toma los valores 0 y 1 como sigue.

$$\text{Calidad-E} = \begin{cases} 1 & \text{si evaluación de la calidad es excelente} \\ 0 & \text{si no es así} \end{cases}$$

$$\text{Calidad-MB} = \begin{cases} 1 & \text{si evaluación de la calidad es muy buena} \\ 0 & \text{si no es así} \end{cases}$$

Obtenga una ecuación de regresión estimada que sirva para estimar la puntuación general cuando se conoce el precio y la evaluación de la calidad.

- d. Empleando $\alpha = 0.10$ pruebe la significancia general de la ecuación de regresión estimada obtenida en el inciso c).
 - e. Use la prueba t para determinar la significancia de cada una de las variables independientes de la ecuación de regresión estimada obtenida en el inciso c). Use $\alpha = 0.10$.
 - f. Dé la gráfica de los residuales estandarizados. ¿Parece razonable la forma de la gráfica de residuales?
 - g. ¿Hay en estos datos alguna observación atípica o alguna observación influyente?
 - h. Estime la calificación general dada a una caminadora cuyo precio es \$2000 y que como evaluación de su calidad obtuvo buena. ¿Cuánto varía esta estimación si la evaluación de la calidad es muy buena? Explique.
56. La *Fuel Economy Guide* (guía de economía de combustible) del Departamento de energía de Estados Unidos proporciona datos sobre el rendimiento del combustible en automóviles y camiones. A continuación se presenta una parte de los datos obtenidos para 35 camiones furgonetas estándar producidos por Chevrolet y General Motors (www.fueleconomy.gov, 21 de marzo de 2003). En la columna titulada tracción se indica si el vehículo tiene tracción en dos ruedas (2WD) o tracción en cuatro ruedas (4WD). En la columna titulada desplazamiento se da el desplazamiento del motor en litros, en la columna titulada cilindros se especifica la cantidad de cilindros que tiene el motor, y en la columna titulada transmisión se indica si la furgoneta tiene transmisión automática o manual. En la columna titulada ciudad mpg se da el rendimiento de combustible en ciudad, en millas por galón (mpg).



Camión	Nombre	Tracción	Desplazamiento	Cilindros	Transmisión	Ciudad MPG
1	C1500 Silverado	2WD	4.3	6	Auto	15
2	C1500 Silverado	2WD	4.3	6	Manual	15
3	C1500 Silverado	2WD	4.8	8	Auto	15
4	C1500 Silverado	2WD	4.8	8	Manual	16
5	C1500 Silverado	2WD	5.3	8	Auto	11
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
32	K1500 Sierra	4WD	5.3	8	Auto	15
33	K1500 Sierra	4WD	5.3	8	Auto	15
34	Sonoma	4WD	4.3	6	Auto	17
35	Sonoma	4WD	4.3	6	Manual	15

- a. Dé una ecuación de regresión estimada que sirva para predecir el consumo de combustible en la ciudad cuando se conoce el desplazamiento del motor. Haga una prueba de significancia empleando $\alpha = 0.05$.
 - b. Agregue la variable ficticia Tracción4, que toma el valor 0 si la furgoneta tiene tracción en dos ruedas y 1 si tiene tracción en cuatro ruedas. Obtenga una ecuación de regresión estimada que sirva para predecir el consumo de combustible en ciudad cuando se conoce el desplazamiento del motor y el valor de la variable ficticia Tracción4.
 - c. Use $\alpha = 0.05$ para determinar si la variable ficticia agregada en el inciso b) es significativa.
 - d. Agregue la variable ficticia OchoCil, que toma el valor 0 si la furgoneta tiene motor de seis cilindros y el valor 1 si la furgoneta tiene motor de ocho cilindros. Obtenga la ecuación de regresión estimada que sirva para predecir el rendimiento de combustible en ciudad cuando se conoce el desplazamiento del motor y el valor de las variables ficticias Tracción4 y OchoCil.
 - e. Pruebe la significancia global y la significancia de cada una de las variables en la ecuación obtenida en el inciso d). Use $\alpha = 0.05$.
57. En el mercado actual se ofrece una amplia variedad de vehículos utilitarios deportivos o SUV (acrónimo en inglés de Sport Utility Vehicle) y de pickups. Para muchos de los compradores es un factor importante el valor de reventa del vehículo. En la tabla siguiente se presenta el valor de reventa (%) después de dos años y se sugiere el precio de 10 SUV, de 10 pickups pequeñas y de 10 pickups grandes (*Kipinger's New Cars & Truckers 2000 Buyer's Guide*).



	Tipo de vehículo	Precio sugerido (\$)	Valor de reventa (%)
Chevrolet Blazer LS	utilitario deportivo	19 495	55
Ford Explorer Sport	utilitario deportivo	20 495	57
GMC Yukon XL 1500	utilitario deportivo	26 789	67
Honda CR-V	utilitario deportivo	18 965	65
Isuzu VehiCross	utilitario deportivo	30 186	62
Jeep Cherokee Limited	utilitario deportivo	25 745	57
Mercury Mountaineer	utilitario deportivo	29 895	59
Nissan Pathfinder XE	utilitario deportivo	26 919	54
Toyota 4Runner	utilitario deportivo	22 418	55
Toyota RAV4	utilitario deportivo	17 148	55
Chevrolet S-10 Extended Cab	pickup pequeña	18 847	46
Dodge Dakota Club Cab Sport	pickup pequeña	16 870	53
Ford Ranger XLT Regular Cab	pickup pequeña	18 510	48
Ford Ranger XLT Supercab	pickup pequeña	20 225	55
GMC Sonoma Regular Cab	pickup pequeña	16 938	44
Isuzu Hombre Spacecab	pickup pequeña	18 820	41
Mazda B4000 SE Cab Plus	pickup pequeña	23 050	51
Nissan Frontier XE Regular Cab	pickup pequeña	12 110	51
Toyota Tacoma Xtracab	pickup pequeña	18 228	49
Toyota Tacoma Xtracab V6	pickup pequeña	19 318	50
Chevrolet K2500	pickup grande	24 417	60
Chevrolet Silverado 2500 Ext	pickup grande	24 140	64
Dodge Ram 1500	pickup grande	17 460	54
Dodge Ram Quad Cab 2500	pickup grande	32 770	63
Dodge Ram Regular Cab 2500	pickup grande	23 140	59
Ford F150 XL	pickup grande	22 875	58
Ford F-350 Super Duty Crew Cab XL	pickup grande	34 295	64
GMC New Sierra 1500 Ext Cab	pickup grande	27 089	68
Toyota Tundra Access Cab Limited	pickup grande	25 605	53
Toyota Tundra Regular Cab	pickup grande	15 835	58

- Obtenga la ecuación de regresión estimada que sirva para predecir el valor de reventa conociendo el precio sugerido. Pruebe la significancia de la relación empleando como nivel de significancia 0.05.
- ¿Proporciona la ecuación de regresión estimada obtenida en el inciso a) un buen ajuste a los datos? Explique.
- Obtenga la ecuación de regresión estimada que sirva para predecir el valor de reventa conociendo el precio sugerido y el tipo de vehículo.
- Emplee la prueba F para determinar la significancia de los resultados de la regresión. ¿A qué conclusión se llega empleando 0.05 como nivel de significancia?

Caso problema 1 Consumer Research, Inc.

Consumer Research, Inc., es una empresa que realiza estudios para otras empresas sobre las actitudes y el comportamiento de los consumidores. En un estudio, el cliente solicitó un estudio sobre las características de los consumidores que pueden servir para predecir los montos que cargan a sus tarjetas de crédito. De una muestra de 50 consumidores se obtuvieron datos sobre ingreso anual, tamaño de la familia, y cargos anuales hechos las tarjetas de crédito. Los datos que se presentan a continuación se encuentran en el archivo Consumer del disco compacto que se distribuye con el libro.



Ingreso (miles de \$)	Tamaño de la familia	Monto de los cargos (\$)	Ingreso (miles de \$)	Tamaño de la familia	Monto de los cargos (\$)
54	3	4016	54	6	5573
30	2	3159	30	1	2583
32	4	5100	48	2	3866
50	5	4742	34	5	3586
31	2	1864	67	4	5037
55	2	4070	50	2	3605
37	1	2731	67	5	5345
40	2	3348	55	6	5370
66	4	4764	52	2	3890
51	3	4110	62	3	4705
25	3	4208	64	2	4157
48	4	4219	22	3	3579
27	1	2477	29	4	3890
33	2	2514	39	2	2972
65	3	4214	35	1	3121
63	4	4965	39	4	4183
42	6	4412	54	3	3730
21	2	2448	23	6	4127
44	1	2995	27	2	2921
37	5	4171	26	7	4603
62	6	5678	61	2	4273
21	3	3623	30	2	3067
55	7	5301	22	4	3074
42	2	3020	46	5	4820
41	7	4828	66	4	5149

Reporte administrativo

1. Usando los métodos de la estadística descriptiva dé un resumen de estos datos. Haga un comentario sobre sus hallazgos.
2. Obtenga ecuaciones de regresión estimada, usando como variable independiente, primero, el ingreso anual y después, el tamaño de la familia. ¿Cuál de estas variables es mejor predictor de los cargos a las tarjetas de crédito? Analice sus hallazgos.
3. Obtenga una ecuación de regresión estimada en la que ingreso anual y tamaño de la familia sean las variables independientes. Analice sus hallazgos.
4. ¿Cuál es el monto del cargo anual en tarjetas de crédito que se puede predecir para un hogar de tres personas con ingreso anual de \$4000?
5. Analice la necesidad de agregar otras variables independientes al modelo. ¿Qué variables sería útil agregar al modelo?

Caso problema 2 Predicción de la puntuación en un examen

Con objeto de predecir cómo se clasificarán los distritos escolares al considerar la pobreza y otras medidas relacionadas con el ingreso, *The Cincinnati Enquirer* reunió datos del Servicio de Administración de la Educación del Departamento de Educación de Ohio y del Departamento de Impuestos de Ohio (*The Cincinnati Enquirer*, 30 de noviembre de 1997). Primero, a principios de 1996, este periódico obtuvo datos sobre las calificaciones de aprobación en matemáticas, lectura, ciencias, escritura y civismo para alumnos de cuarto, noveno y doceavo grados. Combinando estos datos, el periódico calculó el porcentaje total de estudiantes que aprobaba los exámenes en cada distrito.

Se registró también el porcentaje de estudiantes del distrito escolar que recibía Apoyo para menores dependientes (o Aid for Dependent Children, ADC), el porcentaje de quienes calificaron para recibir almuerzos gratis o de precio reducido, así como el ingreso familiar mediano. Una fracción de los datos registrados para los 608 distritos escolares es la siguiente. (El conjunto completo de datos está disponible en el CD que acompaña al libro en el archivo llamado Enquirer).



Posición	Distrito escolar	Condado	% de aprobados	% con ADC	% con almuerzo gratis	Ingreso mediano (\$)
1	Ottawa Hills Local	Lucas	93.85	0.11	0.00	48 231
2	Wyoming City	Hamilton	93.08	2.95	4.59	42 672
3	Oakwood City	Montgomery	92.92	0.20	0.38	42 403
4	Madeira City	Hamilton	92.37	1.50	4.83	32 889
5	Indian Hill Ex Vill	Hamilton	91.77	1.23	2.70	44 135
6	Solon City	Cuyahoga	90.77	0.68	2.24	34 993
7	Chagrin Falls Ex Vill	Cuyahoga	89.89	0.47	0.44	38 921
8	Mariemont City	Hamilton	89.80	3.00	2.97	31 823
9	Upper Arlington City	Franklin	89.77	0.24	0.92	38 358
10	Granville Ex Vill	Licking	89.22	1.14	0.00	36 235
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.

Los datos se han ordenado de acuerdo a los porcentajes en la columna % de aprobados, que son los porcentajes totales de estudiantes que aprueban los exámenes. Los datos en la columna titulada % con ADC son los porcentajes de estudiantes, de cada distrito escolar, que reciben ADC, y los datos en la columna cuyo encabezado es % con almuerzo gratis son los porcentajes de estudiantes acreedores de almuerzo gratuito o a precio reducido. En la columna cuyo encabezado es ingreso mediano, se da el ingreso mediano por familia en cada distrito. Para cada uno de los distritos escolares se da también el condado en el que ubica el distrito escolar. Obsérvese que hay casos en los que en la columna % de almuerzo gratuito aparece un 0, esto indica que ese distrito no participa en el programa de almuerzo gratuito.

Reporte administrativo

Analice este conjunto de datos empleando los métodos presentados en este capítulo y en los capítulos anteriores. Presente un resumen de su análisis comprendiendo los resultados estadísticos clave, las conclusiones, y las recomendaciones en un reporte administrativo. Incluya todo material técnico que considere sea adecuado en un apéndice.

Caso problema 3 Aportaciones de los alumnos

Las donaciones de los exalumnos son una importante fuente de ingresos para las universidades. Si los administradores pudieran determinar los factores que influyen sobre el aumento de la cantidad de alumnos que hacen donaciones, podrían poner en marcha políticas que llevarían a ganancias mayores. Las investigaciones indican que los estudiantes más satisfechos con la relación con sus profesores tienen más probabilidad de titularse, lo que a su vez lleva al aumento de la cantidad de alumnos que hagan donaciones. En la tabla 15.13 se muestran datos de 48 universidades de Estados Unidos (*American's Best Collage*, edición del año 2000). La columna titulada "tasa de titulados" da el porcentaje de alumnos titulados, de los inicialmente inscritos. La columna que tiene como título "% de grupos con menos de 20" da muestra el porcentaje de grupos con menos de 20 alumnos. La columna que tiene como título "Tasa de estudiantes/facultad" da la cantidad total de estudiantes inscritos, dividida entre la cantidad de facultades. Por último, la co-

TABLA 15.13 DATOS DE 48 UNIVERSIDADES NACIONALES (DE ESTADOS UNIDOS)

	Estado	Tasa de titulados	% de grupos con menos de 20	Tasa de estudiantes/facultad	Tasa de alumnos que donan
Boston College	MA	85	39	13	25
Brandeis University	MA	79	68	8	33
Brown University	RI	93	60	8	40
California Institute of Technology	CA	85	65	3	46
Carnegie Mellon University	PA	75	67	10	28
Case Western Reserve Univ.	OH	72	52	8	31
College of William and Mary	VA	89	45	12	27
Columbia University	NY	90	69	7	31
Cornell University	NY	91	72	13	35
Dartmouth College	NH	94	61	10	53
Duke University	NC	92	68	8	45
Emory University	GA	84	65	7	37
Georgetown University	DC	91	54	10	29
Harvard University	MA	97	73	8	46
Johns Hopkins University	MD	89	64	9	27
Lehigh University	PA	81	55	11	40
Massachusetts Inst. of Technology	MA	92	65	6	44
New York University	NY	72	63	13	13
Northwestern University	IL	90	66	8	30
Pennsylvania State Univ.	PA	80	32	19	21
Princeton University	NJ	95	68	5	67
Rice University	TX	92	62	8	40
Stanford University	CA	92	69	7	34
Tufts University	MA	87	67	9	29
Tulane University	LA	72	56	12	17
U. of California–Berkeley	CA	83	58	17	18
U. of California–Davis	CA	74	32	19	7
U. of California–Irvine	CA	74	42	20	9
U. of California–Los Angeles	CA	78	41	18	13
U. of California–San Diego	CA	80	48	19	8
U. of California–Santa Barbara	CA	70	45	20	12
U. of Chicago	IL	84	65	4	36
U. of Florida	FL	67	31	23	19
U. of Illinois–Urbana Champaign	IL	77	29	15	23
U. of Michigan–Ann Arbor	MI	83	51	15	13
U. of North Carolina–Chapel Hill	NC	82	40	16	26
U. of Notre Dame	IN	94	53	13	49
U. of Pennsylvania	PA	90	65	7	41
U. of Rochester	NY	76	63	10	23
U. of Southern California	CA	70	53	13	22
U. of Texas–Austin	TX	66	39	21	13
U. of Virginia	VA	92	44	13	28
U. of Washington	WA	70	37	12	12
U. of Wisconsin–Madison	WI	73	37	13	13
Vanderbilt University	TN	82	68	9	31
Wake Forest University	NC	82	59	11	38
Washington University–St. Louis	MO	86	73	7	33
Yale University	CT	94	77	7	50

luma que tiene como título “Tasa de alumnos que donan” da el porcentaje de alumnos que han hecho alguna donación a la universidad.

Reporte administrativo

1. Resuma estos datos empleando los métodos de la estadística descriptiva.
2. Obtenga una ecuación de regresión estimada que sirva para predecir la tasa de donaciones de los alumnos dada la cantidad de alumnos que se titulan. Analice sus hallazgos.
3. Obtenga una ecuación de regresión estimada que sirva para predecir la tasa de donaciones de los alumnos empleando los datos proporcionados.
4. ¿Qué conclusiones y recomendaciones puede obtener de su análisis?

Caso problema 4 Predicción del porcentaje de triunfos de la NFL



En la liga nacional de futbol americano de Estados Unidos se da seguimiento a diversos datos de desempeño tanto del equipo como de los jugadores (www.nfl.com). En el archivo titulado NLFS-tats del disco compacto se presentan algunos de los datos de fin de año de la temporada del 2005 de la NFL. Cada renglón corresponde a los datos de un equipo de la NFL, y los equipos aparecen de acuerdo a su porcentaje de juegos ganados. A continuación se da la descripción de los datos.

WinPct	Porcentaje de juegos ganados
DefYds/G	Promedio de yardas permitidas por la defensiva del juego
RushYds/G	Promedio de yardas por carrera
PassYds/G	Promedio de yardas por aire por juego
FGPct	Porcentaje de goles de campo
TakeInt	TakeInt Intercepciones obtenidas; total de intercepciones obtenidas por la defensa del equipo
TakeFum	TakeFun Balones sueltos obtenidos; total de balones recuperados por la defensa del equipo
GiveInt	GiveInt Intercepciones otorgadas; total de intercepciones hechas por la ofensiva del equipo
GiveFum	GiveFun Balones sueltos perdidos; total de balones perdidos por la defensa del equipo

Reporte administrativo

1. Resuma los datos empleando los métodos de la estadística descriptiva. Haga un comentario sobre sus hallazgos.
2. Obtenga una ecuación de regresión estimada que sirva para predecir WinPCT usando DefYds/G, RushYds/G, PassYds/G y FGPct. Analice sus hallazgos.
3. En la ecuación de regresión estimada obtenida en el inciso 2), elimine todas las variables independientes que no sean significativas y obtenga otra ecuación de regresión estimada que sirva para predecir WinPct. Use $\alpha = 0.05$.
4. Algunos analistas de futbol americano consideran que las pérdidas de balón son uno de los factores más importantes para determinar el éxito de un equipo. Si $\text{Takeaways} = \text{TakeInt} + \text{TakeFum}$ y $\text{Giveaways} = \text{GiveInt} + \text{GiveFum}$, sea $\text{NetDiff} = \text{Takeaways} - \text{Giveaways}$. Obtenga una ecuación de regresión estimada que sirva para predecir WinPct empleando NetDiff. Compare estos resultados con la ecuación de regresión estimada obtenida en el inciso 3).
5. Obtenga una ecuación de regresión estimada que permita predecir WinPct usando todos los datos proporcionados.

Apéndice 15.1 Regresión múltiple con Minitab



En la sección 15.2 se vio la solución a problemas de regresión múltiple mediante paquetes de software mediante los resultados dados por Minitab al problema de la empresa Butler Trucking. En este apéndice se describen los pasos requeridos para que Minitab genere esos resultados. Primero, es necesario ingresar los datos en una hoja de cálculo de Minitab. Las millas recorridas se ingresan en la columna C1, el número de entregas se ingresan en la columna C2 y el tiempo de recorrido (en horas) en la columna C3. Los nombres de las variables, Miles (millas), Deliveries (entregas) y Time (tiempo) se ingresan como encabezados de estas columnas. En la explicación siguiente se hará referencia a los datos empleando los nombres de las variables o los identificadores de las columnas C1, C2 y C3. A continuación se describen los pasos a seguir con Minitab para obtener los resultados de regresión que se presentan en la figura 15.4.

Paso 1. Seleccionar el menú **Stat**

Paso 2. Seleccionar el menú **Regression**

Paso 3. Elegir **Regression**

Paso 4. Cuando aparezca el cuadro de diálogo **Regression**

Ingresar Time en la caja **Response**

Ingresar Miles y Deliveries en el cuadro **Predictors**

Clic en **OK**

Apéndice 15.2 Regresión múltiple con Excel



En la sección 15.2 se vio la solución a problemas de regresión múltiple empleando paquetes de software mediante los resultados dados por Minitab al problema de la empresa Butler Trucking. En este apéndice se describe el uso de la herramienta de regresión de Excel para obtener la ecuación de regresión estimada para el problema de Butler Trucking. A medida que se describen los pasos a seguir consúltese la figura 15.14. Primero, en las celdas A1:D1 de la hoja de cálculo se ingresan los rótulos Recorrido, Millas, Entregas y Tiempo, y en las celdas B2:D11 se ingresan los datos muestrales. En las celdas A2:A11, los números 1-10 sirven para identificar cada observación.

Los pasos siguientes describen cómo emplear la herramienta de regresión para el análisis de regresión múltiple.

Paso 1. Seleccionar el menú **Herramientas**

Paso 2. Elegir **Análisis de datos**

Paso 3. Elegir **Regresión** en la lista Funciones para análisis

Paso 4. Cuando aparezca el cuadro de diálogo Regresión

Ingresar D1:D11 en el cuadro **Rango Y de entrada**

Ingresar B1:C11 en el cuadro **Rango X de entrada**

Seleccionar **Rótulos**

Seleccionar **Nivel de confianza**

Ingresar 99 en el cuadro **Nivel de confianza**

Seleccionar **Rango de salida**

Ingresar A13 en el cuadro **Rango de salida** (para identificar la esquina superior izquierda de la de la hoja de cálculo en donde aparecerán los resultados)

Clic en **Aceptar**

En los resultados de Excel que se presentan en la figura 15.14, el rótulo para la variable independiente x_1 es Millas (ver celda A30) y el rótulo para la variable independiente x_2 es Entregas (ver celda A31). La ecuación de regresión estimada es

$$\hat{y} = -0.8687 + 0.0611x_1 + 0.9234x_2$$

FIGURA 15.14 RESULTADOS DADOS POR EXCEL AL PROBLEMA DE BUTLER TRUCKING CON DOS VARIABLES INDEPENDIENTES

	A	B	C	D	E	F	G	H	I	J
1	Assignment	Miles	Deliveries	Time						
2	1	100	4	9.3						
3	2	50	3	4.8						
4	3	100	4	8.9						
5	4	100	2	6.5						
6	5	50	2	4.2						
7	6	80	2	6.2						
8	7	75	3	7.4						
9	8	65	4	6						
10	9	90	3	7.6						
11	10	90	2	6.1						
12										
13	SUMMARY OUTPUT									
14										
15	Regression Statistics									
16	Multiple R	0.9507								
17	R Square	0.9038								
18	Adjusted R Square	0.8763								
19	Standard Error	0.5731								
20	Observations	10								
21										
22	ANOVA									
23		df	SS	MS	F	Significance F				
24	Regression	2	21.6006	10.8003	32.8784	0.0003				
25	Residual	7	2.2994	0.3285						
26	Total	9	23.9							
27										
28		Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 99.0%	Upper 99.0%	
29	Intercept	-0.8687	0.9515	-0.9129	0.3916	-3.1188	1.3813	-4.1986	2.4612	
30	Miles	0.0611	0.0099	6.1824	0.0005	0.0378	0.0845	0.0265	0.0957	
31	Deliveries	0.9234	0.2211	4.1763	0.0042	0.4006	1.4463	0.1496	1.6972	
32										

Obsérvese que el uso de la herramienta de regresión de Excel para la regresión múltiple es casi igual a su uso para regresión lineal simple. La principal diferencia es que en el caso de la regresión múltiple se requiere un rango mayor de celdas para identificar las variables independientes.

Apéndice 15.3 Regresión logística con Minitab



Minitab le llama a la regresión logística con una sola variable independiente que puede tomar los valores 0 y 1, Regresión Logística Binaria (Binary Logistic Regression). En este apéndice se describen los pasos que se requieren en el procedimiento de regresión logística binaria de Minitab para generar los resultados presentados en la figura 15.13 para el problema de Simmons. Primero, en una hoja de cálculo de Minitab deben ingresarse los datos. Las cantidades (en miles de \$) que gastaron los clientes en las tiendas Simmons se ingresan en la columna C2, los datos sobre la tarjeta de crédito (1 si tienen tarjeta de crédito de Simmons; 0 si no es así) se ingresan en la columna C3 y el dato sobre el uso del cupón (1 si el cliente usó el cupón; 0 si no fue así) se ingresan en la columna C4. Los nombres de las variables Spending (gasto) Card (tarjeta) y Coupon (cupón) se ingresan en la hoja de cálculo como encabezados de las columnas.

En la explicación siguiente se hará referencia a los datos empleando los nombres de las variables o los identificadores de las columnas C2, C3 y C4. Mediante los pasos siguientes se generarán los resultados de la regresión logística.

Paso 1. Seleccionar el menú **Stat**

Paso 2. Seleccionar el menú **Regression**

Paso 3. Elegir **Binary Logistic Regression**

Paso 4. Cuando aparezca el cuadro de diálogo **Binary Logistic Regression**

 Ingresar Coupon en el cuadro **Response**

 Ingresar Spending y Card en el cuadro **Model**

 Clic en **OK**

La información presentada en la figura 15.13 aparecerá como parte de los resultados.

CAPÍTULO 16



Análisis de regresión: construcción de modelos

CONTENIDO

LA ESTADÍSTICA
EN LA PRÁCTICA:
LA EMPRESA MONSANTO

16.1 EL MODELO LINEAL GENERAL

Modelado de relaciones
curvilíneas
Interacción
Transformaciones a la variable
dependiente
Modelos no lineales que son
intrínsecamente lineales

16.2 DETERMINACIÓN DE CUÁNDO AGREGAR O QUITAR VARIABLES

Caso general
Uso del valor- p

16.3 ANÁLISIS DE UN PROBLEMA MAYOR

16.4 PROCEDIMIENTOS DE ELECCIÓN DE VARIABLES

Regresión por pasos
Selección hacia adelante
Eliminación hacia atrás
Regresión de los mejores
subconjuntos
Elección final

16.5 MÉTODO DE REGRESIÓN MÚLTIPLE PARA EL DISEÑO DE EXPERIMENTOS

16.6 AUTOCORRELACIÓN Y LA PRUEBA DE DURBIN-WATSON

